分类号：TP311　　单位代码：10422
密　级：公开　　学　　号：202215114

山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree

论文题目：基于双注意力机制检测网络 YO-CSA 和时空约束的羽毛球三维轨迹实时提取系统

YO-CSA-T: A Real-time Badminton Tracking System Utilizing YOLO Based on Contextual and Spatial Attention

作 者 姓 名　来苑
培 养 单 位　计算机科学与技术学院
专 业 名 称　计算机科学与技术
指 导 教 师　宣东 教授
合 作 导 师

2025 年 5 月 30 日

中国知网 https://www.cnki.net

摘　要

要实现机器人与人进行羽毛球对打，首先需要获取羽毛球的三维轨迹。而对打任务不可避免地对三维羽毛球轨迹检测有着极高的实时性和准确度的要求。然而，羽毛球飞行时的高速运动，以及相机成像对视角的依赖，一者图像中的羽毛球极容易受环境元素（如场地线）干扰，二者羽毛球在飞行过程中会呈现多种视觉效果。这给快速而准确的二维小目标检测带来了巨大的挑战。

本文以开发一个集实时性与准确性于一体的三维羽毛球跟踪系统为目标。本文首先提出了 YO-CSA 二维检测网络，在 YOLOv8s 的基础上，引入上下文注意力和空间注意力双重注意力机制，①基于双卷积上下文注意力单元（CoT2f）重构骨干网络，②设计了基于空间注意力的颈部网络（SANeck），③引入空间注意力解耦头，搭建了 YO-CSA 二维检测网络，增强了模型提取和融合全局与局部特征的能力，实现了对检测精度的显著提升和对实时性的权衡。

依托于 YO-CSA 二维检测网络，本文集成三个子任务——检测、预测和补偿，构建了一个实时的三维羽毛球轨迹检测系统 YO-CSA-T。该系统首先基于 YO-CSA 网络进行二维图像上的实时羽毛球检测，然后通过立体视觉模块将左右对称的二维轨迹合理映射到三维世界空间中，并生成先验预测以校正和辅助检测任务。最后，依托于轨迹补偿模块，系统会填补轨迹缺失的中间帧，确保轨迹的一致性和连续性。此外，本文在系统执行中引入了多重符合时空演化规则的约束策略，以提高系统在复杂环境中的鲁棒性。

本文在自建的数据集上进行了广泛的实验，评估了 YO-CSA 模型和系统的有效性。对比实验和消融实验结果表明，YO-CSA 二维检测网络在 mAP@0.75 上达到 90.43%的高精度，显著超越了 YOLOv8s 和 YOLO11s。此外，本文在 12 个测试序列上验证了 YO-CSA-T 系统的轨迹提取性能。为了定量分析，本文引入了轨迹平滑度指数和一致性指数并基于多种策略进行了比较。实验证明，YO-CSA-T 可以在保持超过 130fps 的速度下，提取高一致性和连续性的三维空间轨迹，实验结果展示了其在实际应用中的有效性。

关键词：实时小目标检测；三维建模；三维轨迹提取；注意力机制

中国知网　https://www.cnki.net

ABSTRACT

To successfully implement a badminton-playing robot, it is essential to obtain the 3D trajectory of the shuttlecock. However, this task requires not only high accuracy but also real-time performance due to the fast speed of the shuttlecock and the challenges posed by camera perspective dependence. In addition, the shuttlecock's motion is often affected by environmental elements, such as court lines, and exhibits various visual effects during flight. These factors pose significant challenges to fast and accurate 2D small object detection.

This thesis aims to develop a 3D shuttlecock tracking system that integrates both real-time performance and accuracy. To achieve this, we propose the YO-CSA 2D detection network, which builds upon YOLOv8s by incorporating a dual-attention mechanism combining contextual and spatial attention. Specifically, we: (1) reconstruct the backbone network using a dual-convolution contextual attention unit (CoT2f), (2) design a spatial attention-based neck network (SANeck), and (3) introduce a spatial attention-decoupling head. These enhancements empower the model to better extract and fuse global and local features, significantly improving detection accuracy while maintaining a balance with real-time performance.

Based on the YO-CSA 2D detection network, we integrate three key sub-tasks—detection, prediction, and compensation—to construct a real-time 3D shuttlecock trajectory tracking system, YO-CSA-T. The system first performs real-time shuttlecock detection in 2D images using the YO-CSA network. Then, leveraging a stereo vision module, it maps the left-right symmetric 2D trajectories into the 3D world space and generates prior predictions to refine and assist the detection process. Finally, supported by a trajectory compensation module, the system interpolates missing intermediate frames to ensure trajectory consistency and continuity. Furthermore, we introduce multiple constraints that align with spatiotemporal evolution rules, enhancing the system's robustness in complex environments.

We conduct extensive experiments on a custom-built dataset to evaluate the effectiveness of both the YO-CSA model and the YO-CSA-T system. Comparison and ablation experiments show that the YO-CSA 2D detection network achieves a high accuracy of 74.00% mAP@0.75, surpassing both YOLOv8s and YOLOv11. Moreover, the YO-CSA-T system demonstrates excellent trajectory extraction performance across 12 test sequences, maintaining a speed of over 130 fps, showcasing its efficiency in practical applications.

Key words: real-time small target detection; stereo vision; 3D trajectory extraction; attention mechanism

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 研究问题和挑战.....1
1.3 国内外研究现状.....2
1.4 研究内容和主要贡献.....3
1.5 论文内容安排.....4
第 2 章 相关工作.....6
2.1 目标检测.....6
2.1.1 目标检测任务.....6
2.1.2 双阶段目标检测.....6
2.1.3 单阶段目标检测.....7
2.2 自注意力机制.....8
2.2.1 自注意力机制原理.....8
2.2.2 自注意力机制在目标检测方面的应用.....9
2.3 立体视觉建模.....10
2.4 本章小结.....11
第 3 章 YO-CSA:基于双注意力机制的二维检测网络.....12
3.1 YOLO 系列简述.....12
3.2 YO-CAS 网络结构概览.....12
3.3 双卷积上下文注意力单元 CoT2f.....14
3.4 基于空间注意力的颈部网络 SANeck.....17
3.5 空间注意力解耦头.....19
3.6 本章小结.....21
第 4 章 YO-CSA-T:基于 YO-CSA 和时空约束的羽毛球三维轨迹实时提取系统.....22
4.1 系统流程阐述.....22
4.2 立体视觉平台搭建.....23
4.2.1 搭建和相机选型.....23
4.2.2 相机标定.....25
4.3 YO-CSA 二维检测模块.....29
4.4 重建三维轨迹.....30
4.5 基于重投影更新时空约束.....32
4.6 补偿模块.....33
4.7 本章小结.....34

中国知网 https://www.cnki.net

第 5 章 实验设计与结果分析 35
5.1 数据集.....35
5.1.1 数据集的采集与制作.....35
5.1.2 数据增强.....37
5.2 检测模块相关实验与结果分析 39
5.3 系统性能相关实验与结果分析 43
5.3.1 评价指标.....43
5.3.2 实验结果分析.....44
5.4 本章小结.....49
第 6 章 总结与展望 50
参考文献.....52

中国知网 https://www.cnki.net

第1章 绪论

1.1 研究背景与意义

从2012年AlexNet[1]走到人前，深度学习点燃星星之火开始，深度学习目前已经蓬勃发展了十余年。在这十余年间，深度学习逐渐发展出了多个分支，包括AI智能问答[2]、文本自动生成[3]、图像多维分析[4][5]、异常行为检测[6]、时序预测等[7]。随着YOLO[8][9][10][11][12][13][14]、GAN[15]、Bert[16]、Transformer[17]等各种优秀的网络竞相涌现，深度学习为各个领域注入了新的生机，其中就包括了机器人领域。

从融合了自然语言处理能力和自动巡航功能的配送机器人，到能够自动检测盒跟踪目标物体的智能移动监控机器人，再到体育领域仍在研发阶段的运动机器人，深度学习与机器人的深度结合，正在为社会提供新的驱动力。深度学习在体育领域已经有了一定的实践。早在2006年，美国网球公开赛就开始使用集成了多个高速摄像头的鹰眼系统[18]来捕捉网球并提取轨迹信息，并且辅助裁判判决。2018年的俄罗斯世界杯足球赛也设置了视频辅助裁判系统（Video Assistant Referee，VAR）[19]。它作为裁判的一种辅助工具，基于虚拟现实技术、图像处理技术等多种计算机技术协助主裁判进行赛事判决。

深度学习与机器人的碰撞，是多场人机大战的导火索，包括2016年AlphaGo[20]打败九段旗手李世石、2021年GT Sophy[21]击败顶级Gran Turismo游戏赛车手Jones。然而，在球类运动中，比如羽毛球运动中，虽然现有的技术已经可以通过搭建硬件系统来采集比赛数据，但是，落地一个对打机器人，实现真正意义上的人机对打，依然还有一段距离。对打机器人的实现涉及到多个挑战任务[22]，包括实时检测目标球位置，预测球的未来轨迹及其落点，实时更新和优化机械臂运动策略，最终将球回击到对面场地指定位置。球的轨迹检测作为击球的第一步数据分析，也是最为基础和关键的，它的速度和准确度直接影响了球落点预测可信度和回击策略优化方向。

在三维空间中实时并且准确地获取球轨迹，除了可以为对打机器人预估球的落点和制作击球策略带来有利的数据依据外，也可以用来实时地分析比赛数据，制作基于三维的自动化比赛分析系统，帮助教练准确地分析运动员能力，为运动员做出更有针对性、更有效率的训练方案。

1.2 研究问题和挑战

小型球类运动，比如羽毛球、网球、乒乓球等，作为国民运动甚至是全球性运动，其热度在近年来持续上升。小型球操作简单，容易上手，是兼具娱乐性和健身效果的运动。小型球类运动的场地要求灵活，适合在室内外各种环境下进行，因此深受大众喜爱。

中国知网 https://www.cnki.net

在羽毛球运动中，能够实时且准确地提取球轨迹，是对打机器人发展的瓶颈之一。要获取羽毛球对打机器人所要求的三维空间的羽毛球轨迹，有五大挑战：

（1）视觉特征有限。羽毛球是由球托和羽毛组成的类椎体结构，其中，羽毛长度为62-70 毫米，球托直径为 25-28 毫米，高度在 68-78 毫米之间。羽毛球体积小，颜色单一，因此在二维图像上能够提取的视觉特征极其有限，检测任务极易受到背景的干扰，尤其是球网和白色场地线、刺眼灯光、白色广告字等。在对打时，羽毛球体可能会与背景元素无缝融合。因此羽毛球的检测难度巨大。

（2）视觉效果多样。小型球在比赛中的高速运动，会带来模糊和拖影效果，即便是人眼有时也很难准确地辨别球体。与网球、乒乓球等圆球类结构不同，羽毛球的锥形结构最为复杂。在高速飞行的过程中，羽毛球在不同的角度有不同的展示效果，包括圆形、锥形等，相较于任意视角都表现为圆形的网球、乒乓球来说，羽毛球更难于检测。

（3）速度与精度的权衡。人机对打中，机器人需要实时轨迹的数据支撑，才能够及时优化和机械臂的运动轨迹，调整回击策略。实时的同时，数据也需要保证其精确度，否则会影响后续的策略精度。另外，作为移动设备，机器人往往不能携带高性能的计算能力。在算力的限制下，权衡精度和速度，是该课题的一大挑战。

（4）三维研究缺乏。调研发现，现有的轨迹提取研究往往将小型球轨迹的提取局限在二维图像序列中，仅关注平面内的二维运动轨迹。但是，二维轨迹是三维空间中球运动的投影，相较于三维空间，二维轨迹序列内部的高维信息会存在丢失，尤其是在高速飞行或复杂轨迹的情况下，利用二维运动特征进行轨迹提取会限制解决方案的精确度。

（5）数据集资源。由于小型球的高速运动，在低帧率的视频中，会出现模糊、拖影的效果，只有高帧率（100fps 以上）拍摄才能够较为清晰地拍摄球体。要制作高精度的数据集需要耗费大量的时间。因此，相关的公开数据集资源较少。

1.3 国内外研究现状

小型球类运动，例如羽毛球、乒乓球，他们作为受众群体较多的国民运动，必然会吸引各路研究者对其研究。不论是作为机器人对打的必要数据之一，还是作为比赛视频分析系统的支撑，球的轨迹提取都十分重要。

由于乒乓球、网球是规则的圆球体，其中心轨迹可以高度代表整个球体的轨迹，因此，部分研究者将球轨迹的提取转换成了球中心轨迹的提取任务。这也与 CenterNet[23] 的核心思想不谋而合。包括 TTNet[24]、TrackNetV2[25]和 WASB-SBDT[26]，这些工作都通过学习中心点热力图来实现目标物体的检测。TTNet 是一个集乒乓球检测、事件判定、语义分割为一体，针对高分辨率视频的多功能神经网络。TTNet 以连续的视频帧作为输入，搭建卷积神经网络，使网络学习热力图的分布。TTNet 的工作流程与双阶段目标检测模型类似，遵循先粗后细的原则[27]。TTNet 首先缩小目标区域，然后在缩小后的区域

中国知网 https://www.cnki.net

再次基于卷积对乒乓球进行细粒度的检测和分割。TTNet 的主要目标是分析视频比赛得分，因此它受限于单一的视角，且仅在二维平面上进行分析。Yu-Chuan Huang 等人提出的 TrackNetv2 实现了对网球轨迹的提取。TrackNetv2 与 UNet[28]类似，采用编码器-解码器结构由粗到细地提取图像特征，通过多尺度的特征提取，让网络学习生成热力图，基于高斯二维分布在热力图上确定球体的位置。类似地，WASB-SBDT 从 HRNet[29]中获得启发，在传统编码器-解码器的基础上引入了高分辨率模块(High-Resolution Modules，HRMs)来弥补损失的语义和空间分辨率，强化了网络预测球坐标的热力图的能力。

而另一部分的工作，通过优化目标检测主流网络，如 YOLO[8][9][11][12][13][14]、Mask R-CNN[30]等，来强化网络对球轨迹提取任务的适配性。Di Wu 等人在 Mask R-CNN 的基础上，基于梯度估计理论优化模型训练过程，成功提高了视频中网球的识别准确度[31]。Sebastian Gomez-Gonzalez 等人搭建了一个乒乓球的实时跟踪系统，结合了 MobilNets[32]架构，提出以 SSD 实现图像中的乒乓球检测[33]。2021 年，Tianxiao Zhang 等以 YOLOv3[9]和卡尔曼滤波[34]为基础，实现了二维网球追踪系统[35]。

也有工作参考了 Transformer[17]结构。受 ViT[36]的启发，TrackFormer[37]引入了全局上下文采样模块来捕获全局特征，缓解网络中语义的丢失，提高网络对球定位的精确度。MaxVit[38]设计了一个接受连续图像帧的顺序模型，来跟踪体育视频中的高速小型球。Hyunsung Kim 等[39]提出结合 Set Transformer 和 Hierarchical Bi-LSTM，利用 Set Transformer 学习多参与者的关系权重，为轨迹预测提供上下文信息的同时，基于 Hierarchical Bi-LSTM 捕获球的运动以及预测球的轨迹，实现对多种球类的轨迹预测。

现有的研究多聚焦于二维轨迹工作，其主要方法为直接检测球中心轨迹和基于主流网络做适配性设计。仅有乒乓球这类范围小、球特征明显的运动，有着相关的三维轨迹研究。本文的目标是针对现在工作的不足，设计和搭建一个集实时与准确性于一体的三维羽毛球跟踪系统。

1.4 研究内容和主要贡献

本文以开发一个集实时性与准确性于一体的三维羽毛球跟踪系统为目标，专注于羽毛球比赛中的羽毛球轨迹，聚焦于羽毛球三维轨迹的实时提取，进行了一系列的工作。本文提出了基于空间和上下文自注意力的羽毛球三维轨迹实时检测系统 YO-CSA-T（Tracking System Utilizing YOLO Based on Contextual and Spatial Attention）。

YO-CSA-T 主要有三大模块：二维检测模块、立体视觉模块以及轨迹补偿模块。具体地，二维检测模块基于二维检测网络 YO-CSA（YOLO Based on Contextual and Spatial Attention），深度融合空间注意力机制和上下文注意力机制，在 YOLOv8s 的基础上，实现了对图像细粒度空间特征和全局语义信息的有效捕捉和提取；立体视觉模块基于双目相机模型，以左右视角的坐标序列为数据支撑，重建了羽毛球在三维空间的运动，并逆

中国知网 https://www.cnki.net

向对二维检测增加了空间约束，减轻了检测压力；轨迹补偿模块有效补偿了图像序列中漏检或误检的错误帧，提高了系统提取得到的轨迹的准确性和完整性。本文的主要贡献如下：

（1）搭建基于空间和上下文注意力的羽毛球三维轨迹实时检测系统 YO-CSA-T，实现羽毛球比赛中对羽毛球三维轨迹的实时提取任务。YO-CSA-T 通过三个子任务——检测、预测、补偿——相互辅助，检测任务为预测任务提供数据，预测任务为检测任务增加空间约束，补偿任务弥补前两者的缺漏，实现了对羽毛球三维轨迹快速精准的提取。

（2）针对羽毛球体积小、易误检的性质，基于 YOLOv8 框架，设计了二维检测网络 YO-CSA，引入空间注意力机制，使得模型能够自适应地聚焦于细粒度的子特征提取，通过上下文注意力机制增强了模型全局特征的构建能力，提高了模型对上下文的理解，优化了解耦检测头部，帮助模型在复杂背景中做出精准定位。

（3）为了提高检测模块的速度和准确性，本文提出了立体视觉模块，并提出了两条策略辅助优化：①在原始图像中框选感兴趣区域（Region Of Interest，ROI），增强检测网络对目标区域的关注度，显著减少无关背景的干扰和计算负担，提高网络精度和鲁棒性。②根据三维轨迹的历史信息，预测羽毛球未来在左右视角中的位置，动态更新 ROI，为检测任务引入空间约束，减轻检测压力，提升模型对目标物体位置变化的适应能力。

（4）引入轨迹补偿模块。以预测得到的轨迹序列和轨迹掩码作为输入信息，基于编码器-解码器架构构建神经网络，补偿缺失帧的坐标信息，增强了轨迹信息的完整性和一致性，提高了系统在复杂环境下对目标运动状态的实时捕捉与解析能力。

（5）由于公开数据集的稀缺，为了进行有效实验，本文基于自己搭建的立体视觉平台，采集了 10 个不同场景共 32,539 张羽毛球对打图像，并制作了羽毛球相关数据集。

为了验证系统的有效性，本文在自己制作的数据集上进行了广泛的实验。本文将检测模块与 YOLOv8s 等主流网络进行了比较，结果表明，在检测任务上，YO-CSA 二维检测网络的准确率明于这些基准网络，尤其是在 mAP@0.75 指标上。此外，本文还对追踪策略进行了比较实验。实验验证了所提方法在羽毛球比赛中三维跟踪快速且微小的羽毛球轨迹的有效性。

1.5 论文内容安排

论文描述了基于 YO-CSA 二维检测网络的三维羽毛球跟踪系统 YO-CSA-T 的构建，实现了在保证准确性和实时性的前提下，对羽毛球比赛中快速且微小的羽毛球的三维轨迹的高效提取。从羽毛球比赛中提取的轨迹，不但可以用来实时地分析比赛数据，而且可以作为对打机器人预估球的落点和制作击球策略有利的数据依据。

本文主要从七个章节进行陈述：

中国知网 https://www.cnki.net

第一章，介绍研究背景与意义，明确本文的研究任务以及对应挑战，阐述研究内容及主要贡献，并概述了论文的整体结构和章节安排。

第二章，简要回顾国内外研究现状，重点讨论目标检测的相关工作、注意力机制的基本工作原理以及注意力机制在目标检测领域的实践，同时详细介绍立体视觉技术。

第三章，阐述 YO-CSA 网络结构。重点阐述了双卷积上下文自注意力单元 CoT2f，基于空间注意力的特征增强模块 SGE-2f 以及优化后的解耦检测头部三大优化模块。

第四章，详细描述了 YO-CSA-T 系统的工作流程，重点分析了三大子任务——检测、预测、补偿——的实现细节以及协同工作步骤。

第五章，总结了羽毛球比赛视频的特点，并描述了自有数据集的采集和制作流程。

第六章，对二维检测效果与系统跟踪性能进行了充分实验，并对实验结果进行了全面的性能分析，深入探讨了系统在实际应用中的表现与优化空间。

第七章，总结了论文的主要工作，回顾了研究过程中取得的成果，并提出了未来可能的研究方向和进一步改进的思路。

中国知网 https://www.cnki.net

第2章 相关工作

2.1 目标检测

2.1.1 目标检测任务

目标检测的目标是从图像中定位目标视觉物体，包含了分类和定位任务，具有广泛的应用。目标检测可以在自动驾驶领域帮助识别附近行人和车辆，实现避障；在监控领域检测目标移动轨迹，实现监控系统的智能跟踪；在安防领域自动识别异常行为，即时发出警示等。目标检测的目标是快速且准确地分析图像，并提供数据支撑。羽毛球对打机器人同样需要目标检测技术。快速的目标检测可以即时为机器人提供羽毛球的最新坐标。机器人可以根据数据进行羽毛球未来落点的预测，优化自身的行动轨迹和回击策略。

目标检测需要克服很多挑战，比如物体的尺度变化、模糊、遮挡等。目标检测的挑战还包括视角、光照条件、分辨率等。由于不同的目标检测任务具有完全不同的目标物体和约束，所以难度有所不同，其中，由于小物体的视觉信息较少，容易受到背景干扰，因此小物体检测，比如羽毛球，往往难度更高。

传统的目标检测算法通常基于手工特征构建，如第一个实现实时人脸识别的 Viola-Jones 目标检测器[40]，它首先基于滑动窗口在图像的不同尺度上提取 Haar-like 特征，然后进行积分图像计算，再将基于 AdaBoost 算法训练的分类器级联，通过级联分类器判断当前位置是否包含人脸；类似的，Felzenszwalb 等人提出可变形部件模型 DPM[41]，该模型的核心思想是将目标物体拆分成各个部件分别检测，然后将这些部分的可能组合形式标记为检测结果，最后剔除不合理的配置，得到检测结果。

手工特征难以提取复杂的特征表示，因此目标检测的研究在 2010 年后进入了瓶颈期。直到卷积神经网络的崛起促使研究者重新思考目标检测任务的解决方案。基于深度学习的目标检测算法整体可以分为双阶段检测和单阶段检测。双阶段检测算法的核心是先提取出候选区域，然后在候选区域中进行细粒度的定位，两个阶段往往要分别训练。而单阶段的检测算法仅通过一次推理，并行执行分类和定位任务。

2.1.2 双阶段目标检测

Girshick 等人在 2014 年提出的基于区域的卷积神经网络 R-CNN[42]是第一个基于深度学习的双阶段目标检测算法，顺利地打破了传统目标检测算法发展的僵局。

R-CNN 将目标检测分为分类和定位问题。模型首先会经过区域提议模块生成若干候选区域，通过选择性搜索[43]提取一组物体候选框。然后，每个候选框都会被缩放为固定大小，并输入到训练好的卷积神经网络中，提取出 4096 维的特征向量。最后，模型会基于支持向量机 SVM 来预测每个区域是否包含物体，并识别物体类别。在确定了类别后，模型会用边界框回归器预测边界框的位置和大小，进而实现定位。R-CNN 在

中国知网 https://www.cnki.net

VOC07 数据集上显著提高了性能，使得平均精度（mAP）从 33.7%（DPM-v5）提高到 58.5%[44]。但是 R-CNN 的推理速度很慢，多阶段训练也极其耗时。

2014 年，He 等人注意到卷积神经网络中，只有全连接层需要固定输入大小，因此他们修改了卷积层和区域提议模块的先后顺序，提出了空间金字塔池化网络（SPPNet）[45]，巧妙地使得模型可以处理不同纵横比的图像，优化了检测性能。而由于 SPPNet 的整体结构与 R-CNN 类似，因此它不可避免地集成了 R-CNN 多阶段训练、训练时间长等不足。注意到候选区域生成是算法耗时的瓶颈，Fast R-CNN[46]选择将候选区域与原始图像一起作为网络的输入，从而将 mAP 从 58.5%（R-CNN）提高到 70.0%的同时，在速度上提高了 146 倍。之后，Ren 等人提出利用完全卷积网络作为区域提议网络（RPN）来替代候选区域生成步骤，并构建 Faster R-CNN 网络[47]。Faster R-CNN 是第一个接近实时的深度学习检测器（COCO mAP@.5 = 42.7%，VOC07 mAP = 73.2%）。到 Faster R-CNN，目标检测系统中的大多数独立模块（例如候选框检测、特征提取和边界框回归）才被成功地集成到了一个统一的端到端学习框架中。

尽管 Faster R-CNN 的 RPN 突破了 Fast R-CNN 的速度瓶颈，但随后的检测阶段仍然存在计算冗余。研究者也提出了许多改进，包括 RFCN[48]和 Light-head R-CNN[49]。

2.1.3 单阶段目标检测

大部分双阶段目标检测算法遵循“先看一看，再思考一下”的原则，即先粗后细，首先缩小区域，然后执行定位任务，这样既能有效保证召回率又能精确定位。但双阶段算法通常需要长时间的训练，也难以达到实时性能，因此在工程应用上难以被采用。

2016 年 YOLO[8]问世，开创了单阶段模型先河，它开创性地将检测任务转换成了一个回归问题，摒弃了候选区域生成的步骤，以网格为单位，直接进行候选框及其大小的预测。这样，仅做一次推理便可获取目标物体的类别和位置。在 VOC07 数据集上，YOLO 可以在保持 mAP=52.7%的前提下，达到 155 帧每秒的推理速度。

尽管单阶段检测器速度快且结构简单，但在精度上却一直逊色于双阶段检测器。针对这一现象，Lin 等人在 2017 年提出了 RetinaNet[50]。他们发现，这一现象的元凶是前景与背景类别之间的极端不平衡性。为此，RetinaNet 引入了焦点损失函数（Focal Loss），使得模型在训练期间可以更加关注困难分类的样本。焦点损失使单阶段检测器能够在保持很高检测速度的同时，达到与两阶段检测器相当的精度。

单阶段的目标检测算法以简洁为主要特点。2019 年，Zhou 等人提出的 CenterNet[23]，去除了非极大值抑制等后处理步骤，直接将任务浓缩成了对目标物体的中心及其相关属性（如大小、姿态等）的学习，搭建了一个完全端到端的监测网络，但其检测性能也毫不逊色地在 COCO 数据集上达到了 61.1%的 mAP。

中国知网 https://www.cnki.net

近年来，Transformer[17]的自注意力机制也影响了目标检测领域，掀起了卷积和自注意力机制融合或是对立的热潮。自注意力机制优秀的全局视野，克服了卷积局部感受野的限制，进一步激发了神经网络的学习能力。如 ViT[36]验证了纯 Transformer 架构在图像领域的潜力，Detr[51]完全端到端实现目标检测，Swin Transformer[52]通过滑动敞口机制优化自注意力带来的计算成本等。

目标检测网络在迭代过程中，始终期望网络可以关注到目标物体，弱化环境影响，一种是通过学习目标物体与背景的联系，比如基于卷积结构的检测网络通常会存在一个不同尺度特征融合的模块来充分利用上下文信息，包括局部上下文或者全局上下文；另一种是强化网络对目标物体的关注度，比如 CenterNet[23]以及 Detr、Swin Transformer 等 Transformer 架构的网络。为了提高边界框的准确度，检测模型的损失函数也一直在演变，像早期的网络 R-CNN[42]、YOLOv1[8]使用简单的交叉熵损失函数，而 RetinaNet[50]、YOLOv5 利用焦点损失解决类别不平衡和分类难度差异问题。

2.2 自注意力机制

2.2.1 自注意力机制原理

2017 年，Ashish Vaswani 等人[17]首次提出的自注意力机制，是一种让模型主动对数据的不同区域学习不同关注度的注意力设计。与卷积操作全局统一处理不同，它允许网络动态调整对部分区域的关注程度，进而重点关注目标物体区域，削减对不重要区域（如背景区域）的关注。自注意力机制在设计时关注了每对元素之间的相似度，因此它可以捕捉序列中任意两个元素之间的关系，这也赋予了网络捕捉长距离依赖的能力，打破了卷积对感受野的局部性限制，可以提高模型对上下文信息的捕捉性能。

自注意力机制通过每对元素之间的相似度计算来捕捉全局语义信息。首先，自注意力机制会为输入 $\boldsymbol{X}=[\boldsymbol{x}_1,\boldsymbol{x}_2,\ldots,\boldsymbol{x}_n]$，$\boldsymbol{X}\in\mathbb{R}^{n\times d}$ 的每个元素 $\boldsymbol{x}_i$ 线性变换生成三个向量 $\boldsymbol{Q}_i$（Query）、$\boldsymbol{K}_i$（Key）、$\boldsymbol{V}_i$（Value），分别表示查询向量、键向量和值向量：

$$\boldsymbol{Q}=\boldsymbol{X}\boldsymbol{W}_Q,\qquad \boldsymbol{K}=\boldsymbol{X}\boldsymbol{W}_K,\qquad \boldsymbol{V}=\boldsymbol{X}\boldsymbol{W}_V \tag{2-1}$$

其中，$\boldsymbol{W}_Q$、$\boldsymbol{W}_K$、$\boldsymbol{W}_V$ 是网络需要学习的权重矩阵。

然后，自注意力机制模块会为每个元素计算得到一个权重分数表示它与其他位置元素的相关性，如图 2-1 所示。对于第 i 个元素，它对应的查询向量表示为 $\boldsymbol{Q}_i$，则它和第 j 个元素的相似度为 $\frac{\boldsymbol{Q}_i\cdot\boldsymbol{K}_j}{\sqrt{d_k}}$，其中 d_k 表示键向量的维度。对这些权重分数进行归一化，就可以得到权重分布，表示了模型对不同位置元素的不同关注度 Attention：

$$Attention(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V})=Softmax\left(\frac{\boldsymbol{Q}\cdot\boldsymbol{K}}{\sqrt{d_k}}\right)\boldsymbol{V} \tag{2-2}$$

中国知网 https://www.cnki.net

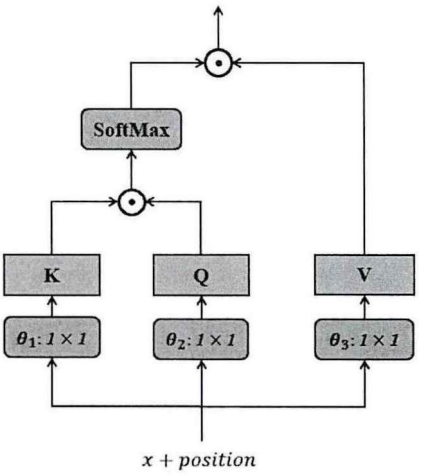


图 2-1 自注意力结构示意图

Transformer 还引入了多头注意力机制，多头注意力机制为每个子空间设置了单独的查询、键和值向量，通过并行多算多个注意力头，先在高维空间多维度地捕捉输入数据丰富的语义信息，再将多个子空间的语义拼接融合，降维得到最终的权重分布。

自注意力机制最早运用在自然语言处理领域中，与图像不同的是文本天然拥有位置信息，而图像的二维分布无法直接作为位置信息。因此，为确保自注意力机制能够理解图像的空间位置分布，通过需要显式地引入位置信息，比如，为每个像素添加二维位置编码，或者将图像切分为若干个图像块，以一维序列的结构输入到模型中。

2.2.2 自注意力机制在目标检测方面的应用

虽然自注意力机制最初是来解决自然语言处理领域中的文本问题的，但是实践发现，自注意力机制在图像中也有着良好的表现，ViT[36]开创性地将 Transformer 引入到图像领域，它将图像切分为 16x16 的图像块，将这些图像块展平成一维序列输入到模型中，就在上 ImageNet 数据集上达到了 88.55%的准确率，毫不逊色于 ResNet[53]网络 87.54%的性能表现。Transformer 目前在图像领域已经有了很多工作，TD-Net[54]提出了一种两阶段的 Trans-Deformer 网络来解决医疗分割问题，他们利用可变形卷积提高了 ViT 识别变形胰腺的能力。TSE DeepLab[55]在 DeepLabv3 的基础上，保留了原空洞卷积结构实现局部特征提取，而将骨干网络生成的特征图转换为了适合自注意力机制处理的序列化数据形式，送入到 Transformer 模块中，以增强网络全局的特征提取能力。Swin-T-NFC[15]将 ViT 运用到了点云和数据上，基于 ViT 和全连接条件随机场（FC-CRFs）的编码器-解码器架构，通过自注意力机制融合不同尺度的特征，从而实现强大的建模能力。

Transformer 也为目标检测领域注入了新活力。Detr[51]和 Swin Transformer[52]就是基于 Transformer 的目标检测模型。Detr 网络完全抛弃了卷积网络模型中的候选区域生成、区域提取、非最大抑制步骤，完全基于 Transformer 结构实现端到端的目标检测。它在

中国知网 https://www.cnki.net

编码器阶段利用 Transformer 结构对提取到的特征进行全局建模，提取图像的上下文信息，然后在解码器阶段基于查询（query）生成目标的边界框和类别。Swin Transformer 注意到了 ViT 的计算效率问题，利用局部窗口来减轻自注意力价值带来的巨大的计算压力。

虽然 Transformer 和自注意力机制可以提高网络的性能，但是，纯 Transformer 结构的模型通常需要庞大的数据集进行训练，Transformer 的高复杂度结构也对模型的速度增加了限制，另外，在局部特征提取的性能上，卷积结构更胜一筹，因此研究者开始尝试将卷积和自注意力机制融合到一个网络模型中，以取两者之长。合理地在卷积网络中结合自注意力机制也能够有效提升网络的性能。Xuanhong Chen 等人[56]提出了一种新的运算 X-volution，该操作集成了卷积计算和自注意力机制处理，在图像处理任务上取得了非常有竞争力的成绩。UniFormer[57]凭借深度卷积将位置信息嵌入到 Transformer 中，在局部和全局出充分利用 UniFormer 模块，促使网络逐步学习特征和语义信息。

鉴于现有的研究，本文聚焦于结合卷积强大的提取局部特征的能力和自注意力机制的优秀的提取捕捉全局语义的能力，实现羽毛球比赛视频中羽毛球的实时检测。

2.3 立体视觉建模

立体视觉是利用两个相机对同一场景的不同视角图像，来恢复三维空间信息（例如深度、场景结构等）的技术。立体视觉的基本原理类似于人眼的视觉系统，通过两个视角获取的场景中目标物体在图像中的差异，来计算场景中目标相对于相机的相对距离，进而推算目标的三维空间信息。立体视觉技术常被用于 SLAM 技术中，作为感知工具来收集环境信息，辅助 SLAM 重建三维场景。立体视觉建模主要有五大步骤：

（1）图像采集。立体视觉平台包含了两个不同视角的相机，需要使用这两台固定了位置和角度的相机同步拍摄同一场景。为了保证拍摄的图像在后续处理中可以获取足够的空间信息，两台相机应保持一定的视角差异和基线距离（两台相机光心之间的距离）。

（2）相机标定。标定是为了确定相机的内参矩阵、畸变系数和外参矩阵。在针孔相机模型中，对于场景中的一点 $P(x,y,z)$，要转换为二维图像上的一个像素点 $p(u,v)$，需要经过世界坐标系-相机坐标系-图像坐标系-像素坐标系转换，如公式（2-3）所示。其中，$\boldsymbol{K}$ 表示相机的内参矩阵，$\boldsymbol{T}$ 表示平台的外参矩阵，即左右相机之间的相对位姿，可由左右相机各自的外参矩阵线性转换获取。为了消除相机上透镜导致的透视失真，需要畸变系数补偿。常用的标定方法有张正友标定法[58]、基于 Kruppa 方程的自标定法[59]等。

$$\begin{bmatrix} u \\ v \end{bmatrix} = KTP_w \tag{2-3}$$

（3）特征匹配。在左右视角中根据目标物体的特征进行特征匹配，确定左右像素坐标系中目标物体的像素点。通常会提取目标物体的边缘、角点、纹理等稳定且丰富的特

中国知网 https://www.cnki.net

征作为匹配的数据支撑。常用的特征匹配算法包括角点检测算法 FAST、基于 Hessian 矩阵的 SURF 算法等。

（4）视差计算。视差是同一物体在左右视图中的位置差异信息，包括水平差值和垂直差值，立体视觉建模可以基于视差推算目标物体在三维空间中的深度信息。除了传统的图像差分法 SAD、Semi-Global Matching[60]外，随着深度学习的发展，基于深度学习的目标检测算法以其强大的鲁棒性成为视差计算的新解决方案。

（5）三维重建。利用内参、畸变系数、外参构建重建模型，根据视差推算目标物体的深度，进而获取目标物体的三维坐标。三维重建可以根据不同领域的要求提供三维坐标或是点云数据，在自动驾驶、文化遗产保护等领域有着广泛的应用。

在本文的工作中，立体视觉被用作羽毛球二维轨迹序列映射到三维空间的关键手段。本文搭建了一个精确且低成本的立体视觉平台，获取高帧率且清晰的图像序列。此外，本文通过引入时间和空间约束条件，优化了二维平面与三维空间之间的映射过程，并减轻了检测模块的计算压力，提升了系统在复杂场景提取轨迹的稳定性和准确性。

2.4 本章小结

本章简要回顾了国内外针对实时提取球类运动三维轨迹问题的研究现状，并且重点讨论了目标检测的发展现状、注意力机制的基本工作原理以及注意力机制在目标检测领域的实践，同时，本章还详细介绍了立体视觉技术，以作为二维平面与三维空间转换的桥梁。

中国知网 https://www.cnki.net

第3章 YO-CSA：基于双注意力机制的二维检测网络

3.1 YOLO 系列简述

从 2016 年 Joseph Redmon 提出 YOLOv1[8]，通过将图像拆分成网格，然后基于网格回归目标物体的类别和边界框开始，YOLO 模型成为了单阶段的目标检测模型的里程碑。YOLO 系列目前已经作为目标检测全新的解决方案活跃在近一个十年的舞台上。

最初的 YOLOv1 主要依托于一个类似 GooLeNet[61]的全卷积网络，利用卷积操作提取特征，利用全连接层预测边界框和类别，同时执行分类和定位两大任务。锚框在 YOLOv2[9]中被引入，在训练前预先指定不同纵横比的锚框可以加快网络对目标物体的定位回归。YOLOv4[11]引入了 Mosaic[62]数据增强，并提出了模型四大部分的功能拆分，包括骨干网络、颈部网络、检测头以及损失函数部分。2020 年，由 Ultralytics 公司推出的基于 Pytorch 架构实现的 YOLOv5 包含了轻量化、硬件部署以及多版本实现等功能，其易部署性和易扩展性，使 YOLOv5 成为了一个比较流行的版本。受 RepVGG 网络[63]的启发，Chuyi Li 等人提出了 EfficientRep 骨干网络，并发布了全新的 YOLOv6[12]。EfficientRep 骨干网络使得 YOLO 更易被部署在工业环境中。YOLOv6 还优化了颈部网络，强化了模型聚合多尺度特征的能力，并基于混合通道策略引入了高效的解耦头，提高了模型的检测效率。YOLOv8 提出以 C2f 模块代替 v5 版本中的 C3 模块，C2f 模块中的跳跃连接有效地丰富了模型的梯度流，使得 YOLOv8 在多项任务中（如检测、分割、姿态识别等）都取得了优越成绩。YOLOv9[13]在网络中增加了一条基于可编程梯度信息（Programable Gradient Information，PGI）的辅助可逆分支，缓解多层特征提取和空间变换导致的信息丢失。YOLOv10[14]聚焦于非极大值抑制（Non-Maximum Suppression，NMS）对推理速度的限制，提出了 NMS-Free，减少网络中的冗余计算，加快目标检测任务的进程。2024 年 10 月发布的 YOLO11 是 YOLO 系列的最新版本。它引入了 C3k2 和 C2PSA 等新模块，专注于在不显著影响精度的前提下缓解网络的计算成本。

从 YOLOv1 到 YOLO11，YOLO 系列一直在引入最新的骨干网络、金字塔结构、特征聚合模块、损失函数（交叉熵损失、焦点损失等）等，以提高多任务的性能。

3.2 YO-CAS 网络结构概览

通过对目标检测近十年来相关工作的调研可知：越来越多的工作开始结合卷积操作和注意力机制。卷积的局部特征提取能力和注意力机制的全局特征提取能力在目标检测任务上都是有益的，且两者无法被其一替代。因此，本文充分结合了卷积网络和注意力机制，基于 YOLOv8s，重新设计和搭建了 YO-CSA 网络，并验证了其优秀的性能。

中国知网 https://www.cnki.net

羽毛球作为一个小体积球体，检测难度较大。一是因为图像中羽毛球自身的视觉特征有限，容易受到背景噪声（如灯光、场地线等）干扰，二是因为羽毛球在高速飞行的过程中，随着视角的变化，在图像中会呈现出多种视觉效果以及模糊和拖影。此外，羽毛球对打机器人需要依赖高度实时和高准确度的轨迹数据来更新后续的行动策略。

本文旨在高实时性且高精度地检测和定位羽毛球，进而获取羽毛球在三维空间的飞行轨迹。而 YOLOv8 作为目标检测领域的主流解决方案之一，具有卓越的检测速度和定位精度。相比于更注重支持多任务的 YOLO11，YOLOv8 在目标检测任务上，因其几乎持平的精度以及优于 YOLO11 的检测速度，更适合于本文的工作目标。

但是，尽管 YOLOv8 在检测任务上性能优秀，对于羽毛球比赛这样同时要求高实时性和高精度的场景，还需要对其性能进行进一步的优化。因此，本文基于 YOLOv8s 的框架模式设计了 YO-CSA 二维检测网络，YO-CSA 网络架构如图 3-1 所示。

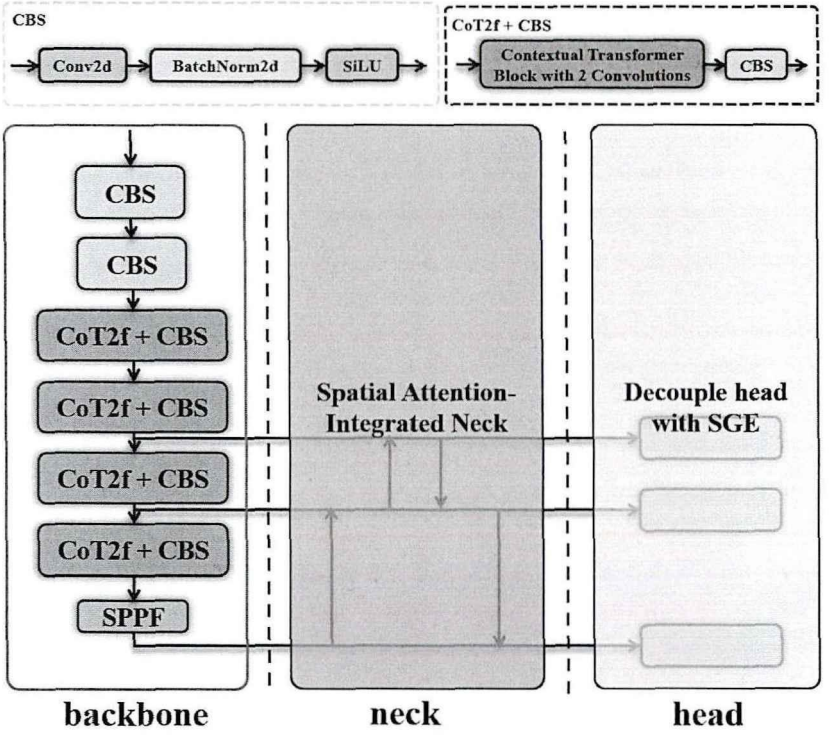


图 3-1 YO-CSA 网络整体结构示意图

受上下文注意力机制（Contextual Transformer Block, CoT）[64]和基于空间分组强化的注意力模块（Spatial Group-wise Enhance, SGE）[65]的启发，本文不仅基于双卷积上下文注意力单元（Contextual Transformer Block with 2 Convolutions，CoT2f）优化了骨干网络，还构建了融合了空间注意力的颈部网络（Spatial Attention-Integrated Neck，SANeck），目的是基于上下文注意力和空间注意力双重注意力机制以增强模型在骨干网络和颈部网络中对位置分布信息的提取和融合能力。本文还提出了空间注意力解耦头（Decouple head with SGE）以强化模型对位置分布的学习能力。

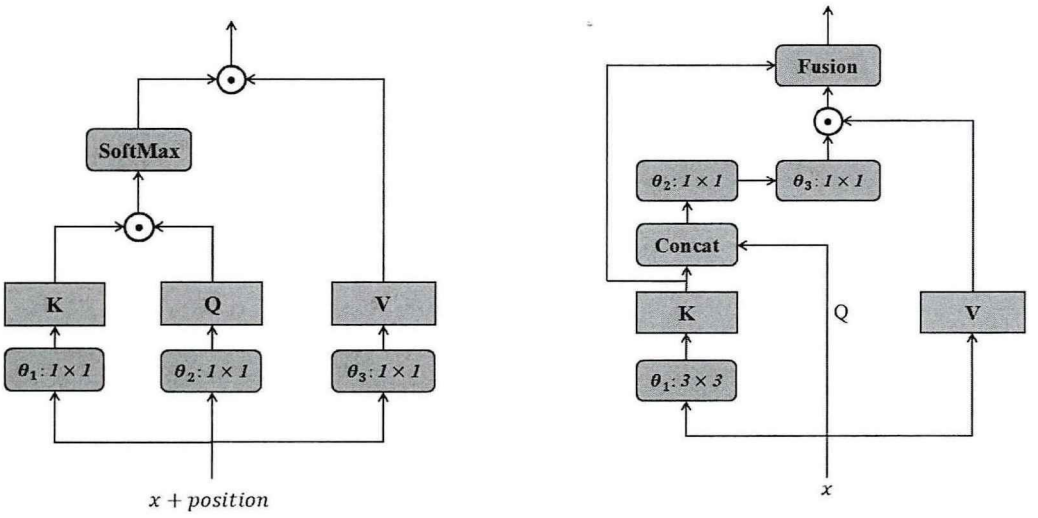
中国知网 https://www.cnki.net

正文 1.2 阐述了羽毛球检测的难题在于视觉特征有限。为应对上述挑战，本文引入了注意力机制以增强模型对目标区域的感知能力。注意力机制能够在复杂背景中自适应地聚焦于目标区域，有效弥补卷积神经网络在捕捉细粒度目标方面的不足，从而更充分地挖掘和利用羽毛球在图像中的有限特征。

3.3 双卷积上下文注意力单元 CoT2f

在基于注意力机制处理序列数据 Transformer[17]结构成为了新的神经网络范式，并且引发了自然语言处理领域新革命的同时，注意力机制凭借其优异的性能逐步活跃到大众眼前。近年来，Transformer 和注意力机制在深度学习领域大放异彩，不仅是自然语言处理这样的一维序列处理领域，增加了对位置信息处理的自注意力机制在图像这样的二维平面上也有着卓越的性能[36]。同时，诸如 SENet[66]、CBAM[67]、ECA-Net[68]等大量工作都将注意力模块融入到了传统的卷积网络中，成功地实现了模型性能的显著提升，促使研究者们对深度神经网络的新方向的探索。

在局部感受野上，卷积层十分适合于捕捉局部特征。但是在全局特征的提取上，卷积层的表现并不佳。卷积层会受到感受野的限制，在纯卷积网络中，要想得到较大的感受野，就需要大量堆叠卷积层，这会不仅会导致计算量暴增，还会出现梯度消失等问题。但是，注意力机制的结构能够天然地打破局部感受野的限制，进而高效地提取全局特征。实践证明，虽然注意力机制会带来一定的计算成本（$O(n^2d)$，其中 n 是输入序列的长度，d 是特征维度），但却能够很好地提高网络捕捉和提取视觉信息的能力[36]。



(a) 传统注意力机制结构　　(b) CoT 结构

图 3-2 传统注意力机制结构与 CoT 结构示意图

中国知网 https://www.cnki.net

传统的注意力机制于一维序列问题中诞生，一维序列其本身的有序性导致传统的注意力机制仅需关注于每个序列元素上成对的键值对的映射关系，而不需要关注序列元素的位置信息。但在二维平面上会造成上下文信息的损失，因而削减网络的学习上限。

Yehao Li 等人注意到了这一点。为了弥补上下文信息的损失，他们设计了一种全新的基于上下文的注意力模块——CoT[64]。图 3-2 分别展示了传统的注意力机制和 CoT 模块的结构。有别于传统的注意机制结构，CoT 结构不再选择基于 1×1 卷积核的线性变化丰富特征空间，而是利用 3×3 卷积生成含有上下文信息的 K，再将 K 作用于注意力矩阵的前后文，达到弥补传统设计导致的上下文信息损失的目的。CoT 巧妙地以一种轻量化的设计将传统结构缺失的上下文信息融入到了注意力矩阵生成过程中。

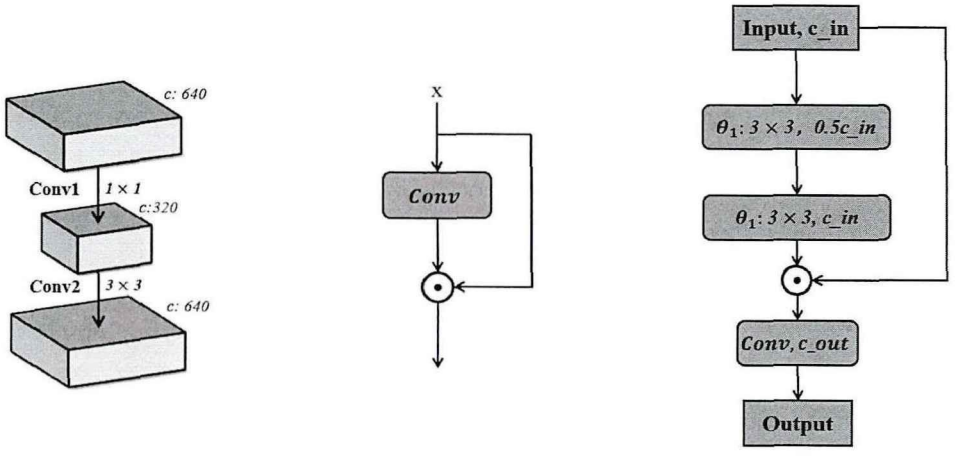
瓶颈结构 Bottleneck[53]和残差结构是 YOLO 系列从 v5 版本就开始采用的优化手段。Bottleneck 整体结构形如一个瓶颈，在通道维度先基于 1×1 卷积高效实现降维操作，然后再基于 3×3 卷积在较小的通道空间内进行升维操作。这样的设计不仅可以避免维度灾难，有效地控制计算量和参数量，还可以在特征空间中引入丰富的非线性变换，抑制过拟合，并且提高模型的泛化能力。Bottleneck 可以被描述为如下公式：

$$y = F(x) = W_3 \cdot \sigma(W_2 \cdot \sigma(W_1 \cdot x)) \tag{3-1}$$

Kaiming He 等人在 ResNet[53]中指出，网络层数的增加会导致梯度消失和退化的现象频出。为了缓解这一现象，ResNet 在设计中引入了含有跳跃连接的残差结构，换句话说，残差结构为网络增加了恒等映射，以优化训练过程中的梯度流动，如公式（3-2）所示。

$$y = F(x) + x \tag{3-2}$$

残差结构的核心是将直接让网络从学习目标函数本身转换成了学习“残差”，在加快模型学习的同时有效提高训练的稳定性。



(a) Bottlenecl 结构　　(b) 残差结构　　(c) YOLO 系列中两者的组合结构

图 3-3 Bottleneck、残差结构以及 YOLO 中组合使用的结构示意图

中国知网 https://www.cnki.net

Bottleneck 和残差结构的具体结构如图 3-3(a)和图 3-3(b)所示，此外，图 3-3(c)展示的是 YOLOv5 和 YOLOv8 中这两种结构的组合使用，YOLO 系列将 Bottleneck 中的 1×1 卷积替换成了一个 3×3 卷积，其目的是保持较大的感受野，维护空间信息。另外，在残差结构之后，往往会跟随一个卷积操作，来限制通道维度扩张。

本文期望设计一个融合了卷积和注意力机制的结构，在控制网络参数量的同时，提高网络的特征学习能力。因此，以这三种各有优劣的结构为基点，本文设计了一个新的混合结构——双卷积上下文自注意力单元 CoT2f，并以此模块重新设计了 YOLO 的骨干网络，如图 3-4 所示，期望减少特征信息的丢失，增强网络捕获全局信息的能力。

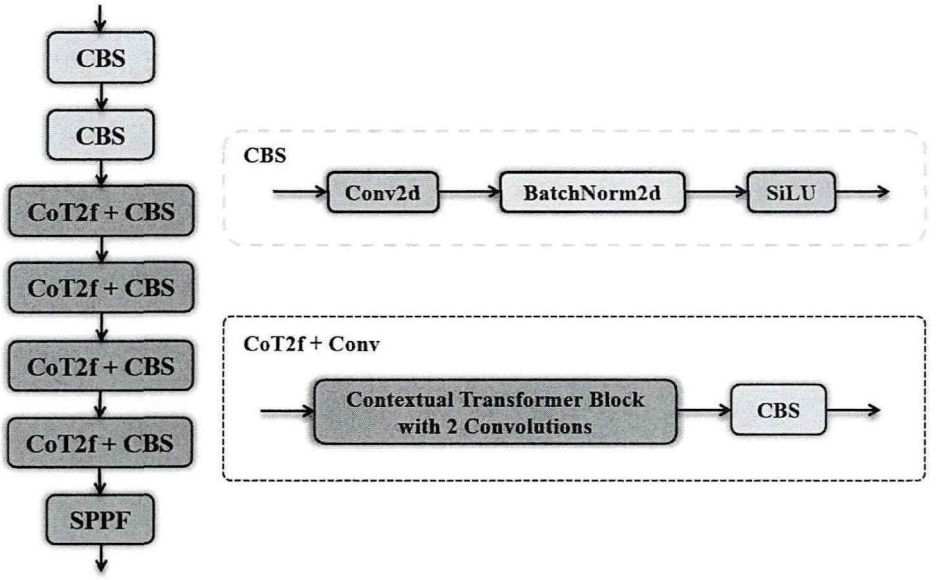


图 3-4 YO-CSA 骨干网络结构

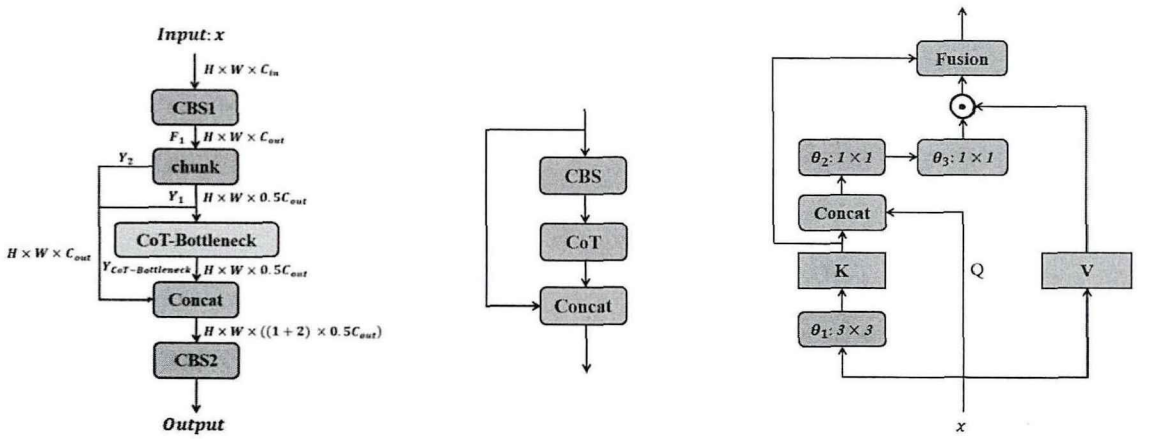
CoT2f 的具体网络结构如图 3-5 所示。CoT2f 主要由两个卷积模块 CBS（每个卷积模块包括了卷积层、批处理操作 BatchNorm[69]和激活函数 SiLU[70]）和一个 CoT-Bottleneck 结构组成。首先，大小为 $H\times W\times C_{in}$ 的输入张量 $\boldsymbol{x}$ 会经先过卷积模块 1，并且转换为一个 $H\times W\times(2c)$ 的输出，记为 F_1，其中，$2c$ 等于卷积模块 1 的输出通道数。然后，输出的 F_1 会被分割成两个切片，记为 $[Y_1,Y_2]$。分别地，Y_1 会作为 CoT-Bottleneck 的输入，进行更细粒度的特征捕捉，得到中间产物 $Y_{CoT-Bottleneck}$。最后，类似于残差结构，中间产物 $Y_{CoT-Bottleneck}$ 会与 F_1 的另一部分 Y_2 进行拼接，送入到卷积模块 2 中进一步融合，最后的卷积模块 2 的任务就是实现不同层提取的特征的融合。

CoT2f 模块的整个流程可以用以下公式（3-3）和公式（3-4）来表示：

$$[Y_1,Y_2]=chunk(Conv(X,W_{conv1})) \tag{3-3}$$

$$F_{output}=Conv(Concat(CoT-Bottleneck(Y_1),Y_2),W_{conv2}) \tag{3-4}$$

中国知网 https://www.cnki.net



(a) CoT2f 结构　　(b) CoT-Bottleneck 结构　　(c) CoT 结构

图 3-5 CoT2f 结构示意图

3.4 基于空间注意力的颈部网络 SANeck

在深度神经网络的范畴内，一个目标物体实质上是由一系列子特征组成的，换句话说，如果可以准确地感知和提取这些子特征，就可以顺利地检测出目标物体。如正文 3.3 所描述，为了强化模型提取特征的能力，骨干网络基于 CoT2f 进行了优化设计。但除了骨干网络之外，颈部网络也与特征提取息息相关，因为它负责了多尺度的特征融合和增强的任务。那么，在经过了骨干网络多级的特征提取后，还需要在颈部网络部分，即基于特征金字塔网络（Feature Pyramid Networks，FPN）[71]和路径聚合网络（Path Aggregation Network，PAN）[72]的双金字塔的特征融合的流程中，增强对子特征的感知与提取。

因此，本文基于双卷积空间注意力增强模块（SGE with 2 Convolutions，SGE-2f）结构设计了基于空间注意力的颈部网络 SANeck。更具体地说，SANeck 在每一轮不同尺度特征图的拼接后，都接入一个 SGE-2f 模块，实现更深维度空间的特征增强。如图 3-6 所示。实验证明融合了 SGE-2f 模块（C2f-SGE 内部）的 SANeck 可以增强模型的提取语义特征的能力。

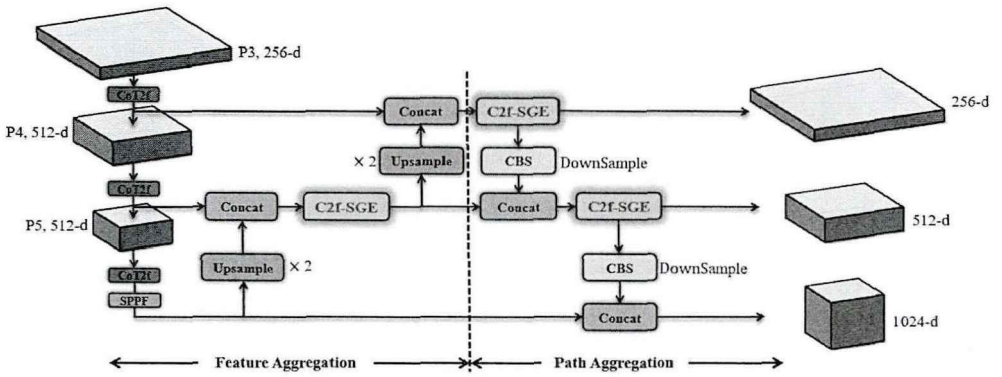


图 3-6 SANeck 结构示意图

中国知网 https://www.cnki.net

直接引入传统的注意力机制会为网络带来较大的计算负担。由于本文的主要目标是实时且精确地在二维图像上检测羽毛球，即便有网络轻量化的手段，本文也不希望在网络初始的设计时就给网络增加较大的参数量。因此，受空间分组增强模块 SGE 的启发，本文设计的 SGE-2f 模块选择以一种轻量化的方式引入了注意力机制。SGE 是一个参考了 CapsNet[73]的轻量化自注意力机制设计，具体结构可见图 3-7。

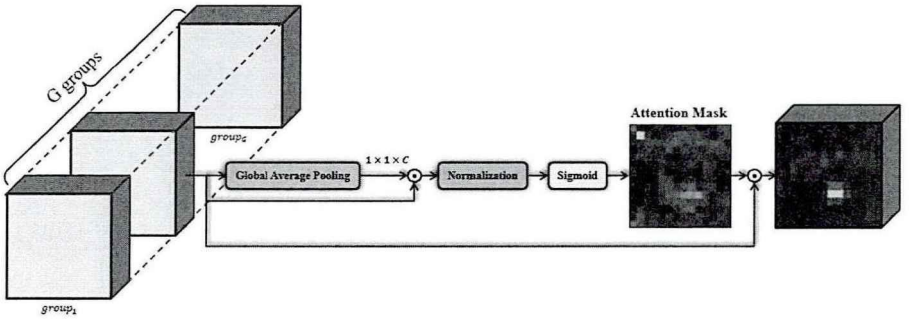


图 3-7 SGE 结构示意图

与传统的注意力机制不同的是，SGE 结构在通道维度对特征图进行了分组处理，它并行地执行每个组对应的子特征的提取，同时，SGE 基于全局平均池化操作 $\mathcal{F}_{gp}(\cdot)$ 获取全局空间特征 $\boldsymbol{g}$：

$$\boldsymbol{g} = \mathcal{F}_{gp}(\boldsymbol{X}) = \frac{1}{m}\sum_{i=1}^{m} x_i \tag{3-5}$$

再将全局空间特征 $\boldsymbol{g}$ 与原始特征图进行相乘，计算局部空间特征和全局空间特征的相似性，见公式（3-6），以此来引导模块对特征进行增强，从而使模型以语义特征组为单位，更高效地学习语义特征的空间分布情况。

$$\boldsymbol{C} = \boldsymbol{g} \cdot \boldsymbol{X} \tag{3-6}$$

在对 $\boldsymbol{C}$ 进行标准化和归一化操作后，对于每一个语义特征组，SGE 都会生成一个初始注意力掩图（Attention Mask），再根据注意力掩图，在原特征图上寻找其对应的语义特征。在此过程中，SGE 额外引入了两个学习参数 w 和 b，帮助网络适应性缩放和偏移。

C2f（CSP Bottleneck with 2 Convolutions），是在 YOLOv8 中被提出的结构，它巧妙地以分割操作间接地取代了一个卷积计算，有效地减少了网络的参数量，这与本文的目标相符，因此，SGE-2f 在设计时也吸取了经验。但与 C2f 模块不同的是，SGE-2f 淘汰了 C2f 模块中的 Bottleneck 操作，而增加了 SGE-2f 结构，通过在空间上融入注意力机制丰富特征空间，为特征的融合和增强引入更多的非线性变化，提高网络学习能力。

SGE-2f 结构同 SGE 以及 CapsNet[73]一样，巧妙利用了“组”的概念。传统卷积操作对所有通道维度的计算和处理是相同的，因此，单一的背景噪声处理会影响这些子特征的识别和定位结果。如果将这些子特征进行分组，也就是说，一个“组”负责一个子特征的提取（或者说，一个特征语义的提取），就可以让每个语义特征组去针对性地学

中国知网 https://www.cnki.net

习和抑制背景噪声，达到更好的特征提取效果。同时，在每个特征语义组内，还可以利用局部空间特征和全局空间特征的相似性使网络针对性学习不同语义特征的空间分布。

值得一提的是，实验发现，得益于轻量化的结构设计，在 small 规模下，与 YOLOv8s 中的 C2f 模块相比，SGE-2f 模块仅增加了 0.002%的参数量，也就是说，SGE-2f 模块可以在几乎不增加网络参数量和计算负担的前提下，为网络的学习能力带来增益。

图 3-8 展示了 SGE-2f 模块的具体结构。首先，上一层的输出会作为第一个卷积层的输入，也就是 SGE-2f 模块的输入。然后，SGE-2f 会将第一个卷积层的输出分割成两个切片，记为 Y_1 和 Y_2，两者形状相同，如公式（3-8）：

$$[Y_1, Y_2] = chunk(Conv(X, W_{conv1})) \tag{3-7}$$

其中，Y_1会作为 n 层 SGE-2f 的输入，每一个 SGE-2f 都是一个类瓶颈结构，旨在控制参数量，避免维度灾难的同时，丰富特征空间，使得 Y_1 可以进行更深地特征增强。而切片 Y_2 与 Y_1 不同，它会被直接送入到 Concat 拼接层，与 n 层 SGE-2f 的 n 个子输出进行拼接操作，最后，拼接得到的中间产物会在第二个卷积层中进行最后的融合处理，得到整个模块的输出。整个流程可以用公式（3-8）来表示：

$$F_{output} = Conv(Concat(n \times SGE - 2f(Y_1), Y_2), W_{conv2}) \tag{3-8}$$

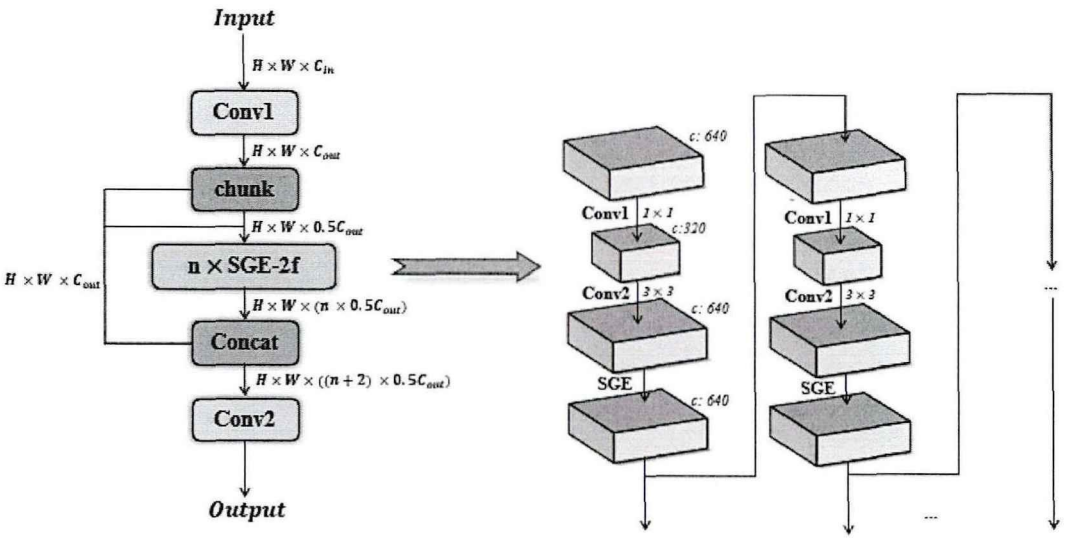


图 3-8 SGE-2f 结构示意图

3.5 空间注意力解耦头

在目标检测的经典范式中，如果说骨干网络的职责是提取特征，生成不同感受野和尺度的特征图，颈部网络的职责是基于多尺度的特征图实现特征融合和特征增强，那么下游层的目标就是处理提取融合后的特征图，并根据不同的目的执行不同的任务，包括

中国知网 https://www.cnki.net

目标分类、边界框回归等[74]。YOLO 的下游层，也就是检测头部分，是比较简单直接的，它并没有为分类和回归任务做特别的处理，仅仅堆叠了两个卷积操作让网络直接学习拟合不同的任务。注意到边界框回归对于目标物体位置信息的强依赖性，本文认为可以在网络的下游补充对特征空间分布的学习，促使网络快速地进行目标分类和边界框回归。

在检测头部，本文设计了一个结合了空间分组增强结构 SGE 的空间注意力解耦头来提高网络学习特征空间分布的能力，更好地完成分类和边界框回归任务。与传统的检测头部设计不同，空间注意力解耦头部不再在分类任务和回归任务之间共享参数，而是基于两个任务独有的并行分支，将两个任务独立处理，这样的优化可以促使网络针对性地学习不同任务的空间分布。而正如在正文 3.4 节中提到的，SGE 结构通过在特征提取的过程中强调了“组”的概念，利用了“组”内的局部空间的特征和全局空间的特征的相似性，帮助网络更有效地学习到了语义特征的空间分配，因此，类似地，融合了 SGE 的解耦检测头会比传统检测头部有着更强的性能。

如图 3-9，在空间注意力解耦头中，多层不同尺度的特征图会先被输入到 SGE 这个轻量化的空间注意力结构中，强化网络对空间分布的感知，达到特征增强和自适应的缩放操作效果。在经过 SGE 层后，单分支会拆解成两个并行分支分别执行分类和边界框回归任务，其中，每个分支的结构与原始检测头保持一致，都包含了两个 3×3 卷积层。

分类任务的输出形状为 $[H, W, nc]$，其中 nc 表示分类任务的目标类别数量，在本文的工作中，仅需要检测“羽毛球”一个类别，因此 $nc = 1$。边界框回归任务的输出形状为 $[H, W, 64]$，其中，每个边界框需要有 4 个参数来唯一确定，即 $[x, y, h, w]$，分别为边界框的中点坐标 x、y 以及边界框的高 h 和宽 w，而由于回归任务在损失函数计算部分应用了分布焦点损失（Distribution Focal Loss，DFL）[75]模块来优化回归过程，DFL 会将边界框拆解为 16 个通道，细粒度地学习分布信息，因此在边界框回归任务中，输出的第三维大小为 $4 \times 16 = 64$。

与初始的检测头部相比，空间注意力解耦头只在 SGE 结构中影响了网络整体的参数量，但由于 SGE 本身就是一个轻量化的结构，其主要的计算操作包括了多组的全局平均池化以及局部特征与全局特征之间的相似性计算，因此优化后的检测头增加的参数量，几乎可以忽略不计。

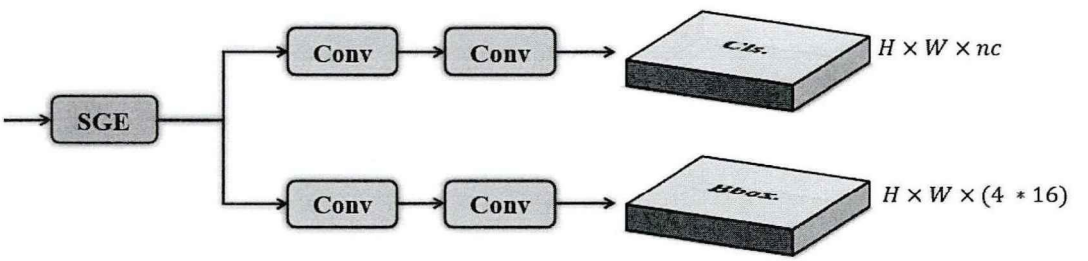


图 3-9 空间注意力解耦头结构示意图

中国知网 https://www.cnki.net

3.6 本章小结

本章首先阐述了二维目标检测网络 YO-CSA 的整体网络结构，然后主要描述了 YO-CSA 的三大优化模块的设计细节，包括基于双卷积上下文注意力单元 CoT2f、融合了空间注意力的颈部网络 SANeck 以及空间注意力解耦头。

中国知网 https://www.cnki.net

第4章 YO-CSA-T：基于 YO-CSA 和时空约束的羽毛球三维轨迹实时提取系统

4.1 系统流程阐述

本文旨在开发一个集实时与准确性于一体的三维羽毛球跟踪系统 YO-CSA-T。YO-CSA-T 主要分为二维检测模块、立体视觉模块以及轨迹补偿模块，YO-CSA-T 通过结合检测、预测、补偿三大子任务，实现对羽毛球三维轨迹的准确提取。其中：

（1）二维检测模块：以 YO-CSA 网络为核心，旨在识别和定位图像序列中的羽毛球，得到二维轨迹。YO-CSA 网络充分利用空间注意力以及上下文注意力机制，在 YOLOv8s 架构的基础上，分别优化和重构了骨干网络、颈部网络以及检测头部，有效缓解了羽毛球体积小、视觉特征有限导致的易漏检误检的现象。

（2）立体视觉模块：根据自搭建的立体视觉平台建模场景的三维结构，将左右视角中成对的羽毛球二维坐标 $[\widehat{\boldsymbol{P}}_L^{(i)}, \widehat{\boldsymbol{P}}_R^{(i)}]$ 映射到三维空间中，计算得到三维空间坐标 $\boldsymbol{P}_w^{(i)}$。鉴于二维检测模块在某些图像帧中会出现误检或漏检的情况，本文利用了三维空间的历史轨迹信息预测未来轨迹，通过将轨迹未来时刻的三维坐标重投影到左右成像平面中，为检测模块动态更新空间约束，减轻检测任务的压力。

（3）轨迹补偿模块：基于编码器-解码器结构设计补偿网络，对二维轨迹数据 $\widehat{\boldsymbol{P}}_L$ 和 $\widehat{\boldsymbol{P}}_R$ 进行进一步的修正。受序列插值的启发，该模块的核心工作是弥补上游图像处理中漏检或误检导致的轨迹缺失，提高轨迹的一致性和完整性。

系统 YO-CSA-T 的工作可分为 6 大步骤，图 4-1 可视化展示了完整的工作流程，其中图 4-1(a)展示了步骤（1）-（5）的整体流程，图 4-1(b)展示了步骤（6），即轨迹补偿模块的整体处理流程。系统工作 6 大步骤包括：

（1）将左右视角的图像序列 $\boldsymbol{I}_L$、$\boldsymbol{I}_R$ 分“组”，同步、顺序地送入二维检测模块；

（2）二维检测模块首先基于 YO-CSA 网络检测得到二维轨迹序列 $\boldsymbol{P}_L$ 和 $\boldsymbol{P}_R$，然后根据对称性约束筛除不合理的坐标节点对，最终输出 $\widehat{\boldsymbol{P}}_L$ 和 $\widehat{\boldsymbol{P}}_R$；

（3）将符合一致性的二维轨迹序列 $\widehat{\boldsymbol{P}}_L$ 和 $\widehat{\boldsymbol{P}}_R$ 送入到立体视觉模块，根据场景的三维结构信息将二维轨迹映射到三维空间，并基于合理性约束重建羽毛球在三维空间的运动轨迹 $\boldsymbol{P}_w$；

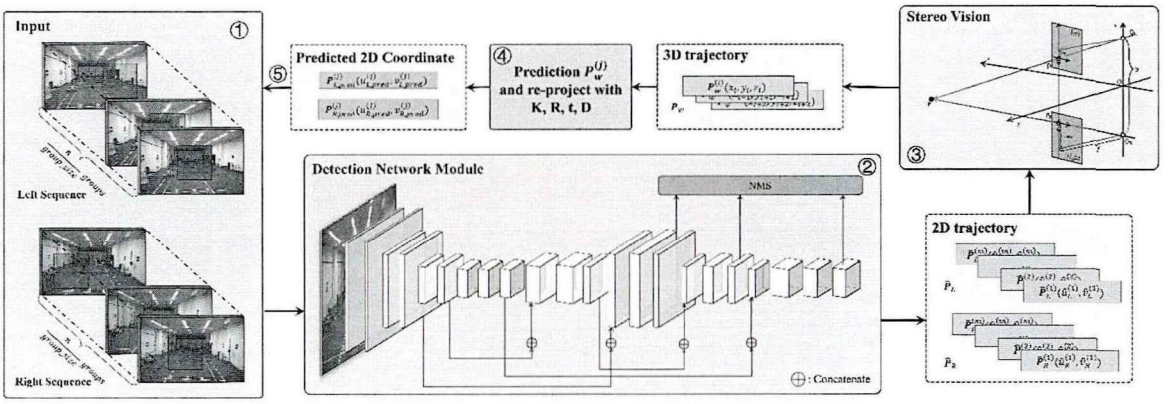
（4）基于羽毛球飞行的时空演化约束以及历史三维轨迹预测羽毛球在未来时刻 j 的坐标 $\widehat{\boldsymbol{P}}_w^{(j)}$，并重投影到左右视角的成像平面中，得到先验估计 $\boldsymbol{P}_{L,pred}^{(j)}$ 和 $\boldsymbol{P}_{R,pred}^{(j)}$；

（5）根据先验估计 $\boldsymbol{P}_{L,pred}^{(j)}$ 和 $\boldsymbol{P}_{R,pred}^{(j)}$ 动态更新下一“组”图像上的 ROI，结合羽毛球在三维空间的运动特征更新检测模块空间约束，减轻检测模块计算压力；

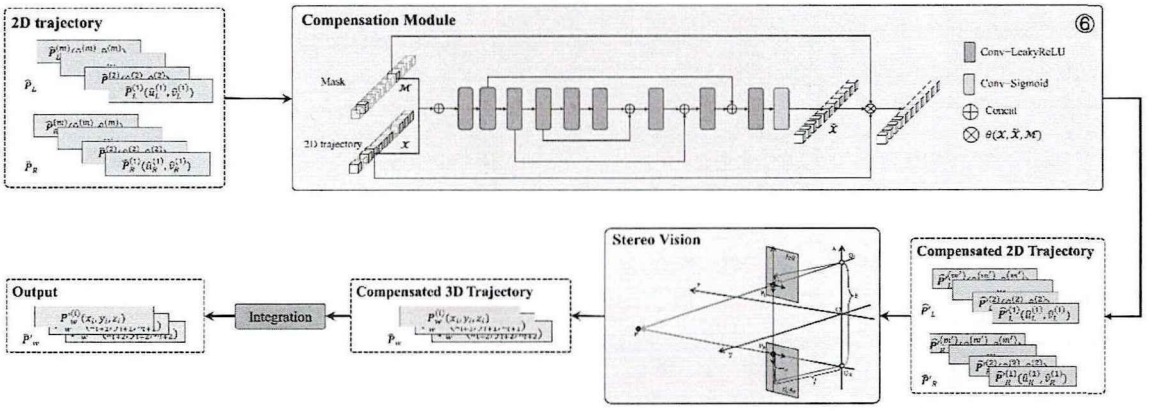
中国知网 https://www.cnki.net

（6）基于补偿网络补偿二维轨迹 $\widehat{\boldsymbol{P}}_L$ 和 $\widehat{\boldsymbol{P}}_R$ 中的缺失帧，得到左右视角的完整轨迹 $\widehat{\boldsymbol{P}}'_L$ 和 $\widehat{\boldsymbol{P}}'_R$，并重新送入到立体视觉模块，得到 $\widehat{\boldsymbol{P}}_w$，同时对步骤（3）中得到的三维轨迹 $\boldsymbol{P}_w$ 进行样条插值得到 $\widetilde{\boldsymbol{P}}_w$，最后结合 $\widehat{\boldsymbol{P}}_w$ 和 $\widetilde{\boldsymbol{P}}_w$，得到最终的三维轨迹 $\widehat{\boldsymbol{P}}'_w$。

为了缓解误差累积对系统提取轨迹能力的干扰，避免系统工作崩溃，本文基于羽毛球飞行轨迹的时空演化规则，在步骤（2）、（3）、（4）、（6）中分别引入了多重约束策略，以提高系统在复杂飞行场景中的鲁棒性以及提取轨迹的一致性。



(a) 工作步骤（1）-（5）



(b) 补偿流程（步骤（6））

图 4-1 系统工作流程图

4.2 立体视觉平台搭建

4.2.1 搭建和相机选型

羽毛球体积小而重量轻，在职业羽毛球比赛中，其飞行速度甚至可以达到 300km/h。对于高速飞行的羽毛球运动，高帧率的图像采集和目标检测可以有效地提高轨迹提取的可靠性。本文关注到了发球时羽毛球飞行轨迹的特殊性，其轨迹往往呈先自然下落（击球前）后抛物线上升再下降（击球后）的趋势，因此，低帧率的图像采集导致的中间连

中国知网 https://www.cnki.net

续帧的缺失，会对发球时的轨迹提取有较大干扰性。鉴于这两点考虑，本文在搭建立体视觉平台时，在相机的选择上着重考量了帧速率这一因素。

本文最初调研了市场上常用的双目相机和深度相机款式，见表 4-1。由于羽毛球标准场地长 13.40 米，通过比较相机支持的深度发现，满足要求的相机，如 ZED，价格普遍较高。另外，满足深度要求的双目相机的帧速率普遍在 30-60fps，成像帧率较低。因此，本文最终选择以两个单目相机搭建双目相机平台。

表 4-1 市场上常用的双目相机和深度相机款式及相关参数

双目相机型号	分辨率	帧速率(fps)	深度(m)	价格(人民币)
ZED	2560x720	60	0.1-15	4620
ZED2i	2560x720	60	0.2-20	6202
D405	1280x720	90	0.07-0.5	2000
D435	1280x720	90	0.3-3	2349

注：价格来源京东购物官网。

本文同样调研了工程上常用的单目工业相机，见表 4-2。在对分辨率、帧速率以及金钱成本（京东网站查询）等多方面比较后，本文最终采用型号为 A7200CU130 的大华工业相机（表中加粗表示）来搭建双目相机平台。

表 4-2 工程上常用的单目工业相机款式及相关参数

单目相机型号	分辨率	帧速率(fps)	黑白/彩色	价格(人民币)
大华 A3A20MU24	4000×3000	30	黑白	1730
大华 A3A20CU24	4000×3000	30	黑白	1875
大华 A7200CU130	**1920×1200**	**164**	**彩色**	**2168**
大华 A7160CU000	720×540	437	彩色	1265
海康 MV-CS028-10UM	1936×1464	121.1	黑白	3315
海康 MV-CU013-A0UC	1280×1024	201.4	彩色	1700

注：价格来源京东购物官网。加粗表示本文最终采用的型号。

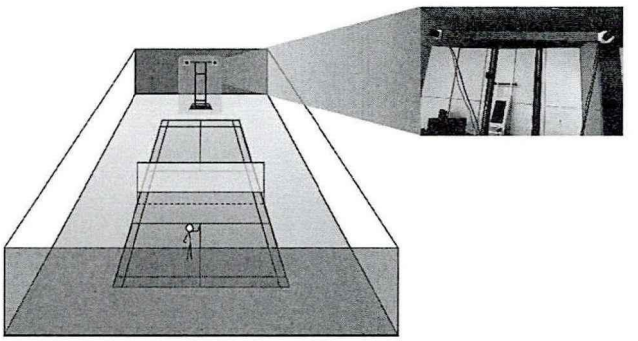
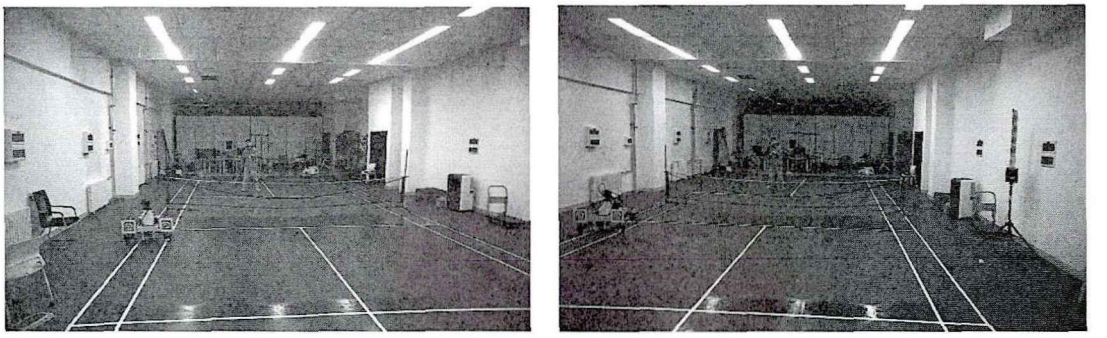


图 4-2 双目相机平台在实验中的搭建

中国知网 https://www.cnki.net

双目相机平台在实验中的搭建如图 4-2 所示。双目相机及其支撑架被摆放在了机器人场地后方，左右相机可以清晰地捕捉对手击球后羽毛球的来球轨迹。在双目相机系统中，左右相机的基线被设置为了 0.8m，高度设置为 1.8m，约为一个成年男子的身高，模拟人眼可以捕捉到的视野范围。图 4-3 是左右相机的视野范围的示意图。



(a) 左相机视野　　(b) 右相机视野

图 4-3 左右相机的视野范围的示意图

由于相机镜头上透镜的存在，光线在投影到成像平面的过程中会产生透视失真，导致图像发生畸变。因此，在利用该平台实现二维坐标到三维空间的映射前，还需要对两个单目相机做标定处理，获取相机准确的内部参数和畸变系数，以及左右单目相机之间的相对位姿，即外部参数。

4.2.2 相机标定

在正文 2.3 中提到，正如公式（3-8）所描述的，立体视觉系统的本质是世界坐标系、相机坐标系、图像坐标系以及像素坐标系四大坐标系之间的转换。因此，立体视觉平台建模的关键就是计算相机的内参矩阵 $\boldsymbol{K}$ 和外参矩阵 $\boldsymbol{T}$，以及畸变系数 $\boldsymbol{D}$ 来抵消透镜导致的透视失真。

$$Z_c\begin{bmatrix}u\\v\\1\end{bmatrix}=\begin{bmatrix}f_x & 0 & u_0 & 0\\0 & f_y & v_0 & 0\\0 & 0 & 1 & 0\end{bmatrix}\begin{bmatrix}\boldsymbol{R} & \boldsymbol{t}\\\vec{0} & 1\end{bmatrix}\begin{bmatrix}X_w\\Y_w\\Z_w\\1\end{bmatrix}=\boldsymbol{KTP}_w \tag{4-1}$$

本文采用张正友标定法[58]，基于棋盘格标定板进行标定，标定板如图 4-4 所示，共拍摄了 12 张不同角度和深度下的标定板图像，从图像中提取标定板的角点特征用于计算相机的内外参数和畸变系数。

中国知网 https://www.cnki.net

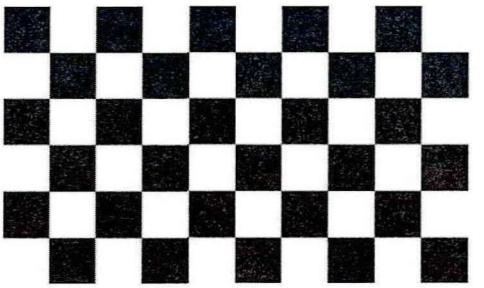


图 4-4 棋盘格标定板

（1）内参矩阵

公式（3-8）也可以表示将棋盘格所在的物理平面映射到相机的成像平面的过程，该过程满足平面间的单应性，基于平面之间的单应性特性，假设棋盘格所在平面 $Z_w = 0$，则可以将公式（3-8）转换为如下形式：

$$s\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \boldsymbol{H}\begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix} \tag{4-2}$$

$$\boldsymbol{H} = [h_1 \quad h_2 \quad h_3] = \lambda \boldsymbol{K}\boldsymbol{T} = \lambda \boldsymbol{K}[\boldsymbol{R}|\boldsymbol{t}] = \lambda \boldsymbol{K}[r_1 \quad r_2 \quad t] \tag{4-3}$$

其中，s 为尺度因子，易得 $\lambda = 1/s$。那么，只要求解得到单应矩阵 $\boldsymbol{H}$，内参矩阵 $\boldsymbol{K}$ 就可以通过分解 $\boldsymbol{H}$ 来求解。注意到旋转矩阵 $\boldsymbol{R}$ 是正交矩阵，其列向量和行向量标准正交，根据该特性约束可得到公式（4-4）和公式（3-8）：

$$h_1^T \boldsymbol{K}^{-T}\boldsymbol{K}^{-1}h_2 = 0 \tag{4-4}$$

$$h_1^T \boldsymbol{K}^{-T}\boldsymbol{K}^{-1}h_1 = h_2^T \boldsymbol{K}^{-T}\boldsymbol{K}^{-1}h_2 = 1 \tag{4-5}$$

其中：

$$\boldsymbol{K} = \begin{bmatrix} \frac{f}{dx} & -\frac{f\cot\theta}{dx} & u_0 & 0 \\ 0 & \frac{f}{dy\sin\theta} & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} \alpha & \gamma & u_0 \\ 0 & \beta & v_0 \\ 0 & 0 & 1 \end{bmatrix} \tag{4-6}$$

为简化公式，令 $\boldsymbol{B} = \boldsymbol{K}^{-T}\boldsymbol{K}^{-1}$，则：

$$\begin{aligned} \boldsymbol{B} &= \boldsymbol{K}^{-T}\boldsymbol{K}^{-1} \\ &= \begin{bmatrix} \frac{1}{\alpha^2} & -\frac{\gamma}{\alpha^2\beta} & \frac{\gamma v_0 - \beta u_0}{\alpha^2\beta} \\ -\frac{\gamma}{\alpha^2\beta} & \frac{1}{\beta^2} + \frac{\gamma^2}{\alpha^2\beta^2} & \frac{\gamma(\beta u_0 - \gamma v_0)}{\alpha^2\beta^2} - \frac{v_0}{\beta^2} \\ \frac{\gamma v_0 - \beta u_0}{\alpha^2\beta} & \frac{\gamma(\beta u_0 - \gamma v_0)}{\alpha^2\beta^2} - \frac{v_0}{\beta^2} & \frac{(\beta u_0 - \gamma v_0)^2}{\alpha^2\beta^2} + \frac{{v_0}^2}{\beta^2} + 1 \end{bmatrix} \end{aligned} \tag{4-7}$$

将 $\boldsymbol{B}$ 代入到旋转矩阵的约束公式（4-5）中，可以得到以下简化的关系式：

中国知网 https://www.cnki.net

$$h_i^T \boldsymbol{B} h_j = v_{ij} b \tag{4-8}$$

$$v_{ij} = \begin{bmatrix} H_{1i}H_{1j} \\ H_{1i}H_{2j} - H_{2i}H_{1j} \\ H_{2i}H_{2j} \\ H_{1i}H_{3j} + H_{3i}H_{1j} \\ H_{2i}H_{3j} + H_{3i}H_{2j} \\ H_{3i}H_{3j} \end{bmatrix}^T \tag{4-9}$$

$$b = [B_{11} \quad B_{12} \quad B_{22} \quad B_{13} \quad B_{23} \quad B_{33}]^T \tag{4-10}$$

根据正交矩阵特性，可以将公式（4-4）转换为 Ax=b 的形式：

$$\begin{bmatrix} v_{12}^T \\ v_{11} - v_{22} \end{bmatrix} b = 0 \tag{4-11}$$

那么，理论上，只要在同一场景下获取大于三张棋盘格图像，就可以利用奇异值分解公式(3-8)求得其最小二乘解，从而求得矩阵 $\boldsymbol{B}$，最后得到相机的内外参数。公式(3-8)表示了内参矩阵 $\boldsymbol{K}$ 中各个参数的表达式。但在实践中，为了在后续操作中提高参数值的可信度，一般会选择 10 张以上的棋盘格图像进行处理。

$$\begin{cases} c_x = \dfrac{\gamma c_y}{\beta} - B_{13}\alpha^2/\lambda \\ c_y = (B_{12}B_{13} - B_{11}B_{23})/(B_{11}B_{22} - B_{12}^2) \\ \alpha = \sqrt{\lambda/B_{11}} \\ \beta = \sqrt{\lambda B_{11}(B_{11}B_{22} - B_{12}^2)} \\ \gamma = -B_{12}\alpha^2\beta/\lambda \\ \lambda = B_{22} - [B_{13}^2 + c_y(B_{12}B_{13} - B_{11}B_{23})]/B_{11} \end{cases} \tag{4-12}$$

因为最小二乘法得到的解只是粗略估计值，所以，为了提高参数的置信度，需要利用极大似然估计[76]优化结果。构造似然函数 $\mathcal{L}$，如公式（4-13），利用最小二乘法得到的估计值作为初始值，迭代使得 $\mathcal{L}$ 取得最大值，即可得到最优解。

$$\mathcal{L}(\boldsymbol{K}, \boldsymbol{R}_i, \boldsymbol{t}_i, \boldsymbol{M}_{ij}) = \prod_{i=1,j=1}^{n,m} f(m_{ij}) = \frac{1}{\sqrt{2\pi}} e^{\frac{-\sum_{i=1}^{n}\sum_{j=1}^{m}(\hat{m}(\boldsymbol{K},\boldsymbol{R}_i,\boldsymbol{t}_i,\boldsymbol{M}_{ij}) - m_{ij})^2}{\sigma^2}} \tag{4-13}$$

$$\hat{m}(\boldsymbol{K}, \boldsymbol{R}_i, \boldsymbol{t}_i, \boldsymbol{M}_{ij}) = \boldsymbol{K}[\boldsymbol{R}\ \boldsymbol{t}]\boldsymbol{M}_{ij} \tag{4-14}$$

其中，n 表示 n 张包含了棋盘格的图像，m 表示每张包含了棋盘格的图像上的作为特征的像素点，$\boldsymbol{M}_{ij}$ 表示第 i 张图像第 j 个像点对应的三维坐标，$\hat{m}(\boldsymbol{K}, \boldsymbol{R}_i, \boldsymbol{t}_i, \boldsymbol{M}_{ij})$ 表示 $\boldsymbol{M}_{ij}$ 对应的像素坐标，$\boldsymbol{R}_i$ 和 $\boldsymbol{t}_i$ 表示第 i 幅图像对应的相机的旋转矩阵和平移向量，$\boldsymbol{K}$ 表示相机的内参矩阵。

（2）畸变系数

中国知网 https://www.cnki.net

畸变分为径向畸变和切向畸变。由于切向畸变一般是相机组装时透镜和成像平面不严格平行导致的，属于系统误差，因此本文不考虑切向畸变，只关注径向畸变。设归一化后的理想无畸变的像素坐标为 (x, y)，归一化的现实畸变后的像素坐标为 $(\hat{x}, \hat{y})$，则左右相机各自的径向畸变可以用公式（3-8）表示：

$$\begin{cases}\hat{x} = x + x[k_1(x^2+y^2) + k_2(x^2+y^2)^2] \\ \hat{y} = y + y[k_1(x^2+y^2) + k_2(x^2+y^2)^2]\end{cases} \tag{4-15}$$

其中，畸变系数 $\boldsymbol{D} = [k_1, k_2]$。径向畸变不会影响相机的光学中心，也就是成像平面的主点坐标 (u_0, v_0)，因此，设归一化的像素坐标 (x, y) 和 $(\hat{x}, \hat{y})$ 对应的真实像素坐标为 (u, v) 和 $(\hat{u}, \hat{v})$，根据归一化原理存在以下约束：

$$\begin{cases}\hat{u} = u_0 + \alpha\hat{x} \\ \hat{v} = v_0 + \beta\hat{y}\end{cases} \tag{4-16}$$

其中，α 和 β 分别表示水平方向和垂直方向的焦距。那么，联合公式（4-15）和公式（3-8），就可以变换得到形如 $\boldsymbol{Ax} = b$ 矩阵形式的等式：

$$\begin{bmatrix}(u-u_0)(x^2+y^2) & (u-u_0)(x^2+y^2)^2 \\ (v-v_0)(x^2+y^2) & (v-v_0)(x^2+y^2)^2\end{bmatrix}\begin{bmatrix}k_1 \\ k_2\end{bmatrix} = \begin{bmatrix}\hat{u}-u \\ \hat{v}-v\end{bmatrix} \tag{4-17}$$

与单应性矩阵 $\boldsymbol{H}$ 的计算方式类似，可先利用最小二乘法得到估计值，再基于最大似然估计，建立似然函数 $\mathcal{L}$，见公式（3-8），迭代得到畸变参数 k_1 和 k_2 的最优解。

$$\begin{aligned}&\mathcal{L}(\boldsymbol{K}, k_1, k_2, \boldsymbol{R}_i, \boldsymbol{t}_i, \boldsymbol{M}_{ij}) \\ &= \prod_{i=1,j=1}^{n,m} f(m_{ij}) \\ &= \frac{1}{\sqrt{2\pi}} e^{\frac{-\sum_{i=1}^{n}\sum_{j=1}^{m}(\hat{m}(\boldsymbol{K}, k_1, k_2, \boldsymbol{R}_i, \boldsymbol{t}_i, \boldsymbol{M}_{ij}) - m_{ij})^2}{\sigma^2}}\end{aligned} \tag{4-18}$$

（3）外参矩阵

类似地，在已知内参矩阵 $\boldsymbol{K}$ 的前提下，分解单应矩阵 $\boldsymbol{H}$ 可以求解得到左右相机各自的外参矩阵，而双目相机平台的外参矩阵 $\boldsymbol{T}$，即左右相机的相对位姿，可以通过两个相机的外参矩阵进行构建。对于左右相机，有以下约束成立：

$$\begin{cases}\boldsymbol{P}_l = \boldsymbol{R}_l \cdot \boldsymbol{P}_w + \boldsymbol{t}_l \\ \boldsymbol{P}_r = \boldsymbol{R}_r \cdot \boldsymbol{P}_w + \boldsymbol{t}_r\end{cases} \tag{4-19}$$

经过线性变换可得：

$$\begin{cases}\boldsymbol{R} = \boldsymbol{R}_r \boldsymbol{R}_l^T \\ \boldsymbol{t} = \boldsymbol{t}_r - \boldsymbol{R} \cdot \boldsymbol{t}_l\end{cases} \tag{4-20}$$

中国知网 https://www.cnki.net

4.3 YO-CSA 二维检测模块

为了解决羽毛球检测中由于特征有限而产生的容易误检、漏检的难题，本文提出了检测网络 YO-CSA，基于 YOLOv8s 框架，优化和重构了骨干网络、颈部网络和检测头部三大部分，以优化网络性能，并且提高了网络在羽毛球实时检测任务上的适配性，强化了模型在复杂环境下的检测性能。进一步地，针对人机对打场景中机器人硬件算力受限的情况，本文在原始图像上框选了 ROI，缩小了检测网络的检测范围，间接缓解复杂背景对检测任务的干扰，并以“组”的形式拆分左右对称的图像序列，输入到网络中进行批处理检测。为了满足机器人对打对实时性的要求，本文引入了硬件加速库 ONNX Runtime 加速网络的推理阶段。

YO-CSA 是一个结合了局部卷积特征提取和全局注意力特征增强的网络。具体地说，本文通过①在骨干网络引入了双卷积上下文注意力单元 CoT2f，赋予模型在不同尺度上动态关注的能力，②在颈部网络引入了基于空间注意力的特征增强模块 SGE-2f，强化全局的特征关联性，③通过空间注意力模块 SGE 捕捉全局上下文信息，优化解耦检测头部，三大手段（具体结构见正文第 3 章详细描述），构建了能够卷积提取局部特征、注意力提取全局特征的二维检测网络 YO-CSA。实验结果表明，YO-CSA 的检测性能显著超越了 YOLOv8s 以及 YOLO11s。

双目相机平台获取的原始图像帧的分辨率是 1920x1200，羽毛球在原始图像中所占像素点比例小于 0.5‰，可提取的视觉特征十分有限，因此检测难度较高。为了解决这一难题，本文在原始图像上框选了 640x640 的 ROI 区域，相比于原始图像，羽毛球在 ROI 中占比可达 0.2%-1%左右。引入 ROI 一方面可以减小网络的计算负担，一方面可以帮助网络提取羽毛球的视觉特征。由于羽毛球在运动过程中可能会离开初始 ROI 的框选范围，因此，为了保证羽毛球在 ROI 范围内，需要在羽毛球运动期间，同步更新 ROI。

在真实对打中，左右视角的图像序列是同步且连续获取的，其顺序天然携带了丰富的时序信息。然而，将图像序列逐帧、串行地输入到检测网络中进行检测会极大地浪费网络强大的批处理能力，限制检测的推理速度。为了充分利用网络的计算资源，避免逐帧处理导致的速度瓶颈，需要引入合理的并行处理优化策略。本文在图像序列获取时，设置了缓存机制，并引入了“组”的概念，如图 4-1(a)所示。当且仅当获取图像大于等于一“组”的图像数量（实验中设置为 5 帧）时，才会以一“组”的形式，输入到网络中进行批处理检测。相比于逐帧输入，“组”输入的策略模式可以显著加速推理速度。

在羽毛球机器人与真人的实际对打中，机器人只能携带有限算力的移动设备，但是机器人又对轨迹提取的实时性有着极高的要求。针对这一挑战，本文基于硬件加速库 ONNX Runtime 对 YO-CSA 网络进行了加速处理。ONNX Runtime 可以基于图优化合并网络的冗余操作，减少计算量。同时，ONNX Runtime 支持降低模型浮点数运算的精度，在不显著影响模型性能的前提下，减少模型的内存占用，加速模型计算。ONNX 作为一

中国知网 https://www.cnki.net

个支持跨框架部署的推理引擎，不但可以加速模型推理，还可以将模型迁移到各种移动设备上，简化部署流程。

检测网络的标准输出形式是 (x,y,w,h)，表示以 (x,y) 为中心，w 和 h 为宽高的，包含了羽毛球的最小边界框。但是，后续的立体视觉模块仅需要羽毛球的中心坐标序列作为输入，因此检测模块仅向下游传输中心坐标，舍弃宽高信息。

4.4 重建三维轨迹

左右视角的图像序列在顺序、同步地经过基于 YO-CSA 检测网络的二维检测模块后，分别可以得到二维轨迹 $\boldsymbol{P}_L=\left\{\left(u_L^{(1)},v_L^{(1)}\right),\left(u_L^{(2)},v_L^{(2)}\right),\dots,\left(u_L^{(n_L)},v_L^{(n_L)}\right)\right\}$ 以及 $\boldsymbol{P}_R=\left\{\left(u_R^{(1)},v_R^{(1)}\right),\left(u_R^{(2)},v_R^{(2)}\right),\dots,\left(u_R^{(n_R)},v_R^{(n_R)}\right)\right\}$。在理论情况下，$\boldsymbol{P}_L$ 和 $\boldsymbol{P}_R$ 应当是同步等长、一一对应的，即，应当存在约束 $n_L=n_R$，且 $\left(u_L^{(i)},v_L^{(i)}\right)\Leftrightarrow\left(u_R^{(i)},v_R^{(i)}\right)$，其中 n_L 和 n_R 分别表示左右视角轨迹的长度。但是，由于检测过程中会出现误检、漏检的情况，更具体地说，漏检会导致当前帧的某一个视角或两个视角的坐标缺失，误检会在后续的合理性判断中被筛除。所以，实际得到的两个视角的轨迹 $\boldsymbol{P}_L$ 和 $\boldsymbol{P}_R$ 通常是不对称的。然而，单个视角的坐标无法基于立体视觉模块推算羽毛球在场景中的深度信息，因此，最终输入到立体视觉模块的左右视角轨迹 $\widehat{\boldsymbol{P}}_L=\left\{\left(\hat{u}_L^{(1)},\hat{v}_L^{(1)}\right),\left(\hat{u}_L^{(2)},\hat{v}_L^{(2)}\right),\dots,\left(\hat{u}_L^{(m)},\hat{v}_L^{(m)}\right)\right\}$ 和 $\widehat{\boldsymbol{P}}_R=\left\{\left(\hat{u}_R^{(1)},\hat{v}_R^{(1)}\right),\left(\hat{u}_R^{(2)},\hat{v}_R^{(2)}\right),\dots,\left(\hat{u}_R^{(m)},\hat{v}_R^{(m)}\right)\right\}$ 应当是合理性筛选后的，同步等长且一一对应的，其中 m 表示筛选后轨迹的长度。

虽然在检测模块的设计中，已经缓解了网络误检、漏检的缺陷，但是，鉴于硬件系统固有的误差属性，以及检测模块中的不确定性，二维轨迹到三维空间的映射会不可避免地放大系统误差，尤其是误检和漏检现象，导致偶现的误检现象对系统的性能产生显著的干扰现象。因此，本文基于轨迹的时空演化规律，在立体视觉模块增加了空间约束机制，以有效缓解误差累积，提升系统的稳定性以及对复杂场景的抗干扰能力。

在当前映射步骤中，本文对左右视角的对称像素坐标增加了时空约束。假设某一时刻羽毛球在左右相机的成像平面中的中心像素坐标分别为 $\boldsymbol{P}_L^{(i)}=\left(u_L^{(i)},v_L^{(i)}\right)$、$\boldsymbol{P}_R^{(i)}=\left(u_R^{(i)},v_R^{(i)}\right)$，考虑到相机成像的高帧率特性以及左右视角的对称性，对于同一时刻的左右视角的坐标 $\boldsymbol{P}_L^{(i)}$ 和 $\boldsymbol{P}_R^{(i)}$，应当仅在水平方向上有一较大范围内的偏差，而在垂直方向上，即便有切向畸变的存在，但是其干扰应当是微弱的。因此，当且仅当 $abs(v_L-v_R)\le\varepsilon_1$ 时，系统才判定这对坐标是有效的，其中 ε_1 是设定的阈值，实验中设为 10 像素。

对于时刻 i，假设羽毛球在左右相机的成像平面中的中心像素坐标分别为 $\boldsymbol{P}_L^{(i)}=\left(u_L^{(i)},v_L^{(i)}\right)$、$\boldsymbol{P}_R^{(i)}=\left(u_R^{(i)},v_R^{(i)}\right)$（后文简写为 $\boldsymbol{P}_L(u_L,v_L)$、$\boldsymbol{P}_R(u_R,v_R)$），要推算时刻 i 时羽毛球在世界坐标系的坐标，需要根据已知参数和几何关系逐步将像素坐标转换到世界坐标系中。假设标定后已知左右相机的内参矩阵分别为 $\boldsymbol{K}_L$、$\boldsymbol{K}_R$，畸变系数分别为 $\boldsymbol{D}_L=$

中国知网 https://www.cnki.net

$[k_{L,1},\ k_{L,2}]$、$\boldsymbol{D}_R = [k_{R,1},\ k_{R,2}]$，外参矩阵$\boldsymbol{T} = [\boldsymbol{R} \mid \boldsymbol{t}]$以及基线长度$B$，其中，外参矩阵包括了旋转矩阵$\mathbf{R}$和平移向量$\mathbf{t}$。

首先将像素坐标$\boldsymbol{P}_L(u_L, v_L)$、$\boldsymbol{P}_R(u_R, v_R)$根据公式（3-8）归一化映射到图像坐标系，得到仅有方向信息的归一化坐标$\boldsymbol{P}_L'(x_L, y_L)$、$\boldsymbol{P}_R'(x_R, y_R)$以及归一化半径$r$，便于后续几何关系的建立：

$$x = \frac{u - c_x}{f_x}, \qquad y = \frac{v - c_y}{f_y}, \qquad r^2 = x^2 + y^2 \tag{4-21}$$

其中，$(c_x,\ c_y)$表示相机的光学中心，f_x、f_y表示相机在水平和垂直方向上的焦距。

然后基于畸变系数$\boldsymbol{D}_L$、$\boldsymbol{D}_R$分别计算左右相机的畸变校正因子k_{radial}，根据校正因子进行畸变校正，可以得到去畸变后的图像坐标$\boldsymbol{P}_L''(x_L', y_L')$、$\boldsymbol{P}_R''(x_R', y_R')$：

$$\begin{cases} P_L''(x_L', y_L') = (x_L \cdot k_{radial,L}, y_L \cdot k_{radial,L}) \\ P_R''(x_R', y_R') = (x_R \cdot k_{radial,R}, y_R \cdot k_{radial,R}) \end{cases} \tag{4-22}$$

其中，

$$k_{radial} = 1 + k_1 r^2 + k_2 r^4 \tag{4-23}$$

再者，根据公式（3-8），基于内参$\boldsymbol{K}_L$、$\boldsymbol{K}_R$可将图像坐标$\boldsymbol{P}_L''$、$\boldsymbol{P}_R''$转换到相机坐标系，得到$\boldsymbol{P}_{c,L}''(x_{c,L}', y_{c,L}', 1)$、$\boldsymbol{P}_{c,R}''(x_{c,R}', y_{c,R}', 1)$，其中$x_c'$和$y_c'$是缺失了深度信息的坐标在相机坐标系下的归一化表示，其真实值需要通过对羽毛球深度z_c的推算来确定。

$$\begin{bmatrix} x_{c,L}' \\ y_{c,L}' \\ 1 \end{bmatrix} = \boldsymbol{K}_L^{-1} \begin{bmatrix} x_L' \\ y_L' \\ 1 \end{bmatrix}, \qquad \begin{bmatrix} x_{c,R}' \\ y_{c,R}' \\ 1 \end{bmatrix} = \boldsymbol{K}_R^{-1} \begin{bmatrix} x_R' \\ y_R' \\ 1 \end{bmatrix} \tag{4-24}$$

为了推算得到z_c的值，需要计算两个坐标之间的视差d，根据相机和视差之间的几何关系进行求解：

$$z_c = \frac{f_x \cdot B}{d}, \qquad d = x_{c,L}' - x_{c,R}' \tag{4-25}$$

其中，f_x表示相机在水平方向上的焦距。在得到了羽毛球在相机坐标系下的深度z_c，根据约束公式（3-8）将归一化坐标转换为相机坐标系下的真实坐标$\boldsymbol{P}_c(x_c, y_c, z_c)$：

$$[x_c \quad y_c \quad z_c]^T = z_c \cdot [x_{c,L}' \quad y_{c,L}' \quad 1]^T \tag{4-26}$$

最后，根据相机的外参矩阵$\boldsymbol{T} = [\boldsymbol{R} \mid \boldsymbol{t}]$，可以将羽毛球坐标从相机坐标系映射到世界坐标系中，得到真实三维空间坐标$\boldsymbol{P}_w(x_w, y_w, z_w)$：

$$\boldsymbol{P}_w = \boldsymbol{R}^{-1} \cdot (\boldsymbol{P}_c - \boldsymbol{t}) \tag{4-27}$$

为了避免误差累积削弱系统的鲁棒性和适应性，在映射得到的三维坐标轨迹中，本文同样基于时空约束对三维空间坐标进行了合理性判断，当且仅当$\left\| \boldsymbol{P}_w^{(j)} - \boldsymbol{P}_w^{(i)} \right\| \le d_t \cdot \Delta t$时，才认为$\boldsymbol{P}_w^{(j)}$合理，其中$\boldsymbol{P}_w^{(i)}$是历史最新的合理三维坐标，$d_t$表示单位时间合理运动距离，$\Delta t$表示两坐标之间的时间差。

中国知网 https://www.cnki.net

4.5 基于重投影更新时空约束

与二维平面不同，羽毛球在三维空间的运动轨迹涵盖了丰富的时间信息和空间信息，三维空间轨迹映射到二维图像平面会造成大量潜在信息的丢失，比如深度信息。二维平面的羽毛球轨迹不仅只能表达其在水平和垂直方向上的位置，还存在视角依赖，也就是说，羽毛球运动在不同视角的二维平面上的表现不同的形态。在这一过程中，尤其是在快速运动的情况下，羽毛球的旋转和飞行角度等信息会被高度压缩，损害轨迹的连续性，限制纯二维平面分析轨迹的准确度。而将二维轨迹恢复到三维空间，虽然无法完全恢复高维的动态特征，但是能够有效地弥补丢失的运动信息，合理地利用三维空间的信息可以帮助系统对未来时刻二维平面上的检测，这是纯二维图像的分析无法做到的。

鉴于此，本文在立体视觉模块利用三维空间中轨迹的历史信息，对未来时刻羽毛球在二维图像上的运动做了先验估计，期望提高系统在复杂飞行场景下的鲁棒性和准确度。

假设系统在时刻 i 检测到了有效的成对二维坐标 $\widehat{\boldsymbol{P}}_L^{(i)}$和 $\widehat{\boldsymbol{P}}_R^{(i)}$，并且在经过三维映射后得到了合理的三维坐标 $\boldsymbol{P}_w^{(i)}(x_w^{(i)},y_w^{(i)},z_w^{(i)})$。那么此时，系统拥有历史时刻 $[0,\ i]$ 之间所有的合理三维坐标，记为三维坐标序列 $\boldsymbol{\mathcal{P}}_w=\{\boldsymbol{P}_w^{(0)},\ \boldsymbol{P}_w^{(1)},\dots,\ \boldsymbol{P}_w^{(i)}\}$。本文在 x、y、z 三轴上基于时间戳分别对轨迹序列 $\boldsymbol{\mathcal{X}}_w=\{\boldsymbol{x}_w^{(0)},\ \boldsymbol{x}_w^{(1)},\dots,\ \boldsymbol{x}_w^{(i)}\}$、$\boldsymbol{\mathcal{Y}}_w=\{\boldsymbol{y}_w^{(0)},\ \boldsymbol{y}_w^{(1)},\dots,\ \boldsymbol{y}_w^{(i)}\}$、$\boldsymbol{\mathcal{Z}}_w=\left\{\boldsymbol{z}_w^{(0)},\ \boldsymbol{z}_w^{(1)},\dots,\ \boldsymbol{z}_w^{(i)}\right\}$作拟合计算 $f_x(t)$、$f_y(t)$、$f_z(t)$，并对羽毛球未来轨迹做出先验估计。

在得到了对时刻 j 羽毛球位置的先验估计 $\widehat{\boldsymbol{P}}_w^{(j)}(x_w^{(j)},y_w^{(j)},z_w^{(j)})$后，将该坐标重投影到左右相机的成像平面。重投影需要先根据公式（4-26）将坐标映射到相机坐标系，得到 $\widehat{\boldsymbol{P}}_c^{(j)}(x_c^{(j)},y_c^{(j)},z_c^{(j)})$，再通过内参矩阵 $\boldsymbol{K}_L$、$\boldsymbol{K}_R$ 分别投影得到 $\boldsymbol{P}_{L,pred}^{(j)}$ 和 $\boldsymbol{P}_{R,pred}^{(j)}$：

$$\begin{cases}\boldsymbol{P}_{L,pred}^{(j)}=\boldsymbol{K}_L\cdot\widehat{\boldsymbol{P}}_c^{(j)}=\boldsymbol{K}_L\cdot(\boldsymbol{R}_L\cdot\widehat{\boldsymbol{P}}_w^{(j)}+\boldsymbol{t}_L)\\ \boldsymbol{P}_{R,pred}^{(j)}=\boldsymbol{K}_R\cdot\widehat{\boldsymbol{P}}_c^{(j)}=\boldsymbol{K}_R\cdot(\boldsymbol{R}_R\cdot\widehat{\boldsymbol{P}}_w^{(j)}+\boldsymbol{t}_R)\end{cases}\tag{4-28}$$

由于上游映射过程中考虑了畸变，因此在重投影流程中也需要利用畸变系数$\boldsymbol{D}_L$、$\boldsymbol{D}_R$对坐标进行畸变恢复，得到最终的像素坐标$\widehat{\boldsymbol{P}}_{L,pred}\left(\hat{u}_L^{(j)},\hat{v}_L^{(j)}\right)$、$\widehat{\boldsymbol{P}}_{R,pred}\left(\hat{u}_R^{(j)},\hat{v}_R^{(j)}\right)$。先验预测并非直接介入二维图像中的羽毛球检测流程，而是通过对 ROI 位置的动态更新，间接优化检测模块对无关背景的弱化处理，并辅助检测模块工作。

同样地，为了防止误差递增削弱系统的可靠性，需要基于羽毛球运动的时空演化约束分别判断左右成像平面中先验位置的合理性。本文在这里基于每个视角中的预测点与最新历史点 $P_{last}(u_{last},\ v_{last})$的欧氏距离 d_{ed}，来判断预测的合理性，如果 d_{ed}小于阈值 ε_2（根据数据集中羽毛球的速度，实验设置$\varepsilon_2=320pixels$），则认为预测合理。

由于系统在实际轨迹提取的流程中，是以“组”进行批处理检测的，因此，ROI 的动态更新也需要和“组”的检测步长同步执行。假设当前“组”的图像对应时刻为 $[t_{i-n},$

中国知网 https://www.cnki.net

$t_{i-n-1}, \cdots, t_{i-1}]$，其中 n 表示一“组”的图像数量，那么，本文通过先验预测“组”的中间时刻，即 $t_{i+\frac{n-1}{2}}$ 时刻的羽毛球位置，来更新下一“组”检测时的 ROI。

4.6 补偿模块

由于系统在二维检测模块和立体视觉模块在二维平面和三维空间中都对轨迹进行了严格的合理性筛查，即便 YO-CSA 检测网络已经达到了较高的检测性能，但在绝大多数情况下，系统提取的三维轨迹仍然难以保证其完整性，会存在中间零散图像帧中的羽毛球位置坐标缺失的现象。这种轨迹的缺失本质上不是检测模块的性能局限，而是基于合理性约束的筛查策略在避免异常点和提高鲁棒性之间的权衡导致。为了弥补权衡带来的轨迹损失，本文引入了补偿模块作为辅助分支，基于轨迹的一致性约束，利用卷积神经网络补偿缺失帧，重建连续轨迹，提高系统提取的轨迹的完整性。

受 TrackNetv3[77]的启发，类似于插值，本文基于上游模块提取的三维轨迹让网络学习补偿缺失帧。补偿网络 $\mathcal{F}$ 的输入包括两个部分：①左右视角得到的二维轨迹序列经合理性筛查后的结果，记为 $\mathcal{X} \in \mathbb{R}^{T\times 2}$，其中 T 表示轨迹长度，②轨迹掩膜 $M \in \{0,1\}^{T\times 1}$，帮助网络识别需要补偿的缺失帧，可通过上游标记缺失帧获取，其中 $M_{t,i}=1$ 表示该图像帧检测到的羽毛球位置数据有效，$M_{t,i}=0$ 表示该图像帧位置缺失。

补偿网络 $\mathcal{F}$ 结构如图 4-5 所示，网络整体基于编码器-解码器结构，首先利用两个卷积操作将轨迹信息和掩膜信息映射到高维特征空间，然后基于简化后的 U 型结构[28]深度融合浅层特征和深层语义信息。由于轨迹是一维信息序列，因此补偿网络使用了一维卷积层在时间轴上滑动提取特征。补偿网络采用最小化均方误差作为损失函数进行训练。

在补偿网络 $\mathcal{F}$ 输出完整的轨迹序列 $\widetilde{\mathcal{X}} \in \mathbb{R}^{T\times 2}$ 后，根据轨迹掩膜 M，可以提取出补偿网络的插值坐标，进而更新原始轨迹 $\mathcal{X}$，如公式（3-8）所示：

$$\mathcal{X}' = \begin{cases} \mathcal{X}_i, & if\ M_{t,i}=1 \\ \widetilde{\mathcal{X}}_i, & if\ M_{t,i}=0 \end{cases} \tag{4-29}$$

在利用 $\widetilde{\mathcal{X}}$ 填补了缺失的位置节点后，二维轨迹序列 $\mathcal{X}'$ 会重新被送入立体视觉模块，映射到三维空间重建羽毛球的运动轨迹 $\widehat{\mathcal{X}}$，然后与补偿前的三维轨迹 $\boldsymbol{P}_w$ 进行融合。

本文在轨迹序列 $\boldsymbol{P}_w$ 和 $\widehat{\mathcal{X}}$ 的融合中，基于样条插值引入了合理性约束判断，记为 $\theta(\mathcal{X}, \widetilde{\mathcal{X}}, \mathcal{M})$：首先根据原始轨迹 $\boldsymbol{P}_w$，利用样条插值，得到另一个完整轨迹 $\boldsymbol{P}_w'$，假设缺失帧的位置集合为 $\mathcal{L}=\{t|M_{t,i}=0, \forall i \in [1,T]\}$，首先对缺失帧 $t \in \mathcal{L}$ 判断补偿值 $\widehat{\mathcal{X}}_{t,i}$ 的合理性（认为当 $\left\|\widehat{\mathcal{X}}_{t,i}-\boldsymbol{P}_w^{(j)}\right\| \le \varepsilon_3$ 时，$\widehat{\mathcal{X}}_t$ 合理，其中，$\boldsymbol{P}_w^{(j)}$ 表示原始轨迹 $\boldsymbol{P}_w$ 中，缺失帧前最新帧的位置，ε 表示阈值），若 $\widehat{\mathcal{X}}_t$ 合理，再对 $\boldsymbol{P}_w^{(i)'}$ 和 $\widehat{\mathcal{X}}_{t,i}$ 进行加权融合，得到最终的补偿值 $\widehat{\mathcal{X}}_{t,i}'$，该过程可用以下公式来表示：

中国知网 https://www.cnki.net

$$\widehat{X}_{t,i}{}' = \begin{cases} \boldsymbol{P}_w^{(i)}, if\ M_{t,i} = 1 \\ \alpha \widehat{X}_{t,i} + (1-\alpha)\boldsymbol{P}_w^{(i)'}, if\ M_{t,i} = 0\ and\ \left\| \widehat{X}_{t,i} - \boldsymbol{P}_w^{(j)} \right\| \le \varepsilon_3 \\ \boldsymbol{P}_w^{(i)'}, \quad if\ M_{t,i} = 0\ and\ \left\| \widehat{X}_{t,i} - \boldsymbol{P}_w^{(j)} \right\| > \varepsilon_3 \end{cases} \tag{4-30}$$

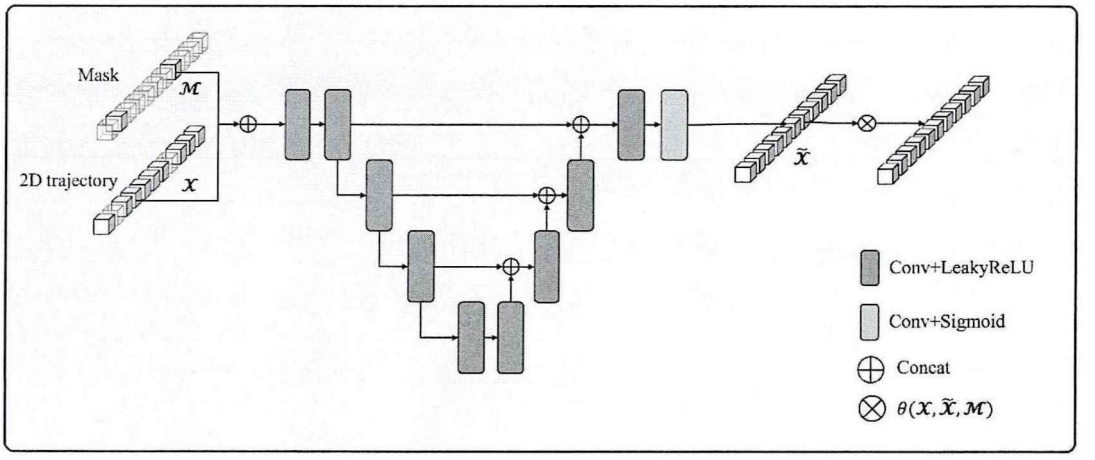


图 4-5 补偿网络 $\mathcal{F}$ 结构图

4.7 本章小结

本章详细阐述了三维羽毛球跟踪系统 YO-CSA-T 的架构以及工作流程。YO-CSA-T 主要分为二维检测模块、立体视觉模块以及轨迹补偿模块，通过结合检测、预测、补偿三大子任务，实现对羽毛球三维轨迹的准确提取。YO-CSA-T 的工作共分为 6 大步骤，其中引入了多种策略以提高系统提取轨迹的一致性和连续性。

中国知网 https://www.cnki.net

第5章 实验设计与结果分析

为了检验 YO-CSA-T 系统的有效性和优越性，本文首先基于自搭建的立体视觉平台（详见正文 4.1 所述）采集了 10 个不同场景的羽毛球图像，共计 32539 张，并制作了自有数据集，然后从二维检测任务与系统整体的轨迹提取性能两大维度进行了全面的实验评估。

在检测任务上，本文通过一系列消融实验和性能对比实验，验证了三大优化模块 Cot2f、SANeck 以及空间注意力解耦头在提升网络性能方面的显著作用。同时，与现有主流方法（如 YOLOv8s、YOLO11s 等）相比，本文提出的 YO-CSA 检测网络在整体检测性能上实现了显著突破，特别是在 mAP@0.75 指标上展现出了优异的提升。

在轨迹提取任务中，本文引入了全新的评价指标轨迹平滑度指数 S（包括速度平滑指数 S_v、加速度平滑指数 S_a）和轨迹一致性指数 C，并且基于这两个指标定量地对三大约束策略的性能进行了深入的对比与分析。

5.1 数据集

由于体育比赛相关的数据集仍处于一个匮乏的状态，而能够人机对打高帧率要求的、公开的羽毛球数据集更为稀缺。因此，为了验证 YO-CSA 网络的检测性能以及系统 YO-CSA-T 的轨迹实时提取可行性，本文采集和制作了一个高质量的羽毛球数据集。

5.1.1 数据集的采集与制作

本文基于正文 4.2 提到的自搭建的立体视觉平台，采集了涵盖了 10 个不同场地或环境（包括不同角度、不同灯光效果）下的羽毛球对打数据。经过数据抽样与清洗后，原始图像共计图像 32539 张。

由于 YO-CSA 最终在 640x640 的 ROI 上进行二维检测任务，因此本文在数据集的原始图片上进行了 640x640 大小的随机采样，并且限制其中必须存在羽毛球。

为了避免模型学习到不是本文所期望的位置信息，在采样时，数据集保证了羽毛球不一定在 640x640 采样区域的中心位置，而是随机分布在 640x640 的区域中，以避免羽毛球位置的特殊性干扰和削弱 YO-CSA 网络定位的泛化性。

图 5-1 展示了部分数据。从中可以看到，即便是在 640x640 的采样区域，羽毛球所占像素比例也非常小，受到背景中的灯光和场地线的干扰，部分羽毛球甚至肉眼也难以辨别。羽毛球在图像中有限的视觉特征，大大提高了检测模块的检测难度。

中国知网 https://www.cnki.net

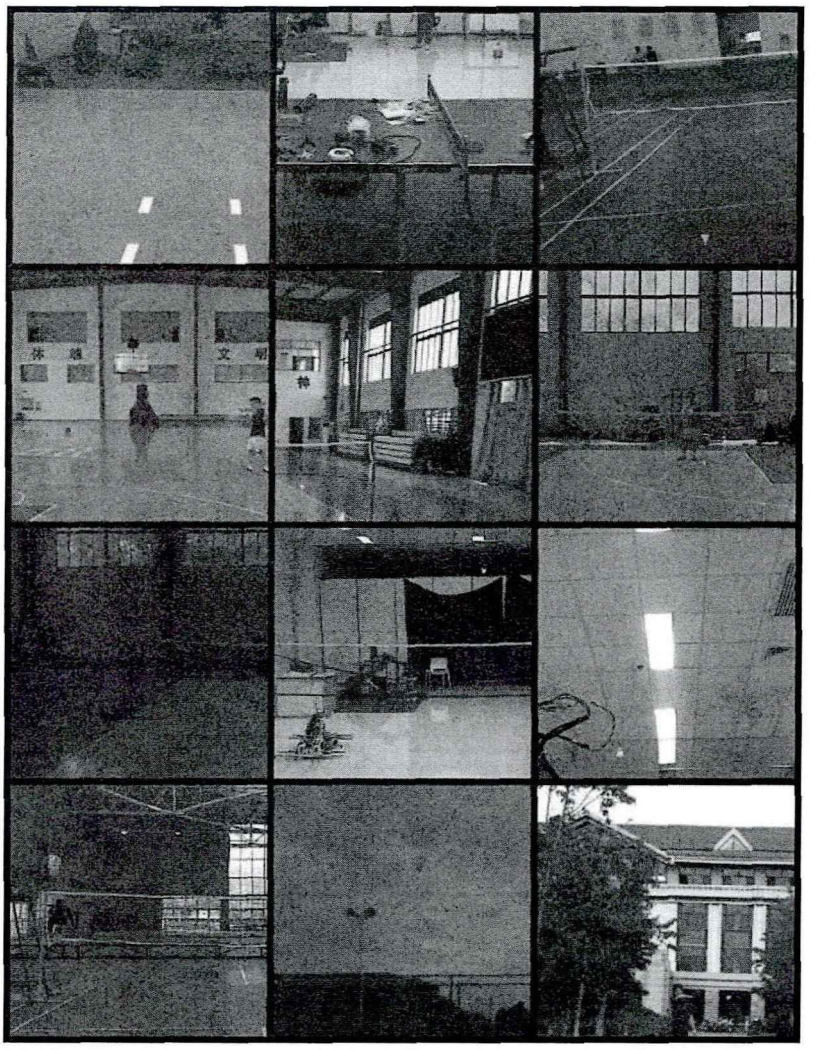


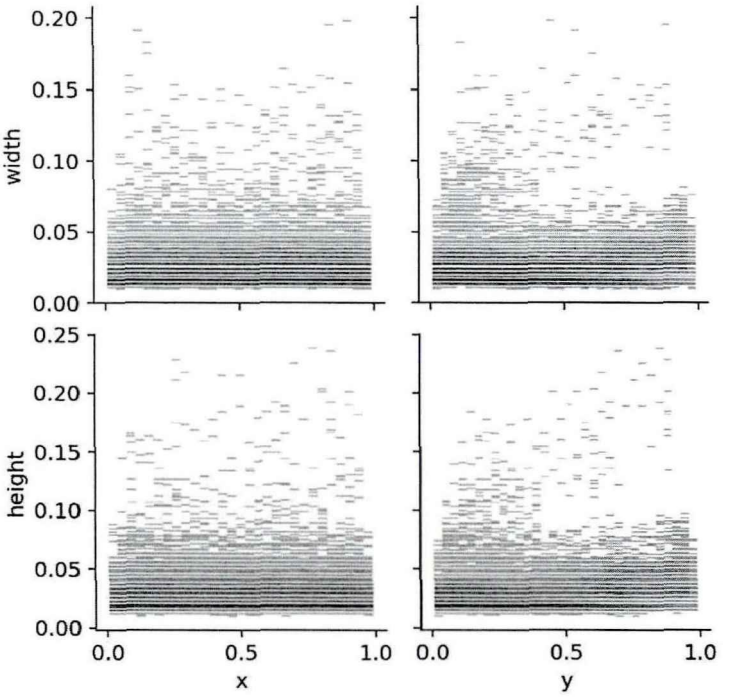
图 5-1 自有数据集部分场景图片

图 5-2 展示了数据集中羽毛球的分布情况。其中，图 5-2(a)展示了数据集中羽毛球的宽高分布情况，图 5-2(b)展示了数据集中羽毛球的宽高之间的关系：

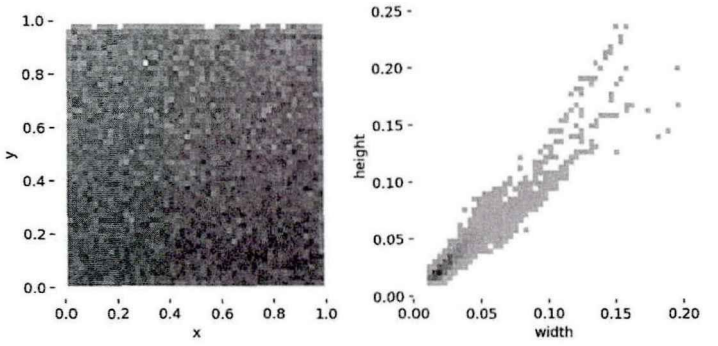
（1）由图 5-2(a)可知，羽毛球比较均匀地分布在采样区域中。同时，数据集中，大部分的羽毛球所占像素比例小于等于 0.25%（0.05x0.05），所有的羽毛球所占像素比例都在 5%（0.25x0.2）以下。整体而言，羽毛球的视觉特征非常有限。

（2）根据图 5-2(b)所示，羽毛球的边界框在数据集中整体呈现为一个接近于正方形的矩形，这一结论与羽毛球的标准尺寸相符。羽毛球的羽毛长度为 62-70 毫米，球托直径为 25-28 毫米，高度在 68-78 毫米之间。此外，羽毛球在高速飞行的过程中，会有一段相当长的时间球托朝前，这在图像中会呈现近似圆形的形态，与数据集中羽毛球的分布情况相符。

中国知网 https://www.cnki.net



(a) 羽毛球在图像中宽和高的分布情况



(b) 数据集中羽毛球宽与高之间的关系图

图 5-2 自有数据集中羽毛球的分布情况

5.1.2 数据增强

为了增强网络的泛化性和鲁棒性，本文在实际训练中，对训练数据应用了多种数据增强技术，针对羽毛球在飞行过程中的不同姿态以及环境的多样性，本文引入了以下三大方面的数据增强手段：

（1）图像的基本属性：包括图像的色调、饱和度、亮度等。通过对 HSV 颜色模型（Hue, Saturation, Value）[78]中的色调 H、饱和度 S 和亮度 V 的范围性随机调整，模拟不同环境和光源的真实场景。

（2）图像的几何变换：包括旋转、平移、缩放、上下翻转、左右翻转等。通过对简单的几何变换的随机组合，增强模型对目标物体位置的敏感度，强化模型在不同尺度下的泛化能力。

中国知网 https://www.cnki.net

（3）额外噪声的引入：基于 Mosaic[62]数据增强技术，随机裁剪四张图像，病拼接生成一张混合图像，帮助模型学习从局部视图中识别到目标物体的视觉特征的能力。引入概率性的随机擦除，在图像上随机遮挡图像部分区域，在训练过程中随机遮挡图像区域的技术，提高模型的鲁棒性。

表 5-1 训练过程中数据增强相关参数

超参数	值
色调变化范围	**[-0.4, 0.4]**
饱和度变化范围	**[-0.9, 0.9]**
亮度变化范围	**[-0.7, 0.7]**
旋转角度	**[-0.2, 0.2]**
平移	**[-0.3, 0.3]**
剪切	[-0.2, 0.2]
透视	[-0.0001, 0.0001]
上下翻转概率	0.5
左右翻转概率	0.5

注：表中加粗的参数是在 ultraysic 官方默认训练参数基础上的修改

表 5-1 中所示的超参数是数据增强相关的超参数，加粗的部分是在 ultraysic 官方默认训练参数的基础上进行的修改。此外，图 5-3 展示了部分数据增强后的图像效果。

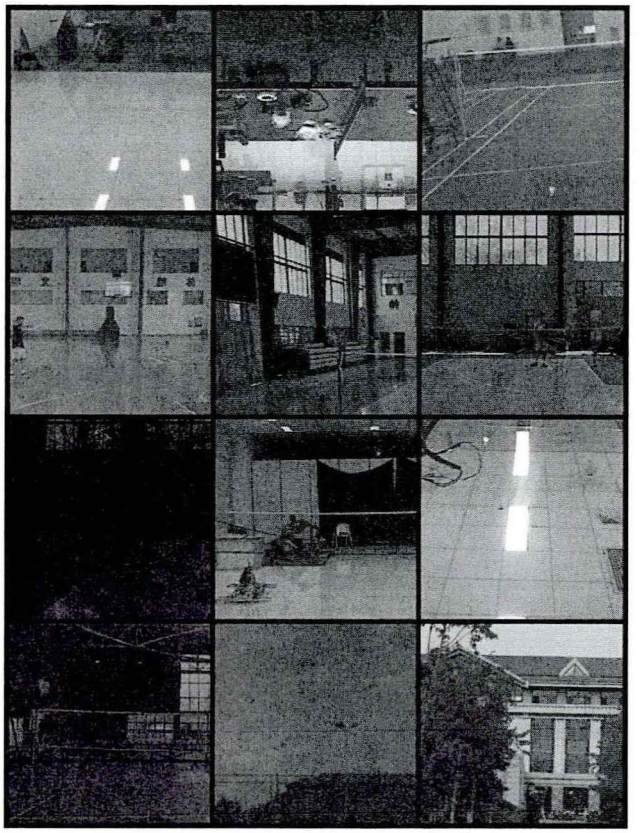


图 5-3 数据增强效果示意图

中国知网 https://www.cnki.net

5.2 检测模块相关实验与结果分析

实验基础设置见表 5-2、表 5-3。除了对数据增强相关参数微调以强化网络对复杂背景的抗干扰能力外，本文沿用了对 ultralytics 官方版本的训练参数。基于这样的实验设置，本文在自有数据集上对 YO-CSA 网络进行了 400 次迭代训练。

表 5-2 实验服务器设置

名称	型号/版本
GPU	NVIDIA GeForce RTX 3090 GPU
CUDA	12.2
深度学习框架	Pytorch 2.4.1
跨平台推理引擎	Onnxruntime-gpu 1.19.2

表 5-3 实验训练参数设置

参数名	值
训练迭代次数	400
批大小	64
初始学习率	0.01
最终学习率	0.0001
优化器	随机梯度下降法[83]
动量	0.937
权重衰减	0.0005
预热迭代次数	3.0

本文首先对比了 YO-CSA 网络与其他目标检测网络（Faster R-CNN[47]、RetinaNet[50]、TrackNetV2[25]、YOLOv5s、YOLOv8s 以及 YOLO11s）之间的检测性能，具体结果可见表 5-4 所示，其中加粗部分为每个评价指标的最优结果。

表 5-4 YO-CSA 与其他主流网络在自有数据集上的检测结果

模型	mAP@0.5 (%)	mAP@0.75 (%)	mAP@0.5:0.95 (%)	召回率 (%)	检测速度 (fps)
Faster R-CNN	98.30	78.29	58.52	87.10	229.6
RetinaNet	93.87	62.76	59.57	74.09	222.4
TrackNetV2	98.21	68.23	60.61	89.32	215.6
YOLOv5s	98.49	76.06	65.59	95.28	**285.7**
YOLOv8s	99.38	82.67	71.50	98.62	250.0
YOLO11s	99.37	86.94	71.56	98.25	238.1
YO-CSA	**99.43**	**90.43**	**74.00**	**99.02**	243.9

注：mAp@0.75 要求只有当模型预测的边界框与真实标注的 IoU 达到或高于 0.75 时，才为正确检测。

中国知网 https://www.cnki.net

由于边界框的定位准确度会直接影响轨迹提取的准确度，而相比于 mAP@0.75，mAP@0.5 并不能有效展示模型预测的边界框的定位精度，如图 5-4 所示。因此本文在实验中重点关注了不同模型在 mAp@0.75 指标上的表现。

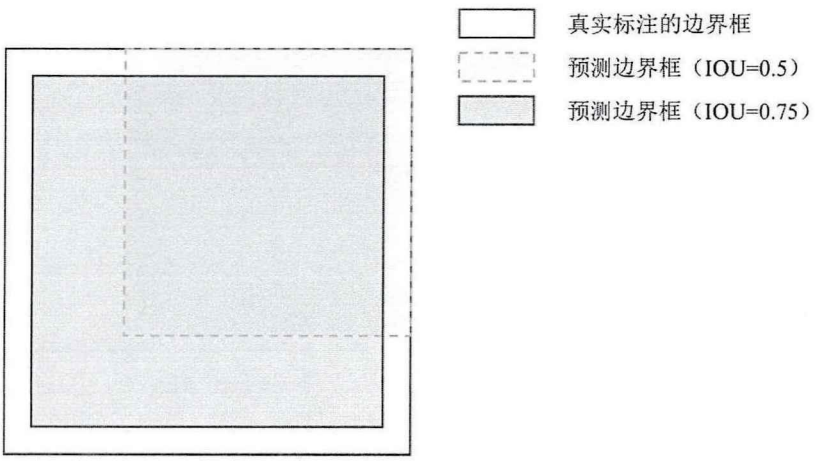


图 5-4 mAP@0.5 和 mAP@0.75 的精确度对比

实验结果显示，除了检测速度指标外，YO-CSA 在其他所有指标（mAP@0.5、mAP@0.75、mAP@0.5:0.95、召回率、准确率）上都超越了其他主流模型，尤其是在 mAP@0.75 和 mAP@0.5:0.95 指标上，分别达到了 90.43%和 74.00%的高精确度，在 mAp@0.75 指标上，超越了 YOLOv8 模型 7.76%、YOLO11 模型 3.49%，在 mAP@0.5:0.95 指标上，超越了 YOLOv8 模型 2.50%、YOLO11 模型 2.44%。

mAp@0.75 要求只有当模型预测的边界框与真实标注的 IoU（Intersection over Union，重叠度）达到或高于 0.75 时，才被视为正确检测，该指标的显著提升说明 YO-CSA 可以在更为严格的检测标准下精准地定位目标物体，具有优秀的定位能力。而 mAP@0.5:0.95 则是模型在多个 IoU 阈值下的平均精度，综合评估模型在不同检测标准下的表现。mAP@0.5:0.95 指标的提高，说明 YO-CSA 在不同检测标准下都能保持优异的性能，表明其卓越的鲁棒性和适应性。

图 5-5 展示了 YO-CSA 与其他模型在检测任务中的表现对比，其中，每张图像的右下角放大 5 倍地展示了不同网络的检测结果（不同颜色的边界框）与真实标注值（红色半透明矩形区域）的差异。比较三个模型与真实标注值的差异可知，YO-CSA 在推理过程中生成的边界框与真实标注值最为契合，这也证明了其优越的检测精度。

中国知网 https://www.cnki.net

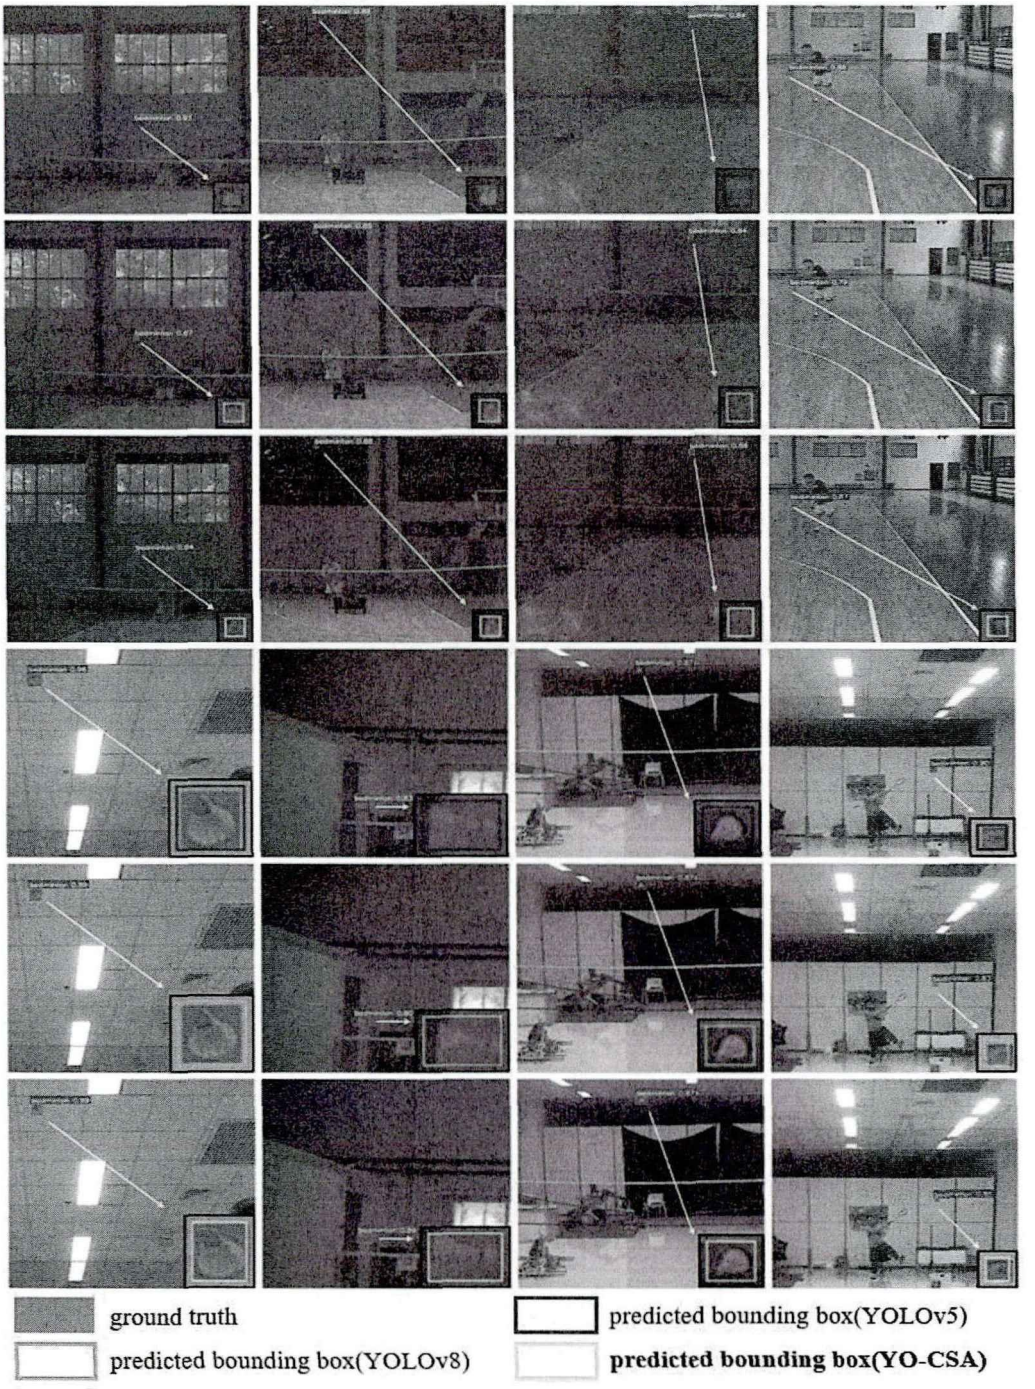


图 5-5 YO-CSA 与 YOLOv5s、YOLOv8s 的预测效果比较

为了验证 YO-CSA 中三大优化手段的有效性，本文对 YO-CSA 开展了消融实验，实验结果如表 5-5 所示。消融实验设置如下：

（1）YOLOv8s：ultralytics 官方开源版本。为保证消融实验结果的可靠性，在训练中不导入预训练权重。

（2）YOLOv8s+ab：仅在 YOLOv8 框架中引入双卷积上下文注意力单元 CoT2f 和基于空间注意力的特征增强模块 SGE-2f，目的是验证空间注意力解耦头的贡献。

中国知网 https://www.cnki.net

（3）YOLOv8s+ac：仅在 YOLOv8 框架中引入双卷积上下文注意力单元 CoT2f 和空间注意力解耦头，目的是验证基于空间注意力的特征增强模块 SGE-2f 的贡献。

（4）YOLOv8s+bc：仅在 YOLOv8 框架中引入基于空间注意力的特征增强模块 SGE-2f 和空间注意力解耦头，目的是验证双卷积上下文注意力单元 CoT2f 的贡献。

（5）YOLOv8s+abc：在 YOLOv8 框架中引入双卷积上下文注意力单元 CoT2f、基于空间注意力的特征增强模块 SGE-2f 以及空间注意力解耦头，检验 YO-CSA 网络的整体检测性能。

表 5-5 YO-CSA 在自有数据集上的消融实验结果

模型	mAp@0.5 (%)	mAp@0.75 (%)	mAP@0.5:0.95 (%)	召回率 (%)	GFlops
YOLOv8s	99.38	82.67	71.50	98.62	23.6
YOLOv8s+ab	99.40	89.21	73.32	98.91	20.9
YOLOv8s+ac	99.40	89.37	73.56	98.40	20.9
YOLOv8s+bc	99.42	88.37	73.54	98.97	23.6
YOLOv8s+abc (YO-CSA)	**99.43**	**90.43**	**74.00**	**99.02**	**20.9**

由于三个优化模块都遵循了轻量化的原则，因此，YO-CSA 网络的参数量相较于 YOLOv8 并没有上升。相反，Cot2f 结构的轻量化设计有效减少了原骨干网络的参数量，使得 YO-CSA 网络的整体参数量下降到 20.9GFlops，下降了 11.44%。

实验结果表明，三种优化手段都为模型带来了性能的提升，尤其是在 mAP@0.75 指标上：引入了 Cot2f 和 SGE-2f 的 YOLOv8s 在 mAP@0.75 上达到了 89.21%，引入了 Cot2f 和新检测头的 YOLOv8s 在 mAP@0.75 上达到了 89.37%，引入了 SGE-2f 和新检测头的 YOLOv8s 在 mAP@0.75 上达到了 88.37%，远高于 YOLOv8s 模型在 mAP@0.75 上 82.67%的分值。这说明三种手段都有效地优化了边界框的回归任务。

同时采用三种优化手段可以达到更好的检测效果，YO-CSA 在 mAP@0.75 指标上达到了 90.43%的优秀成绩，超越了 YOLOv8 模型 7.76%。这说明上下文注意力和空间注意力能够有效地帮助网络提取全局语义和局部子特征和强化模型的学习能力。

正文 4.3 中提到，为了缓解移动机器人对算力的限制，本文在 YO-CSA 的推理过程基于 OnnxRuntime 硬件加速库进行了加速操作，表 5-6 展示了加速前后的相关数据，包括模型单帧的推理时间以及加速前后准确率和召回率对比等指标。

总体来说，经过加速后，YO-CSA 单帧的推理时间显著减少到 5.82ms/帧，减少了 12.7%，帧率提高到了 171.82fps，同时检测精度没有明显变化。这说明模型可以在算力消耗和推理速率之间达成一个良好的平衡，在低算力环境下也可以在保持精度的同时进行较高速率的推理。

中国知网 https://www.cnki.net

表 5-6 YO-CSA、YOLOv8s 以及 YOLO11s 加速前后的检测结果对比

模型	mAp@0.5 (%)	mAp@0.75 (%)	mAP@0.5:0.95 (%)	召回率 (%)	推理速度 (fps)
YOLOv8s	99.38	82.67	71.50	98.62	146.20
YOLOv8s 加速后	99.34	82.65	71.27	98.55	168.63
YOLO11s	99.37	86.94	71.56	98.25	142.25
YOLO11s 加速后	99.36	86.45	71.23	98.17	150.15
YO-CSA	**99.43**	**90.43**	**74.00**	**99.02**	149.93
YO-CSA 加速后	99.42	90.41	73.94	99.01	**171.82**

5.3 系统性能相关实验与结果分析

5.3.1 评价指标

获取羽毛球在三维空间的真实运动轨迹存在一定挑战，这需要高精度的定位设备，如红外线探测器，搭建囊括整个球场范围的 3D 运动捕捉系统，才能够在限制速率下捕获球的运动，如 Habiba Hegazy 等人[79]利用红外深度摄像头捕获乒乓球的轨迹。

但是，搭建这样的系统需要较高成本，在其他相关工作中，研究者往往通过其他手段来避免对真实三维运动轨迹的采集，例如，Vito Renò等人[80]依托于四台高分辨率摄像机搭建 3D 立体系统，通过图像处理技术重建网球的运动轨迹作为真实值；Jonas Tebbe 等人[81]以乒乓球发球机设定的旋转角度作为真实值，来验证提出方法对球旋转的估计性能；S. Mohammad Amin Moazzen 等人[82]通过建立虚拟 3D 环境来采集球轨迹数据进行实验。鉴于采集羽毛球高精度的三维运动轨迹需要耗费的较大成本，本文在实验设计中，不直接采集三维运动轨迹，而是通过对三维运动轨迹的特性研究来间接定量分析系统的性能。

考虑到羽毛球在三维空间的运动轨迹应当是平滑的，并且在时间序列上有极高连续性和一致性的，本文基于轨迹本身的平滑性和连续性设置了两个维度评价指标来定量分析系统轨迹提取的性能，评价指标的计算方式如下：

（1）轨迹平滑度指数 S

假设系统提取得到轨迹 $\boldsymbol{P}_w = \{\boldsymbol{P}_w^{(0)}, \boldsymbol{P}_w^{(1)}, \dots, \boldsymbol{P}_w^{(n)}\}$，其中 $\boldsymbol{P}_w^{(i)} = (x_w^{(i)}, y_w^{(i)}, z_w^{(i)})$ 表示轨迹 $\boldsymbol{P}_w$ 中第 i 个三维坐标点，n 表示轨迹的长度，那么，可以得到第 i 个三维坐标点 $\boldsymbol{P}_w^{(i)}$ 对应的速度 v_i 和加速度 a_i 为：

$$\boldsymbol{v}_i = \frac{\boldsymbol{P}_w^{(i+1)} - \boldsymbol{P}_w^{(i)}}{t_{i+1} - t_i}, \qquad \boldsymbol{a}_i = \frac{\boldsymbol{v}_{i+1} - \boldsymbol{v}_i}{t_{i+1} - t_i} \tag{5-1}$$

其中，t_i 表示 $\boldsymbol{P}_w^{(i)}$ 对应的时刻。那么，可以根据每一组相邻点之间的速度和加速度差异计算得到速度平滑指数 S_v 和加速度平滑指数 S_a，具体计算公式如下：

中国知网 https://www.cnki.net

$$\begin{cases} S_v = \dfrac{1}{n-2}\sum_{i=1}^{n-2} \Delta v_i{}^2, & \Delta v_i = \|\boldsymbol{v}_{i+1} - \boldsymbol{v}_i\| \\ S_a = \dfrac{1}{n-2}\sum_{i=1}^{n-2} \Delta a_i{}^2, & \Delta a_i = \left\| \dfrac{\boldsymbol{v}_{i+1} - \boldsymbol{v}_i}{(t_{i+2} - t_i)/2} \right\| \end{cases} \tag{5-2}$$

该评价指标旨在定量评估轨迹的平滑度。具体地说，速度和加速度的变化程度反映了轨迹在时空中的连续性，若速度和加速度的平均差异越小，说明获取的轨迹在各个时刻的动态变化越平滑；而若速度和加速度的平均差异越大，说明轨迹中可能存在显著的噪声或异常值，导致轨迹偏离真实运动路径，表现出不稳定性和较低的平滑度。

（2）轨迹一致性指数 C

类似地，假设系统提取得到轨迹 $\boldsymbol{P}_w = \{\boldsymbol{P}_w^{(0)}, \boldsymbol{P}_w^{(1)}, \dots, \boldsymbol{P}_w^{(n)}\}$，其中 $\boldsymbol{P}_w^{(i)} = (x_w^{(i)}, y_w^{(i)}, z_w^{(i)})$ 表示轨迹 $\boldsymbol{P}_w$ 中第 i 个三维坐标点，n 表示轨迹的长度，则可以根据每一组相邻点之间的重心差异计算得到轨迹的一致性指数 C：

$$\begin{aligned} C &= \frac{1}{n-1}\sum_{i=1}^{n-1} |\Delta C_i|, \\ \Delta C_i &= \sqrt{(x_w^{(i+1)} - x_w^{(i)})^2 + (y_w^{(i+1)} - y_w^{(i)})^2 + (z_w^{(i+1)} - z_w^{(i)})^2} \end{aligned} \tag{5-3}$$

轨迹重心的平均变化程度可以作为评估轨迹一致性的关键性指标。重心的变化越剧烈，说明轨迹在空间分布上越不稳定，可能在部分时间序列片中存在缺失情况。若相邻轨迹点之间存在剧烈的重心变化，则意味着轨迹存在明显的波动，不符合一致性。因此，重心的平均变化程度越小，说明轨迹越稳定、越连续。通过计算轨迹的平均重心变化，可以定量分析轨迹的一致性和连续性。

5.3.2 实验结果分析

为了验证 YO-CSA-T 系统提取轨迹的性能，本文依托于正文 4.2 所述的立体视觉平台，采集了 10 个 160fps 的，分辨率为 1920x1200 的发球或击球视频片段。由于白色羽毛球在图像中视觉特征极其有限，背景中的大量白色区域会对检测任务造成较大干扰效果，因此，为了评估系统在复杂背景下的工作能力，这 10 个片段在采集时针对性地选取了包含大量白色物体（包括墙体、杂物、灯光等）的场景。

在系统的轨迹提取流程中，步骤（2）、（4）-（6）都通过额外引入基于时空约束的策略来增强系统对复杂背景的抗干扰性，包括：

（1）先在分辨率为 1920x1200 的原始图像上框选 640x640 的 ROI，再将左右视角对称的 ROI 以“组”的形式送入到检测模块进行羽毛球二维检测。通过增加羽毛球在检测图像中的比例，减少无关背景对检测任务的干扰，来提高检测任务的定位精度。

中国知网 https://www.cnki.net

（2）基于历史三维轨迹，预测下一“组”图像中间时刻的未来三维坐标，并且基于立体视觉建模，重投影到左右成像平面中，进而根据未来三维轨迹在二维平面上的映射 $\widehat{\boldsymbol{P}}_{L,pred}$ 和 $\widehat{\boldsymbol{P}}_{R,pred}$ 来同步更新 ROI 的范围；

（3）对于经处理后的满足一致性的二维轨迹 $\widehat{\boldsymbol{P}}_L$ 以及 $\widehat{\boldsymbol{P}}_R$，基于补偿模块进行缺失帧的填补，再将补偿后的二维轨迹重新送入到立体视觉模块，最终映射生成连续的三维轨迹 $\widehat{\boldsymbol{P}}_w'$。

为了检验三条策略对系统鲁棒性的有效贡献，本文对这三种策略进行了比较实验，通过对轨迹平滑度指数 S（包括速度平滑指数 S_v、加速度平滑指数 S_a）和轨迹一致性指数 C 的定量分析，评估策略的效力。实验具体设置如下：

（1）策略 A：直接在原始分辨率为 1920x1200 的二维图像序列上进行目标检测，将基于合理性约束处理后的对称的左右二维轨迹送入到立体视觉模块进行三维匹配。

（2）策略 B：在左右视图上框选大小为 640x640，并且包含羽毛球的 ROI 区域。但是，ROI 的位置不会基于步骤（5）进行动态更新。

（3）策略 C：在左右视图上框选大小为 640x640，并且包含羽毛球的 ROI 区域。同时，利用三维轨迹的历史信息，在三维空间中预测下一“组”中间时刻时羽毛球的三维空间坐标，再重投影到左右视图上得到 $\widehat{\boldsymbol{P}}_{L,pred}$ 和 $\widehat{\boldsymbol{P}}_{R,pred}$，进而进行 ROI 的同步更新。

（4）策略 D：对于步骤（2）得到的二维轨迹 $\widehat{\boldsymbol{P}}_L$ 以及 $\widehat{\boldsymbol{P}}_R$，将其送入到补偿模块中，基于补偿网络对缺失帧进行填补，再将补偿后的二维轨迹送入到立体视觉模块中，得到最终的三维轨迹 $\widehat{\boldsymbol{P}}_w'$。

表 5-7 基于平均有效检测比例、轨迹平滑度指数 S（包括 S_v 和 S_a）、轨迹一致性指数 C 以及提取速度总结了四种策略下的系统性能。其中，平均有效检测比例表示系统在所有片段中检测到羽毛球的图像帧数比例的平均值。由于补偿模块是系统的辅助分支，所以在实验室并未测试策略 D 下系统的运行速度。

表 5-7 不同策略约束下的系统性能结果

策略	平均有效检测比例（%）	平滑度指数		一致性指数	速度（fps）
		速度平滑指数	加速度平滑指数		
策略 A	27.86	>100	>1e7	19.10	85.7
策略 B	30.38	6.91	1.13e6	5.76	**135.9**
策略 C	81.28	3.92	2.77e5	2.98	133.3
策略 D	**100.00**	**2.31**	**2.25e5**	**2.35**	-

分析表 5-7 数据，可以得到以下结论：

（1）基于原始分辨率的检测，计算负担较重，耗时较久。先框选 640x640 的 ROI 再进行检测，可以极大地加快检测速度。这项策略有效减小检测模块的计算压力。

中国知网 https://www.cnki.net

（2）相比于 1920x1200 的原始分辨率，羽毛球在 640x640 的 ROI 区域中占比更高，从而使得检测模块能够更加关注与目标物体，因此系统的检测效果更好。与策略 A 相比，策略 B 所得到的轨迹在平滑度和一致性方面有着显著的提升，这表明 ROI 的引入，可以抑制无关背景对轨迹提取的干扰。

（3）基于三维历史轨迹对羽毛球的未来位置做先验估计，并结合动态更新 ROI 的策略 C，可以大幅度地提升有效检测的比例。另外，在不明显影响速率的前提下，结合预测和动态调整 ROI 的策略 C 提取得到的轨迹，其平滑度和一致性相较于策略 B 亦有着显著的提升。

综上所述，在系统提取轨迹的工作流程中引入三大时空约束策略，可以有效地优化轨迹的质量，提取得到平滑且保持高度一致性的羽毛球运动轨迹。

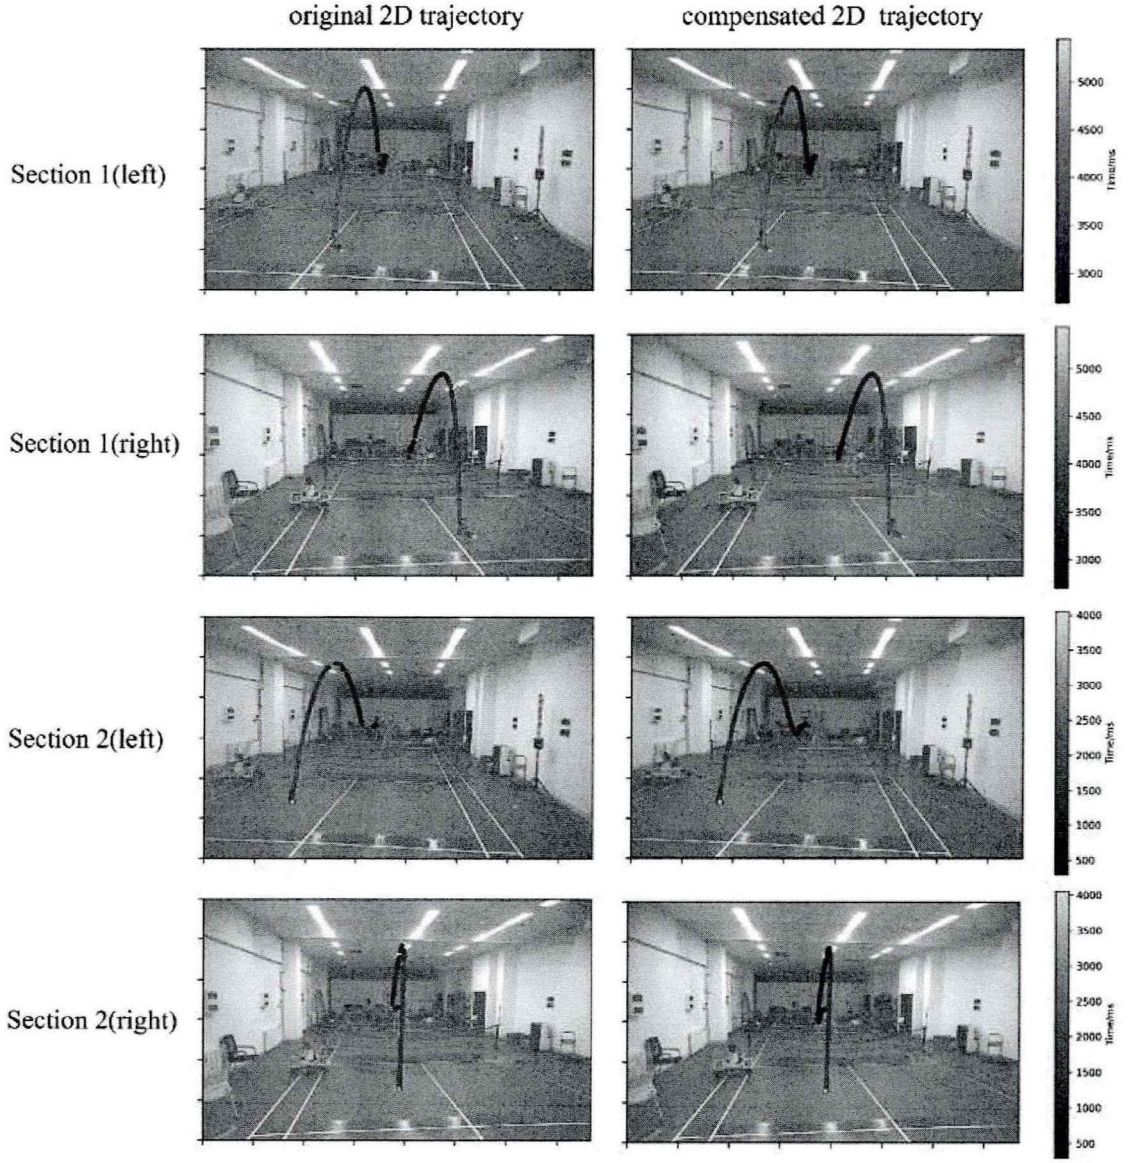


图 5-6 部分片段左右视图补偿前后对比

中国知网 https://www.cnki.net

表 5-8 部分片段左右视角二维轨迹补偿前后的平滑度指数与一致性指数对比

片段（视角，状态）	平均有效检测比例（%）	平滑度指数		一致性指数
		速度平滑指数	加速度平滑指数	
片段 1（左）	81.90	5.54	3.70e5	2.00
片段 1（左，补偿后）	100.00	4.23 ↓	3.05e5 ↓	1.53 ↓
片段 1（右）	81.90	5.50	3.58e5	1.95
片段 1（右，补偿后）	100.00	4.14 ↓	2.92e5 ↓	1.50 ↓
片段 2（左）	95.39	3.69	2.74e5	1.65
片段 2（左，补偿后）	100.00	3.29 ↓	2.63e5 ↓	1.59 ↓
片段 2（右）	95.39	3.83	2.74e5	1.97
片段 2（右，补偿后）	100.00	3.73 ↓	2.64e5 ↓	1.91 ↓
片段 3（左）	74.79	4.02	2.72e5	1.78
片段 3（左，补偿后）	100.00	2.82 ↓	2.04e5 ↓	1.08 ↓
片段 3（右）	74.79	4.24	2.85e5	2.41
片段 3（右，补偿后）	100.00	3.00 ↓	2.15e5 ↓	1.48 ↓

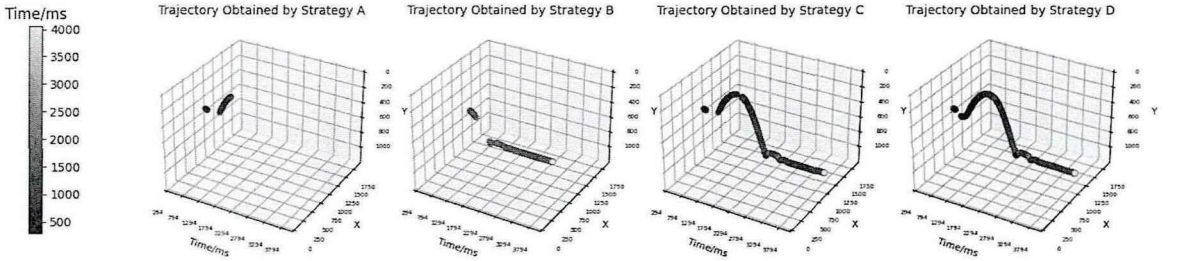
注：表中箭头（↓）表示了补偿后各评价指标数值的变化趋势，除平均有效检测比例外，其他指标越小表示轨迹越连续和平滑。

表 5-8 是部分轨迹二维轨迹在经过补偿模块前后轨迹的平滑度与一致性的对比（类比于 $z = 0$ 的三维坐标点代入计算）。比较表中数据可以发现，经过了补偿模块的轨迹，其平滑度指数和一致性指数都有显著下降，也就是说，补偿后的轨迹更加地平滑和连续。

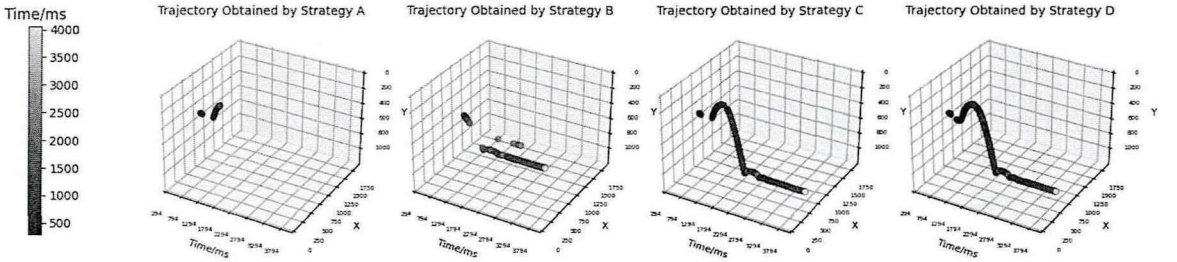
另外，图 5-6 展示的部分片段经由检测模块后提取得到的左右视角的二维轨迹以及补偿后的二维轨迹对比图也证明了补偿模块的有效性。

图 5-7 是其中一条片段基于不同策略提取得到的轨迹的对比图，可以直观地看到，根据策略 A，即不增加约束，直接在原始分辨率上进行检测，系统极易由于初始的误检导致工作崩溃；而根据策略 B，系统只能在固定的 ROI 区域有较好的轨迹提取效果，一旦羽毛球离开了 ROI，就无法提取到坐标信息；相比之下，策略 C 获得的轨迹已经相当平滑且连续了，而策略 D 进一步提高了系统提取的轨迹的平滑度和连续性。

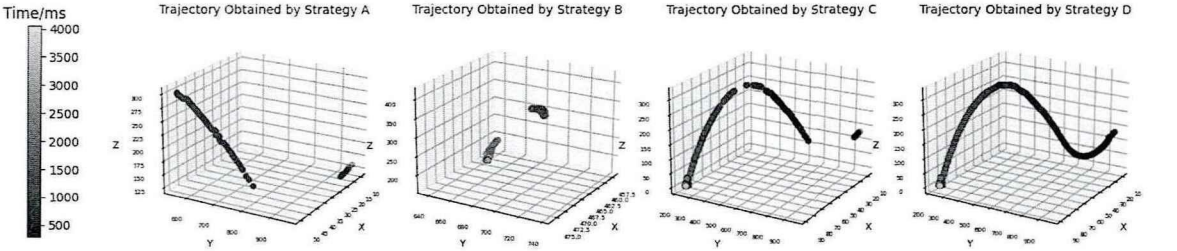
中国知网 https://www.cnki.net



(a)不同策略下左成像平面提取的二维轨迹



(b)不同策略下右成像平面提取的二维轨迹



(c)不同策略下提取的三维轨迹

图 5-7 一条轨迹不同策略下提取的二维轨迹和三维轨迹对比

表 5-9 策略 C 下不同系统的性能比较

系统	平均有效检测比例（%）	平滑度指数		一致性指数	速度（fps）
		速度平滑指数	加速度平滑指数		
Faster R-CNN[47] + 系统流程	70.30	8.90	9.70e5	7.34	100.0
RetinaNet[50] + 系统流程	72.00	7.62	8.59e5	6.81	120.6
TrackNetV2[25] + 系统流程	75.90	5.67	6.34e5	5.02	150.6
YO-CSA-T	81.28	3.92	2.77e5	2.98	133.3

中国知网 https://www.cnki.net

为了检测不同配置系统的性能，本文在策略 C 的设置下（可测试实时轨迹提取的性能），替换了不同的目标检测网络，进行了性能比较，表 5-9 展示了相关的实验结果。实验证明，YO-CSA-T 可以更快速地提取更高一致性和连续性的三维轨迹。

5.4 本章小结

本章首先介绍了自有羽毛球数据集的采集与制作过程，然后对数据集进行了数据分布的分析，证明数据集的广泛性以及丰富性，最后通过可视化对比展示了数据增强前后的效果。

然后，本章从检测模块和系统性能两大角度展开了充分的实验，以验证 YO-CSA-T 系统在真实场景下的有效性。在检测模块中，本章首先与其他目标检测网络（Faster R-CNN[47]、RetinaNet[50]、TrackNetV2[25]、YOLOv5s、YOLOv8s 以及 YOLO11s）进行了检测性能的比较，然后通过消融实验验证了三大优化手段的有效性。在系统性能上，本章比较了不同策略对系统的提升，并且在策略 C 的设置下，比较了不同系统配置的性能，证明了 YO-CSA-T 系统的优越性。

中国知网 https://www.cnki.net

第6章 总结与展望

在研究者们夜以继日的探索之下，从对卷积[85]、BatchNorm[69]、ReLU[86]激活函数等基础操作的探究，到全卷积网络、编码器-解码器结构[28]、Transformer[17]等网络架构的推出，深度神经网络的真容被逐步地展现，其潜力和性能也一次次地突破了各个领域的瓶颈。机器人领域和体育领域作为深度学习发展的受益领域之二，亦有着广阔的发展空间。

日前已有 AlphaGo[20]vs 九段旗手李世石、GT Sophy[21]vs 顶级 Gran Turismo 游戏赛车手 Jones 等多场人机大战。但在体育赛事中，要想实现真正的人机对打，比如羽毛球人机对打，还尚有多个难题需要解决，包括对球轨迹的实时提取、对球落点的预测、对机械臂运动的实时规划等。而本文的研究重心是开发一个集实时性与准确性于一体的三维羽毛球跟踪系统 YO-CSA-T，实现羽毛球人机对打的关键的第一步。

人机对打要求对羽毛球三维轨迹的高实时性和高准确度的提取。而作为小球类运动，羽毛球在图像中的有限视觉特征以及高速运动的视角依赖和噪声干扰，使得二维图像中的羽毛球检测成为不小的挑战。为了权衡实时性与准确度，本文基于 YOLOv8s，提出了基于双注意力机制的二维检测网络 YO-CSA。通过引入上下文注意力和空间注意力双注意力机制，YO-CSA 重新设计了骨干网络、颈部网络以及检测头部。轻量化的注意力结构不仅进一步减少了网络的参数量，而且大大提高了二维检测的定位精度。在获取了羽毛球的二维轨迹后，本文基于自搭建的立体视觉模块和羽毛球运动的时空演化规律，引入了多重时空约束策略，将二维轨迹有效地映射到了三维空间中。本文还提出了轨迹补偿模块，以弥补二维检测模块中的误检、漏检，以及多重约束策略下被筛除的不合理点，最终得到了高连续性和一致性的羽毛球三维运动轨迹。

本文对 YO-CSA 二维检测网络进行了充分的实验。对比实验证明，与其他目标检测模型相比，YO-CSA 可以在保证快速推理的前提下，达到最为优越的性能。同时，消融实验了双注意力机制在骨干网络、颈部网络以及检测头部的有效贡献。此外，本文基于自由的轨迹数据对 YO-CSA-T 系统的整体性能进行了实验。实验证明了多重约束策略的有效性以及系统提取得到的轨迹的连续性和一致性。

但是，YO-CSA 还存在一定的局限，未来的工作可以从以下方面进行优化和完善：

（1）立体视觉模块的限制。目前的双目相机平台需要固定搭建，搭建后不可移动，不可避免地会限制机器人的移动范围。理想的设计是将双目相机平台搭建在机器人之上，随着机器人的运动捕捉羽毛球。但这会引入新的挑战：机器人的有限体积会限制双目相机的基线距离和视野范围，进而影响三维建模的深度探测范围。机器人追逐球的高速运动会造成图像的震荡和剧烈变化，为二维检测带来更大的难题。

中国知网 https://www.cnki.net

（2）系统的限制。本文对系统的性能评估依赖于 NVIDIA GeForce RTX 3090 GPU，该版本的 GPU，性能会高于常用的移动性设备。虽然本文对模型进行了加速操作，但是还可以针对移动型设备的特性进一步优化，使其在嵌入式移动设备上展示更优越的表现。

（3）数据集的限制。受限于环境，本文制作的自有数据集仅包含了 10 个不同场地或环境，共计图像 32539 张。未来应该在更多样化的场景下（如多观众、广告位等）补充数据集，以模拟真实羽毛球对打的应用场景。

（4）其他球类运动的迁移。相对于网球、乒乓球等高速移动的小球类运动来说，羽毛球的姿态最为多变，颜色最易受干扰。因此，未来可以增加该系统对于网球、乒乓球等其他球类运动的性能测试，来检测本文解决方案的鲁棒性。

中国知网 https://www.cnki.net

参考文献

[1] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[2] 王智悦, 于清, 王楠, 等. 基于知识图谱的智能问答研究综述[J]. Journal of Computer Engineering & Applications, 2020, 56(23).

[3] 万小军, 冯岩松, 孙薇薇. 文本自动生成研究进展与趋势[J]. 中国计算机学会. CCF2014-2015 中国计算机科学技术发展报告会论文集, 2015: 298-323.

[4] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. Annual review of biomedical engineering, 2017, 19(1): 221-248.

[5] Xing F, Xie Y, Su H, et al. Deep learning in microscopy image analysis: A survey[J]. IEEE transactions on neural networks and learning systems, 2017, 29(10): 4550-4568.

[6] 吴沛宸, 袁立宁, 郭放, 等. 视频异常行为检测综述[J]. Journal of Frontiers of Computer Science & Technology, 2024, 18(12).

[7] Wang Y, Wu H, Dong J, et al. Deep time series models: A comprehensive survey and benchmark[J]. arXiv preprint arXiv:2407.13278, 2024.

[8] Redmon J. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.

[9] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

[10] Farhadi A, Redmon J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition. Berlin/Heidelberg, Germany: Springer, 2018, 1804: 1-6.

[11] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[12] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[13] Wang C Y, Yeh I H, Mark Liao H Y. Yolov9: Learning what you want to learn using programmable gradient information[C]//European Conference on Computer Vision. Springer, Cham, 2025: 1-21.

[14] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. arXiv preprint arXiv:2405.14458, 2024.

[15] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.

中国知网 https://www.cnki.net

[16] Deepa M D. Bidirectional encoder representations from transformers (BERT) language model for sentiment analysis task[J]. Turkish Journal of Computer and Mathematics Education (TURCOMAT), 2021, 12(7): 1708-1721.

[17] Vaswani A. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017.

[18] 吴强. 鹰眼系统在职业网球比赛的应用效果及其影响研究[D]. 首都体育学院, 2019.

[19] 周义顺. 2018 年俄罗斯世界杯 VAR 系统介入裁判判罚的实证研究[D]. 鲁东大学, 2021.

[20] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. nature, 2016, 529(7587): 484-489.

[21] Wurman P, Barrett S, Sony A I, et al. Training Champion-level Race Car Drivers Using Deep Reinforcement Learning[J].

[22] Yang F, Shi Z, Ye S, et al. Varsm: Versatile autonomous racquet sports machine[C]//2022 ACM/IEEE 13th International Conference on Cyber-Physical Systems (ICCPS). IEEE, 2022: 203-214.

[23] Zhou X, Wang D, Krähenbühl P. Objects as points[J]. arXiv preprint arXiv:1904.07850, 2019.

[24] Voeikov R, Falaleev N, Baikulov R. TTNet: Real-time temporal and spatial video analysis of table tennis[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 884-885.

[25] Sun N E, Lin Y C, Chuang S P, et al. Tracknetv2: Efficient shuttlecock tracking network[C]//2020 International Conference on Pervasive Artificial Intelligence (ICPAI). IEEE, 2020: 86-91.

[26] Tarashima S, Haq M A, Wang Y, et al. Widely Applicable Strong Baseline for Sports Ball Detection and Tracking[J]. arXiv preprint arXiv:2311.05237, 2023.

[27] Cheng G, Yuan X, Yao X, et al. Towards large-scale small object detection: Survey and benchmarks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023.

[28] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer International Publishing, 2015: 234-241.

[29] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 5693-5703.

中国知网 https://www.cnki.net

[30]He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.

[31]Wu D, Xiao A. Deep learning-based algorithm for recognizing tennis balls[J]. Applied Sciences, 2022, 12(23): 12116.

[32]Howard A G. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.

[33]Li W, Liu X, An K, et al. Table tennis track detection based on temporal feature multiplexing network[J]. Sensors, 2023, 23(3): 1726.

[34]Welch G. An Introduction to the Kalman Filter[J]. 1995.

[35]Zhang T, Zhang X, Yang Y, et al. Efficient golf ball detection and tracking based on convolutional neural networks and kalman filter[J]. arXiv preprint arXiv:2012.09393, 2020.

[36]Dosovitskiy A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[37]Yu J, Liu Y, Wei H, et al. Towards Highly Effective Moving Tiny Ball Tracking via Vision Transformer[C]//International Conference on Intelligent Computing. Singapore: Springer Nature Singapore, 2024: 368-379.

[38]Chao V, Nguyen H Q, Jamsrandorj A, et al. Tracking the Blur: Accurate Ball Trajectory Detection in Broadcast Sports Videos[C]//Proceedings of the 7th ACM International Workshop on Multimedia Content Analysis in Sports. 2024: 41-49.

[39]Kim H, Choi H J, Kim C J, et al. Ball trajectory inference from multi-agent sports contexts using set transformer and hierarchical bi-LSTM[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 4296-4307.

[40]Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]//Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001. Ieee, 2001, 1: I-I.

[41]Felzenszwalb P, McAllester D, Ramanan D. A discriminatively trained, multiscale, deformable part model[C]//2008 IEEE conference on computer vision and pattern recognition. Ieee, 2008: 1-8.

[42]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.

[43]Uijlings J R R, Van De Sande K E A, Gevers T, et al. Selective search for object recognition[J]. International journal of computer vision, 2013, 104: 154-171.

中国知网 https://www.cnki.net

[44] Zou Z, Chen K, Shi Z, et al. Object detection in 20 years: A survey[J]. Proceedings of the IEEE, 2023, 111(3): 257-276.

[45] Grauman K, Darrell T. The pyramid match kernel: Discriminative classification with sets of image features[C]//Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1. IEEE, 2005, 2: 1458-1465.

[46] Girshick R. Fast r-cnn[J]. arXiv preprint arXiv:1504.08083, 2015.

[47] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[48] Dai J, Li Y, He K, et al. R-fcn: Object detection via region-based fully convolutional networks[J]. Advances in neural information processing systems, 2016, 29.

[49] Li Z, Peng C, Yu G, et al. Light-head r-cnn: In defense of two-stage object detector[J]. arXiv preprint arXiv:1711.07264, 2017.

[50] Ross T Y, Dollár G. Focal loss for dense object detection[C]//proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2980-2988.

[51] Zhu X, Su W, Lu L, et al. Deformable detr: Deformable transformers for end-to-end object detection[J]. arXiv preprint arXiv:2010.04159, 2020.

[52] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.

[53] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[54] Dai S, Zhu Y, Jiang X, et al. TD-Net: Trans-Deformer network for automatic pancreas segmentation[J]. Neurocomputing, 2023, 517: 279-293.

[55] Yang J, Tu J, Zhang X, et al. TSE DeepLab: An efficient visual transformer for medical image segmentation[J]. Biomedical Signal Processing and Control, 2023, 80: 104376.

[56] Chen X, Wang H, Ni B. X-volution: On the unification of convolution and self-attention[J]. arXiv preprint arXiv:2106.02253, 2021.

[57] Li K, Wang Y, Zhang J, et al. Uniformer: Unifying convolution and self-attention for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(10): 12581-12600.

[58] Zhang Z. Flexible camera calibration by viewing a plane from unknown orientations[C]//Proceedings of the seventh ieee international conference on computer vision. Ieee, 1999, 1: 666-673.

中国知网 https://www.cnki.net

[59]Zeller, Cyril, and Olivier Faugeras. *Camera self-calibration from video sequences: the Kruppa equations revisited.* Diss. INRIA, 1996.

[60]Hirschmuller H. Stereo processing by semiglobal matching and mutual information[J]. IEEE Transactions on pattern analysis and machine intelligence, 2007, 30(2): 328-341.

[61]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.

[62]Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[63]Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great again[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13733-13742.

[64]Li Y, Yao T, Pan Y, et al. Contextual transformer networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(2): 1489-1500.

[65]Li X, Hu X, Yang J. Spatial group-wise enhance: Improving semantic feature learning in convolutional networks[J]. arXiv preprint arXiv:1905.09646, 2019.

[66]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[67]Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.

[68]Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.

[69]Ioffe S. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.

[70]Elfwing S, Uchibe E, Doya K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural networks, 2018, 107: 3-11.

[71]Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.

[72]Li H, Xiong P, An J, et al. Pyramid attention network for semantic segmentation[J]. arXiv preprint arXiv:1805.10180, 2018.

[73]Sabour S, Frosst N, Hinton G E. Dynamic routing between capsules[J]. Advances in neural information processing systems, 2017, 30.

中国知网 https://www.cnki.net

[74] Pei J, Wu X, Liu X, et al. SGD-YOLOv5: A Small Object Detection Model for Complex Industrial Environments[C]//2024 International Joint Conference on Neural Networks (IJCNN). IEEE, 2024: 1-10.

[75] Li X, Wang W, Wu L, et al. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection[J]. Advances in Neural Information Processing Systems, 2020, 33: 21002-21012.

[76] Myung I J. Tutorial on maximum likelihood estimation[J]. Journal of mathematical Psychology, 2003, 47(1): 90-100.

[77] Chen Y J, Wang Y S. Tracknetv3: Enhancing shuttlecock tracking with augmentations and trajectory rectification[C]//Proceedings of the 5th ACM International Conference on Multimedia in Asia. 2023: 1-7.

[78] Smith A R. Color gamut transform pairs[J]. ACM Siggraph Computer Graphics, 1978, 12(3): 12-19.

[79] Hegazy H, Abdelsalam M, Hussien M, et al. Online detection and classification of in-corrected played strokes in table tennis using IR depth camera[J]. Procedia Computer Science, 2020, 170: 555-562.

[80] Renò V, Mosca N, Nitti M, et al. Real-time tracking of a tennis ball by combining 3d data and domain knowledge[C]//2016 1st International Conference on Technology and Innovation in Sports, Health and Wellbeing (TISHW). IEEE, 2016: 1-7.

[81] Tebbe J, Klamt L, Gao Y, et al. Spin detection in robotic table tennis[C]//2020 IEEE international conference on robotics and automation (ICRA). IEEE, 2020: 9694-9700.

[82] Moazzen S M A, Ahmadi A. 3D simulation of tennis game using learning algorithms by application of virtual reality[C]//2017 Iranian Conference on Electrical Engineering (ICEE). IEEE, 2017: 1527-1531.

[83] Lu M, Wu B, Yang X, et al. Benign Oscillation of Stochastic Gradient Descent with Large Learning Rates[J]. arXiv preprint arXiv:2310.17074, 2023.

[84] Wang S, Wang H, She S, et al. Swin-T-NFC CRFs: An encoder–decoder neural model for high-precision UAV positioning via point cloud super resolution and image semantic segmentation[J]. Computer Communications, 2023, 197: 52-60.

[85] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[86] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 807-814.

中国知网 https://www.cnki.net