羽毛球击球帧检测算法研究

重庆大学硕士学位论文

（学术学位）

学生姓名：郜深阵

指导教师：薛方正　教授

学科门类：工学

学科名称：控制科学与工程

研究方向：计算机视觉

答辩委员会主席：王智慧　教授

授位时间：2024 年 6 月

中国知网　https://www.cnki.net

Research on Frame Detection Algorithm of Badminton Shot

A thesis submitted to Chongqing University

in partial fulfillment of the requirement

for the degree of

Master of Science

in

Control Science and Engineering

by

Shenzhen Gao

Supervisor: Prof. Fangzhen Xue

June , 2024

中国知网 https://www.cnki.net

摘　要

击球帧是指羽毛球运动中球员击打羽毛球并改变其飞行方向的视频帧，是智能化羽毛球分析系统所需的必要信息。它包含运动员的击球位置与击球动作、羽毛球落地点与击球点等数据，对羽毛球击球方式识别和技战术策略制定等下游任务至关重要。然而，目前仍旧缺乏一种能够自动获取羽毛球击球帧的算法。羽毛球检测是羽毛球击球帧检测的基础，并以运动员姿态作为辅助。但是，现有羽毛球检测算法检测精度不高，同时算法计算量大、复杂度高，对计算设备要求高。本文旨在研究智能化羽毛球分析系统中的羽毛球数据获取方法，重点关注羽毛球击球帧检测这一具体问题，并同时对其前置任务羽毛球检测和人体姿态估计进行研究，以促进羽毛球运动的智能化发展。

针对羽毛球图像特点和现有检测算法局限，本文设计了一种有效的端到端深度网络结构，完成在检测精度、计算量和模型复杂度达到综合平衡的羽毛球检测算法，并以此为基础完成羽毛球击球帧检测算法的设计。最后通过实验验证了算法的有效性。论文主要研究工作如下：

（1）本文提出一种高精度轻量化羽毛球检测算法，实现端到端的实时高精度羽毛球检测。主要工作如下：①设计了一个轻量化特征提取模块。本文采用更轻量化的部分卷积（Partial Convolution，PConv）作为核心卷积模块，引入结构重参数化和高效多尺度注意力（Efficient Multi-Scale Attention，EMA），设计了一个轻量化特征提取模块。②提出了一个轻量化的多尺度特征融合模块。针对模型上/下采样方式单一提供特征不足的问题，本文提出了注意力双分支并行上/下采样模块，并且设计了一个轻量化的并行空洞卷积特征提取模块。在此基础上，实现串行的跨层连接和并行多分支结构结合，扩充了特征提取的途径，从而提高模型的表征能力。③优化边界框损失函数的计算方法。针对羽毛球小目标特点，本文结合 MPD-IoU 与 Inner-IoU 改进了边界框损失函数的计算方法，以提高小目标对网络损失的贡献，从而提升检测精度。在羽毛球数据集上实验表明，本文提出的算法在预测精度、速度与模型复杂度等性能综合考虑下表现最优。

（2）本文提出一种羽毛球击球帧识别算法。算法主要工作如下：①优化了 YOLO-Pose 关键点检测算法，提高算法检测的精度。针对 YOLO-Pose 采用的通道拼接多尺度特征融合方式无法区分不同尺度特征对检测的贡献问题，本文引入了加权双向特征金字塔网络，并对其特征融合方式做进一步研究，引入语义与细节融合模块（semantics and detail fusion，SDI），提升多尺度特征融合的效果。②提出一种羽毛球击球帧识别算法。本文结合羽毛球姿态和运动员姿态信息进行击球帧

中国知网 https://www.cnki.net

检测设计，并基于检测结果重现羽毛球轨迹。在公开数据集和羽毛球数据集上验证了本文提出算法的有效性。

关键词：羽毛球检测；多尺度特征融合；击球帧；轻量化

中国知网 https://www.cnki.net

Abstract

Shot frame refers to the video frame of players hitting the badminton and changing its flight direction, which is the necessary information for the intelligent badminton analysis system. It contains the player's hitting position and hitting action, badminton landing place and hitting point and other data, which is very important for the downstream tasks such as the identification of badminton hitting mode and the formulation of technical tactics and strategies. However, there is still a lack of an algorithm that can automatically obtain the badminton shot frame. Badminton detection is the basis of badminton shot frame detection, and it is assisted by player posture. However, the accuracy of existing badminton detection algorithms is not high, and the calculation amount and complexity of algorithms are large, which requires high computing equipment. This thesis aims to study the badminton data acquisition method in the intelligent badminton analysis system, focusing on the specific problem of the frame detection of the badminton shot, and at the same time, the study of its pre-task badminton detection and human posture estimation, in order to promote the intelligent development of badminton.

In view of the characteristics of badminton images and the limitations of existing algorithms, this thesis designs an effective end-to-end deep network structure to complete the badminton detection algorithm that achieves a comprehensive balance in detection accuracy, calculation amount and model complexity, and completes the design of the badminton shot frame detection algorithm on this basis. Finally, the effectiveness of the algorithm is verified by experiments. The main research work of this thesis is as follows: (1) This thesis proposes a high-precision lightweight badminton detection algorithm to achieve end-to-end real-time high-precision badminton detection. The main work is as follows: ① a lightweight feature extraction module is designed. In this thesis, Partial Convolution (PConv) is adopted as the core convolutional module, and structural heavy parameterization and Efficient Multi-Scale Attention (EMA) are introduced to design a lightweight feature extraction module. ② A lightweight multi-scale feature fusion module is proposed. In order to solve the problem of insufficient features provided by single up/down sampling mode, this thesis proposes an attention double-branch parallel up/down sampling module, and designs a lightweight parallel void-convolution feature extraction module. On this basis, serial cross-layer connection and parallel multi-branch structure combination are realized, which expands the way of feature extraction and

中国知网 https://www.cnki.net

improves the representation ability of the model. ③ Optimize the calculation method of boundary frame loss function. According to the characteristics of badminton small target, this thesis combines MPD-IoU and Inner-IoU to improve the calculation method of boundary frame loss function, so as to increase the contribution of small target to network loss and improve the detection accuracy. Experiments on badminton data show that the proposed algorithm performs best under the comprehensive consideration of prediction accuracy, speed and model complexity.

(2) In this thesis, an algorithm for frame recognition of badminton shots is proposed. The main work of the algorithm is as follows: ① The YOLO-Pose key point detection algorithm is optimized to improve the detection accuracy of the algorithm. Aiming at the problem that the channel splicing multi-scale feature fusion method adopted by YOLO-Pose cannot distinguish the contribution of different scale features to detection, this thesis introduces the weighted bidirectional feature pyramid network, and further studies its feature fusion mode, introducing semantics and detail fusion, semantics and detail fusion (SDI) to improve the effect of multi-scale feature fusion. ② A badminton frame recognition algorithm is proposed. This thesis combines the information of badminton posture and player posture to detect the shot frame, and reproduces the trajectory of badminton based on the detection results. The effectiveness of the proposed algorithm is verified on the open data set and badminton data set.

Keywords: Badminton detection; Multi-scale feature fusion; Badminton shot; Lightweight

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 羽毛球检测国内外研究现状.....3
1.2.2 小目标检测国内外研究现状.....4
1.2.3 姿态估计国内外研究现状.....6
1.3 本文主要研究内容.....7
1.4 本文组织架构.....9
2 问题分析及相关理论基础.....11
2.1 问题研究.....11
2.1.1 问题分析.....11
2.1.2 难点分析.....13
2.1.3 算法选择.....14
2.2 相关理论基础.....15
2.2.1 相关算法基础.....16
2.2.2 数据集与评价指标.....23
2.3 本章小结.....26
3 基于 RT-DETR 的羽毛球检测算法研究.....28
3.1 RT-DETR 网络.....28
3.2 特征提取网络优化.....29
3.2.1 卷积操作分析与选择.....29
3.2.2 结构重参数化.....30
3.2.3 轻量化注意力机制.....32
3.2.4 轻量化 PREMA$_B$locks 卷积模块.....34
3.3 基于注意力机制的并行多尺度特征提取与融合结构设计.....35
3.3.1 注意力双分支并行上采样模块.....35
3.3.2 注意力双分支并行下采样模块.....37
3.3.3 并行空洞卷积特征提取模块.....38
3.3.4 并行多分支多特征提取与融合网络.....39
3.4 小目标检测层.....40
3.5 损失函数优化.....41
3.6 实验与分析.....42
3.6.1 实验环境与参数设置.....42
3.6.2 损失函数超参数实验.....43

中国知网 https://www.cnki.net

3.6.3 对比实验.....44
3.6.4 消融实验.....46
3.7 本章小结.....46
4 基于 YOLO-Pose 的运动员姿态估计算法.....48
4.1 基准模型选择.....48
4.2 YOLO-Pose 网络.....49
4.3 多尺度特征融合方式优化.....52
4.3.1 加权双向特征金字塔网络.....52
4.3.2 特征融合方式研究.....53
4.4 实验与分析.....55
4.4.1 数据集与评价指标.....55
4.4.2 试验环境与参数设置.....55
4.4.3 对比试验.....56
4.4.4 消融实验.....56
4.5 本章小结.....57
5 基于羽毛球与运动员信息的击球帧检测算法.....58
5.1 任务分析与方案设计.....58
5.2 羽毛球击球帧检测算法研究.....60
5.3 实验与分析.....61
5.4 本章小结.....62
6 结论与展望.....64
6.1 结论.....64
6.2 展望.....65
参考文献.....66

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

羽毛球是一个适合所有年龄段人的运动，它以上手简单、娱乐性强和对场地要求低的特点深受广大民众喜爱。根据《中国羽毛球市场分析报告》显示，我国羽毛球参与运动人数超过 2.5 亿，是我国体育运动的重点项目之一。在大数据时代下，智能化体育分析系统常用来做运动分析，对运动员比赛风格、比赛习惯等进行总结，以提高运动员们的竞技水平。目前，智能化体育分析系统已经在部分运动领域投入使用，如图 1.1 为 swing vision 公司设计的网球可视化分析系统。

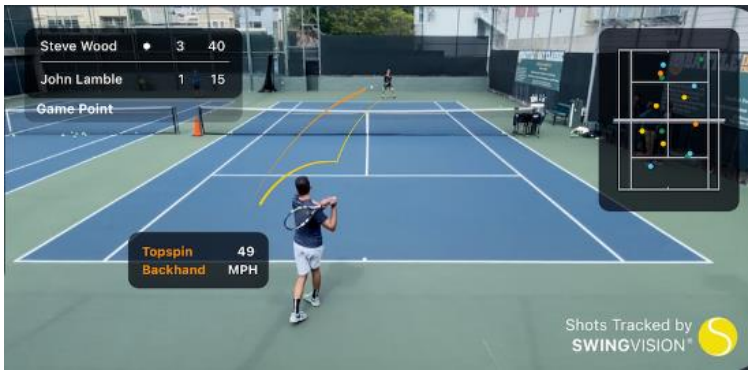


图 1.1 swing vision 网球可视化分析系统

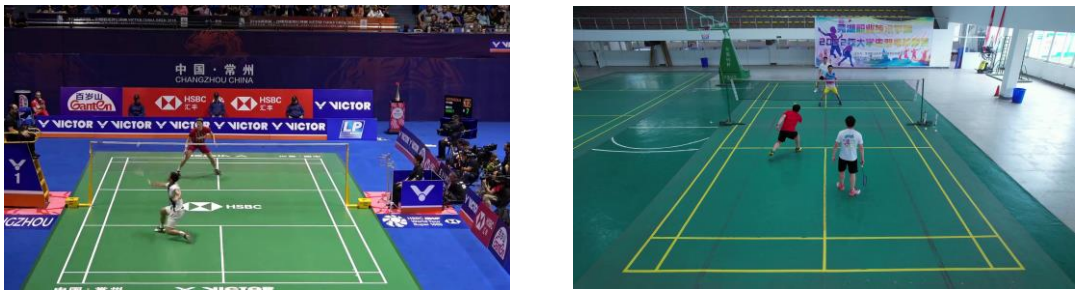
Fig.1.1 swing vision tennis visual analysis system

尽管智能化羽毛球分析系统备受关注，但是相关研究尚显有限，且这些研究成果几乎未投入实际应用。随着羽毛球运动越来越受欢迎，民众对智能化羽毛球系统的需求也日益增加。但是，至今智能化羽毛球分析系统仍旧没有一个较好的解决方法。目前，已投入使用的智能化羽毛球分析系统很少且较难获取，如“鹰眼[1]”。但鹰眼系统所需设备价格高昂，普通人无法承担，并且数据不公开，因此无法普及。

智能化羽毛球分析系统面临的主要难题是如何低成本获取羽毛球数据。智能化羽毛球分析系统需要的数据包括羽毛球轨迹、击球点、落地点等，运动员击球位置、击球动作等。击球帧是指羽毛球运动中球员击打羽毛球并改变其飞行方向的视频帧，是获取上述羽毛球数据的关键。它包含着运动员的击球位置、击球动作与羽毛球的落地点、击球点等信息，是羽毛球轨迹划分的信号。目前，智能化羽毛球分析系统常用的数据获取方式为人工获取或鹰眼系统，它们需要投入大量的人员、时间、金钱成本，这显然是无法满足大众需求。因此，采用易获取的羽毛球视频数，如比赛中保留的大量比赛视频以及个人采集视频数据（如图 1.2 所示），通过智能化手段进行羽毛球数据获取，是一种更为科学且实用的方法。在这个过程中，击球

中国知网 https://www.cnki.net

帧检测不可缺少的一环，但目前尚缺乏一种自动从原始视频中获取羽毛球击球帧的方法。



（a）羽毛球比赛数据示例 （b）个人采集数据示例

图 1.2 羽毛球图像数据示例

Fi.1.2 Example of badminton image data

羽毛球击球帧的检测离不开羽毛球检测和运动员姿态估计检测算法。①对于羽毛球检测来说，目前仍旧缺少高精度且对计算设备要求低的羽毛球检测算法。羽毛球检测面临的主要挑战源自其图像特性主要难度来自其自身图像的特点。羽毛球的体积小、纹理简单、外观特征不明显，同时其运动速度快（可达每小时数百公里）、运动背景复杂，导致羽毛球在图像呈现微小、模糊、形变严重、拖尾等特性，使得检测更加困难。由于上述的羽毛球图像问题，经典检测算法在羽毛球检测任务上是失效或者使用条件极其苛刻的[2]。随着深度学习的崛起，神经网络可以自主提取复杂的特征实现物体的检测，在很多领域中有着优秀的表现，利用神经网络进行羽毛球检测是一种比较具有潜力的方法。②高精度且对计算设备要求低的运动员姿态估计算法同样是羽毛球击球帧检测的关键。击球帧是运动员击打羽毛球改变其方向的时刻，利用运动员姿态作为辅助信息能更准确的获取羽毛球击球帧。

综上所述，目前智能化羽毛球分析系统缺乏一种面向羽毛球击球帧检测算法。本文拟对羽毛球检测和运动员姿态估计算法进行研究，并设计一种羽毛球击球帧检测算法，促进下游应用发展，如击球方式识别、运动识别和技战术策略制定等，以满足智能化羽毛球分析系统对羽毛球数据获取的部分需求。

1.2 国内外研究现状

近些年，深度学习的研究取得了瞩目的成果，并在生产生活中得到广泛的应用，在体育分析领域的研究也日益增多且硕果累累。然而，足球和网球等其他球类运动相比，羽毛球尚未享受到最新的深度学习进展带来的福利。本文旨在研究智能化羽毛球分析系统中的羽毛球数据获取方法，重点关注羽毛球击球帧检测这一具体问题，并同时对其前置任务羽毛球检测和关键点检测进行研究，以促进羽毛球运动的

中国知网 https://www.cnki.net

智能化发展。基于此本文从羽毛球检测、人体姿态估计的国内外研究成果进行研究分析；同时，从羽毛球小目标的特点出发，对现有的小目标检测研究成果进行研究分析，以探究一种更优秀的算法方法。

1.2.1 羽毛球检测国内外研究现状

羽毛球外观特征简单、体积小，整体是一个不规则的球体，并且比赛中的羽毛球飞行速度很快（最快可达 400 多千米/小时）、运动范围大、背景复杂，导致羽毛球图像存在微小且模糊、特征少、多尺度和拖尾严重等问题，如图 1.3 所示。准确检测和定位一个高速运动且微小的羽毛球是一项非常具有挑战性的工作。



图 1.3 羽毛球图像的部分特点

Fig.1.3 Some features of badminton images

在羽毛球检测研究初期，研究人员便利用传统图像处理方法进行羽毛球检测，如背景减除法、帧差法、光流法等。Watanabe H 等人[3]采用背景减除法识别运动羽毛球。胡景新等人[4]通过背景减除法分割背景与前景，计算目标区域的中心点作为羽毛球位置。但算法实时性与精度不高。赵军[5]使用三帧差分算法区分前景与背景，结合光流法获取羽毛球位置。光流法的使用虽然在一定程度上改善了背景簇问题，但运算效率不高，对硬件性能要求高。王恺睿[6]提出基于奇异值分解的自适应混合高斯模型，通过模板匹配算法检测羽毛球，提升了对运动羽毛球检测的精度。Kalsotra 等人[7]提出一种基于形态学操作与背景减除法的目标检测算法，通过背景减除法区分背景与前景，同时利用膨胀、腐蚀等形态学操作，获取目标的完整轮廓，实现目标的检测。但形态学操作计算量大，算法的实时性不高。基于传统图像处理的高速运动小球检测受到许多假设的限制，例如线性轨迹、高对比度和无遮挡等，同时算法的计算效率不高，实时性受限。

近几年，越来越多的研究人员利用卷积神经网络（Convolutional Neural Networks，CNN）进行运动分析并且获得了优异的效果。Kamble 等人[8]利用神经

中国知网 https://www.cnki.net

网络检测足球比赛视频中的足球、球员和背景。Komorowski 等人[9]利用卷积神经网络提取图像中的特征，通过融合多尺度中间特征图来生成足球位置的热力图，实现足球的检测的追踪。但以上两种算法并未针对羽毛球检测任务进行设计，同时受到诸多的限制，如无遮挡等，因此在羽毛球检测上效果不佳。Huang 等人[10]设计一种基于热力图的高速小球运动检测算法 TrackNet，用于追踪广播视角比赛视频中的网球和羽毛球等高速小球。该算法利用多个连续帧取代单帧图像作为输入来克服图像模糊问题，使用 VGG16[11]特征提取网络从多个连续图像提取高速小球特征，然后通过上采样网络[12]生成球中心位置分布概率的热力图。但该网络在速度更快、图像更模糊的羽毛球上的表现不如网球。Huang 等人[13]针对羽毛球特点再次改进了 Tracknet 得到 TrackNetV2，算法引入了跳跃连接同时将 Tracknet 的多输入单输出设计改进为多输入多输出设计，在处理速度、预测精度等方面大幅提高 TrackNet 的性能。Liu 等人[14]采用基于 Dice 损失和二元交叉熵损失的组合损失，并且引入了残差结构再次改进了 TrackNetV2，使得模型参数量更小，同时检测精度更高。

利用传统图像处理方法进行羽毛球检测受到许多假设的限制，例如线性轨迹、高对比度和无遮挡等，在面对复杂的羽毛球比赛场景，这些假设很难满足。目前基于深度学习的羽毛球检测算法需要算力较高，只能在高算力设备上进行部署，且精度上仍旧有提升空间。

1.2.2 小目标检测国内外研究现状

小目标通常指分辨率小于 32 像素×32 像素的目标，运动比赛图像中的羽毛球绝大多数都属于小目标的范畴。由于视觉特征较差、噪声较多等问题，小目标检测现已成为计算机视觉中最具有挑战性的任务之一。即使是 SOTA 网络，在检测小目标和正常尺寸目标方面也存在巨大的性能差距。以 YOLOv8[15]为例，在 COCO 数据集上，该算法在小物体上的平均精度(AP，Average Precision)仅有 35.3%，而在中、大物体上则可以达到 58.3%和 69.8%。目前针对小目标检测方法可以分为基于多尺度特征学习的方法、改进正负样本匹配机制的方法和基于注意力的方法。

基于多尺度特征学习的方法。此类方法通过融合高层语义信息和低层位置信息提高模型的表征能力，增强模型对小目标的检测效果。此方法主要有两种结构：一种是串行的跨层连接结构，另一种是并行多分支网络结构。串行的跨层连接首先对多个尺度的特征进行上采样，然后通过跨层连接实现特征融合。Lin 等人提出的 FPN（Feature Pyramid network）[16]是多尺度特征学习的经典结构, 网络经过自下而上的特征提取之后，引入自上而下的结构，融合相邻层的特征进行预测，从而提高检测的精度。受 FPN 中交互设计的启发，PANet[17]通过双向路径丰富了特征层次结构。在上述的特征提取于自上而下路径传递语义信息后，PANet 添加了一条自下向上的路径，用于传递低层的位置信息，增强高层特征的位置信息。后续学者在此

中国知网 https://www.cnki.net

基础上继续进行改进，如 NAS-FPN[18]、BiFPN[19]和递归特征金字塔[20]（Recursive-FPN），提升检测的效果。并行多分支网络结构通过多分支实现多尺度，代表网络有 SPP[21]等算法。SPP 通过将特征图分成不同尺度的 N×N 子块并行在每个子块上面进行最大池化操作实现多尺度特征的提取与融合。Li 等人[22]通过设计并行的子网来实现多尺度预测。一个子网专门用于检测大尺度目标，另一个则专注于学习小尺寸特征，以便检测小目标。Li 等人[23]构建一个拥有并行的多分支架构的算法 TridentNet，算法在同一个特征图上面利用不同空洞率的共享参数的空洞卷积并行捕获不同尺寸特征，对目标进行检测。多尺度特征学习的方法虽然可以提高检测精度，但是由于增加了更多的参数和计算量，会减慢模型推理的速度。

改进正负样本匹配机制的方法。小目标边框的容忍度低，一个微小的扰动可能都会导致小目标超出边框。此外，v。因此，改进正负样本匹配机制的方法通过提高小目标 IoU，提升小目标对损失的贡献，从而使更多小目标样本被分为正样本，进而提高检测效果。Redmon 等人[24]发现，相比大目标，小目标更易受到随机误差的影响。因此，他们提出一种基于目标尺寸设定不同权重的损失函数，以提升小目标检测性能。针对小目标存在前景与背景不均衡问题，Deng 等人[25]提出了一种考虑前景-背景之间平衡的损失函数，通过全局重建损失和正样本区域（Positive patch loss）损失提高前景与背景的特征质量，进而提升了小目标检测的性能。Inner-IoU[26]利用辅助边框改善边框回归泛化性不足的问题，通过尺度因子 ratio＞0 调节辅助边框大小，改善小目标回归效果。NWD[27]使用 Wasserstein 距离来测量边界框的相似性，降低 IOU 对小目标的敏感性，并且可以度量重叠目标的相似性，提高小目标和密集目标检测的效果。通过改进正负样本匹配机制，提升小目标对网络损失的贡献，是提升小目标检测精度的一种有效途径。

基于注意力的方法。注意力机制通过借鉴人类的认知机制，对特征图不同部分分配不同的权重，以突出图像中的重要区域，同时抑制不必要的区域。基于注意力机制的方法通过筛选特征中关于小目标的部分特征并抑制背景和噪声区域，增强小目标的特征表达，提升检测的效果。SCRDet[28]通过引入像素注意力和通道注意力设计一个目标检测器，其中像素注意力和通道注意力以监督方式进行训练，以突出显示小目标区域，同时消除噪声的干扰，提高小目标检测效果。Lu 等人[29]设计双路径模块来突出小物体的关键特征并抑制非物体信息，并通过提出的增强通道注意（ECA）块替换复杂的卷积组件，抑制背景干扰，提升小目标检测效果。Carion 等人[30]基于 Transformer 构建了一种端到端的检测网络 DETR，将检测问题转换成集合预测问题，采用一种基于集合的全局损失通过二分匹配实现检测。DETR 在视频和图像检测中表现良好，但网络收敛速度慢。Zhu 等人[31]认为只需要关注目标周围的小部分像素便可以实现特征有效提取，利用提出的多尺度可变形注意模块提

中国知网 https://www.cnki.net

高空间分辨率，使得算法不需要特征金字塔网络，便实现小目标的检测性能的提高。Dai 等人[32]提出的 Dynamic DETR 是 DETR 的另一个变体，算法具有动态编码器和动态解码器，利用从低到高分辨率表示的特征金字塔，实现从粗到细的目标检测，且模型收敛速度更快。虽然基于注意力的方法在小目标检测上取得了巨大的进步，但是算法效果的提升需要以大量计算开销为代价，导致实时性的下降和计算设备成本的增加。

1.2.3 姿态估计国内外研究现状

人体姿态估计是计算机视觉领域的重要任务之一，用来识别和定位人体关节的位置。传统的人体姿态估计主要使用基于图结构模型的方法，将人体简化为简笔画获取人体姿态结构。最近，深度学习在人体姿态估计领域的应用取得了重大突破，显著提升了姿态估计的性能。2D 人体姿态估计根据人数可以分为 2D 单人姿态估计和 2D 多人姿态估计。

2D 单人姿态估计是用于对单人图像时进行人体关节点定位的算法。Toshev 等人[33]首次在姿态估计中引入级联深度神经网络，提出了 DeepPose 算法，用于从图像中学习关键点。从此人体姿态估计进入了深度学习的阶段。Sun 等人[34]基于 ResNet-50 提出了结构感知回归方法并更改表示方法，采用基于人体信息和骨骼的表示，实现比仅使用关节位置更稳定的结果。Newell 等人[35]提出了一种形似沙漏的网络进行姿态估计，网络串联多个“沙漏网络”，同时引入中间监督的训练方式，捕获多尺度特征进行姿态识别。Sun 等人[36]提出了一种高分辨率网络 HRNet，通过并行连接和融合从高分辨率到低分辨率的网络分支来保持高分辨率，从而实现更准确的关节点热力图预测。Yu 等人[37]在 HRNet 基础上提出了更轻量级网络 Lite-HRNet，设计了一个条件通道加权块（contidional channel weighting）替代 1×1 卷积，以提高网络的计算效率并保持高性能。

2D 多人姿态估计需要确定人员的数量和位置，同时针对不同的人对关节点进行分组。2D 多人姿态算法主要分为了自上而下和自下而上两种方式。

（1）**自上而下**的算法，首先使用人体检测模型进行人体检测，然后再对检测出来的人体进行单人姿态估计，如图 1.4 所示。针对姿态估计问题，Su 等人[38]提出了通道随机模块（Channel Shuffle Module）和空间与通道注意瓶颈模块（Spatial Channel-wise Attention Residual Bottleneck），以实现通道与空间信息增强，从而克服遮挡问题实现较好的姿态识别性能。Qiu 等人[39]认为遮挡关节点和图像与人体姿态结构密切相关，提出综合考虑图像内容和人体姿态的渐进 GCN 模块（Image-Guided Progressive GCN module）解决多人姿势估计中的遮挡问题。Yang 等人[40]提出了一种基于 Transformer 的人体姿态估计模型 TransPose，利用注意力机制来预测基于热图的关键点位置，学习遮挡场景中人体姿态的细粒度信息。自上而下方法的

中国知网 https://www.cnki.net

复杂性随着图像中人数的增加而线性增加，因此该方法不仅算法复杂，同时其运行时间是也是多变的。

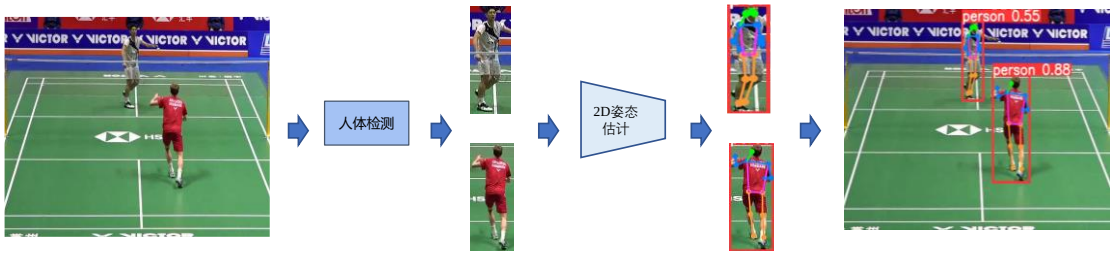


图 1.4 自上而下的多人姿态估计

Fig.1.4 Top-down multi-person pose estimation

（2）相比之下，自下而上的方法可以保证检测时间的不变性。现有的自下而上的方法大多是基于热力图的方法。首先基于热力图方法检测人体关键点，然后利用人体关键点之间的联系组合成一个完整的人，完成姿态估计，如图 1.5 所示。Cao 等人[41]提出了 OpenPose 模型，它使用 CPM（Convolutional Pose Machines）[42]方式进行关键点检测，通过热图和亲和场（PAF，Part Affinity Fields，一组带有向量图的二维向量场，用来预测关键点坐标，其中向量图编码肢体的位置和方向）将关键点与每个人相关联，实现多人人体姿态估计。Pishchulin 等人[43]提出了一种基于 Fast R-CNN 的人体姿态估计算法 DeepCut，该算法首先提取图片中的肢体候选区域，然后将候选区域转化为一个关节点并进行部位分类，最后使用整数线性规划（ILP，Integer Linear Programming）将这些部位组装成完整的人体姿势，但算法计算成本较高。自下而上方法需要一些后处理如像素级的 NMS、分组等，这些后处理会降低热图的细粒度，导致无法区分相近关键点。



图 1.5 自下而下的多人姿态估计

Fig.1.5 Multi-person pose estimation from the bottom to down

1.3 本文主要研究内容

本文旨在研究智能化羽毛球分析系统中的羽毛球数据获取方法，重点关注羽毛球击球帧检测这一具体问题，并同时对其前置任务羽毛球检测和关键点检测进

中国知网 https://www.cnki.net

行研究，以促进羽毛球运动的智能化发展，满足智能化羽毛球分析系统对羽毛球数据获取的部分需求。

针对目前羽毛球检测精度低，算法参数量大、复杂度高等问题，以及智能化羽毛球分析系统缺乏有效的羽毛球击球帧检测算法这一具体挑战，本文展开如下分析：

（1）对羽毛球击球帧检测算法缺乏问题。击球帧是运动员击球并改变其运动方向的视频帧，因此可以利用检测到的羽毛球获取羽毛球飞行姿态，利用人体姿态估计获取运动员的姿态作为辅助信息，结合两者信息可以准确获取到击球时刻，从而获取击球帧。

（2）因羽毛球图像自身特点导致的检测精度低的问题。该问题主要来自球场上羽毛球体积小、运动速度快、运动范围大、背景复杂等，图像上表现为羽毛球微小且模糊、特征少、多尺度和背景复杂等。对于羽毛球图像微小、特征少和多尺度问题，可以利用低层的高分辨率特征，扩大模型的特征尺度，实现羽毛球定位精度的提升；对于羽毛球模糊和背景复杂造成噪声干扰问题，可以结合注意力机制通过高层语义信息对低层特征进行特征选择，或者通过设计损失函数调整前景-背景损失平衡，实现噪声的过滤。综上所述，可通过使用高分辨率特征、引入注意力机制或者优化损失函数等方式解决羽毛球图像微小且模糊、特征少等问题，提升检测的精度。

（3）智能化羽毛球分析系统实用性问题，主要在于羽毛球数据获取算法性能问题。对羽毛球数据获取算法，需要实现在预测精度、计算速度、计算复杂度等方面的性能综合平衡。首先需要解决的便是前置算法的性能问题，包括羽毛球检测和姿态估计等问题。目前基于 CNN 的羽毛球检测方法性能精度较高，通过在 CNN 中引入更高效、更有效的卷积操作或者模型结构，剔除原算法中的冗余部分，使得 CNN 检测算法的参数量更少、计算效率更高，从而实现在精度与速度上的平衡。

鉴于此，本文拟开展以深度学习为基础的羽毛球检测算法研究与运动员姿态估计算法研究，并以此为基础进行羽毛球击球帧算法的研究。本文主要研究内容如图 1.6 所示。

本文设计的羽毛球击球帧检测算法有着两个前置输入：羽毛球姿态和运动员姿态。针对羽毛球姿态，本文主要进行高精度且轻量化羽毛球检测算法的研究，以实现一种检测精度与速度综合平衡的羽毛球检测算法。在特征提取阶段，本文通过引入效率更高的卷积操作，设计更轻量、更高效的特征提取基础模块，提升模型计算的效率的同时保证所提取特征的质量；在特征融合阶段，本文引入更低层特征，同时针对网络多尺度特征融合结构中的一些计算复杂或者存在弊端的模块如上/下采样模块进行重新设计，再次提升模型的精度且保持计算量的平衡。并且针对羽毛

中国知网 https://www.cnki.net

球小目标的特点优化损失函数，在不增加网络参数的同时提升检测精度。针对运动员姿态，本文以端到端的姿态估计网络设计为基准，并通过探究一种更优的特征融合方式提高姿态估计的精度。最后本文利用设计的羽毛球检测算法和运动员姿态估计的结果作为输入，进行羽毛球击球帧的检测。算法细节见第三、四、五章内容。至此，实现羽毛球击球帧的检测。

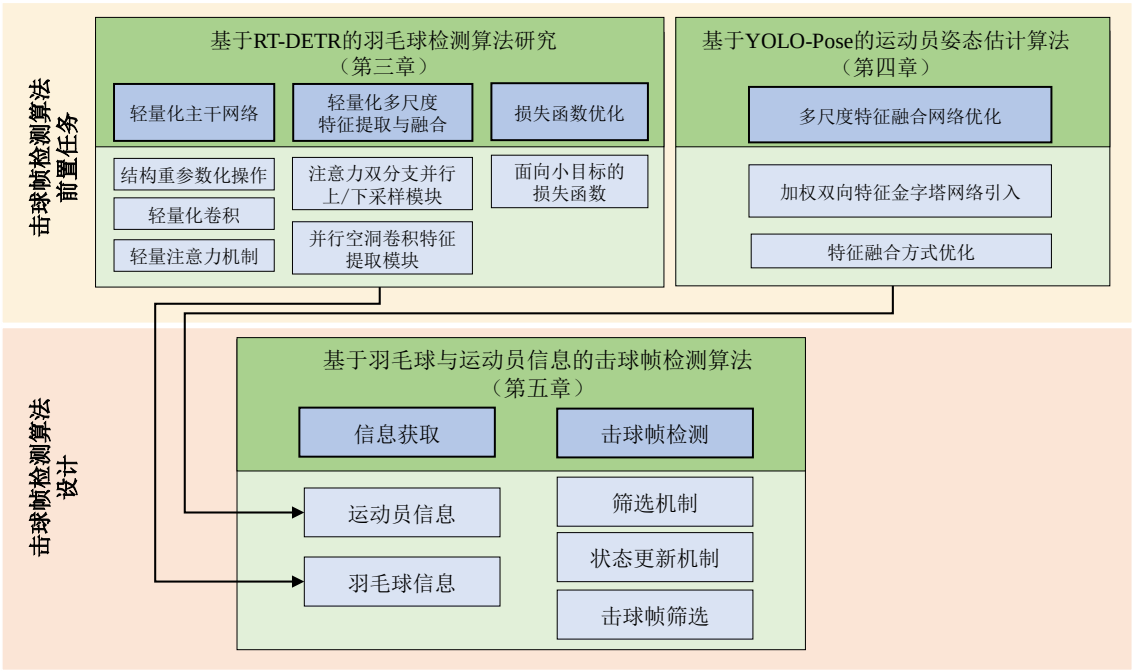


图 1.6 主要研究内容框架

Fig.1.6 Main research content framework

1.4 本文组织架构

本文主要对自动获取羽毛球击球帧的方法展开研究，同时同步对前置任务羽毛球检测、运动员关键点检测算法进行研究。本文共分为六个章节，各章节主要安排如下：

第一章为绪论。该章主要介绍羽毛球击球帧检测对羽毛球运动分析的重要性、可行性与研究价值。然后，简述了羽毛球检测、小目标检测与姿态估计的研究现状并分析了现有方法存在的局限性问题。最后，说明本文的主要研究内容与章节安排。

第二章相关理论基础。本章主要进行击球帧算法研究分析以及相关神经网络知识介绍。本章分析通过分析羽毛球击球帧检测这一任务的特点进行方案设计，并分析任务存在的主要难点，通过对比传统方法与深度学习方法的优劣，选择基于深度学习的方法进行主要算法设计。然后，本章介绍了深度神经网络的基本知识，并对现有的高性能、高精度的卷积操作与特征提取方式进行研究，以实现算法在预测精度、计算速度、计算复杂度等方面的性能综合平衡。最后介绍了本文使用的数据

中国知网 https://www.cnki.net

集与评价指标。本章节为算法研究分析与基础性的知识介绍章节，为更好地理解下文中的算法设计与深度神经网络模型做铺垫。

第三章为羽毛球检测算法研究内容。本章基于 RT-DETR 设计了一个高效且轻量级的羽毛球检测网络 Badminton-DETR。网络通过优化主干网络、损失函数及设计 PMB-FPN 多尺度特征融合网络，使得模型在保持小体积的同时，显著提升了检测速度和精度。该网络采用高效卷积和注意力模块，结合结构重参数化，实现了轻量化主干网络设计。提出的 PMB-FPN 通过跨层连接和多分支结构融合高低层特征，增强了对羽毛球小目标的检测能力。优化的 Inner-MPDIoU 损失函数则解决了小目标检测中的边框容忍度低问题。实验表明，Badminton-DETR 在羽毛球检测任务上表现优异，优于基准模型。

第四章为运动员姿态估计算法研究内容。该章针对运动员姿态估计任务，基于 YOLO-Pose 从多尺度特征融合模块角度进行优化。针对原 YOLO-Pose 在多尺度特征融合网络部分无法区分不同层特征对网络的贡献问题，该章引入了加权双向特征金字塔网络（BiFPN），通过特征加权的方式区分不同层特征对网络的贡献。同时盖章对特征融合的方式做进一步研究，通过对比不同的融合方式，探究了一种最优的特征融合方法，以提升多尺度特征融合的效果。最后，通过实验验证优化方案的有效性。

第五章为羽毛球击球帧检测算法研究内容。该章分析羽毛球击球帧检测这一任务的特点，设计一个基于羽毛球与运动员信息的击球帧检测算法。算法结合羽毛球的目标检测结果和运动员的姿态估计信息，分析羽毛球的运动轨迹和运动员的挥拍动作，判断击球瞬间，实现羽毛球击球帧检测任务。最后，通过实验验证了算法的有效性。

第六章为总结与展望。本章对本文研究工作进行总结并讨论了未来研究工作。

中国知网 https://www.cnki.net

2 问题分析及相关理论基础

击球帧检测在运动员训练分析、比赛策略分析以及智能体育系统等多个领域都具有广泛的应用价值。本章分析通过分析羽毛球击球帧检测这一任务的特点，设计一个可行的方案，并分析了主要面临的挑战，选择基于深度学习的方法进行主要算法设计。然后，对现有的高性能、高精度的卷积操作与特征提取方式进行分析，以实现算法在预测精度、计算速度、计算复杂度等方面的性能综合平衡。最后介绍了本文使用的数据集与评价指标。

2.1 问题研究

2.1.1 问题分析

击球帧在羽毛球这项快速且技巧性极强的运动中，扮演着至关重要的角色。它不仅记录了球员击打羽毛球的瞬间，更是羽毛球运动分析的关键数据点。羽毛球的飞行轨迹、速度、旋转等参数在这一时刻都会发生显著变化，而这些变化往往能够反映出球员的技术水平、战术意图以及比赛状态。因此，准确地识别和分析击球帧，对于提升羽毛球运动的训练效果、比赛分析水平以及运动科学研究都具有重要意义。

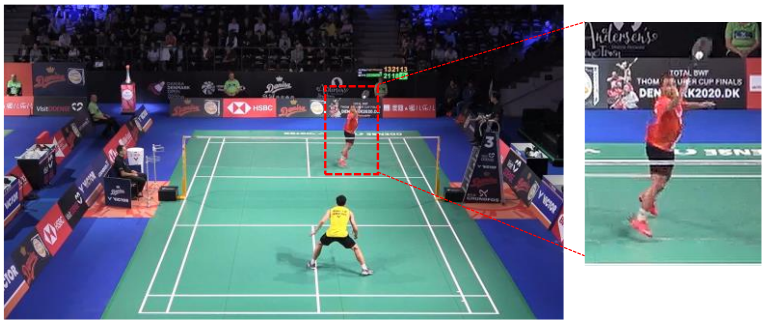


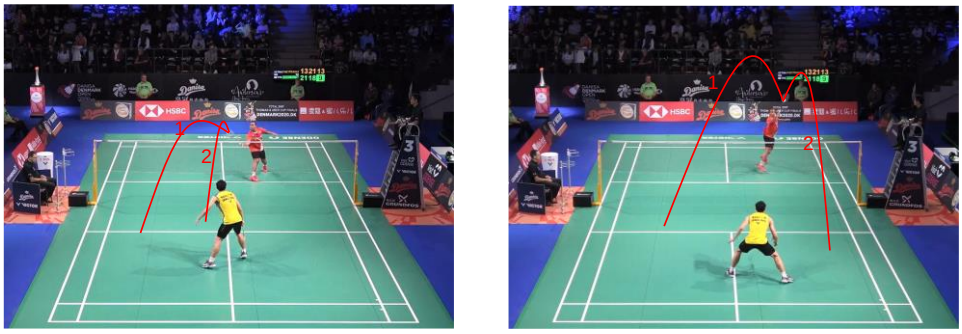
图 2.1 羽毛球击球帧

FIG.2.1 Badminton shot frame

击球帧是指羽毛球运动中球员击打羽毛球并改变其飞行方向的视频帧。在羽毛球运动视频分析中，传统的帧检测方法无法精确捕捉这一关键瞬间。从定义来看，击球帧是由运动员发起，羽毛球承担，并通过图像设备记录的连续图像中的某一瞬间，如图 2.1 所示。因此，借助计算机视觉技术，通过将羽毛球的目标检测结果与运动员的姿态估计信息相结合，实现击球帧检测，是一种可能的设计方案。为什么方案中需要羽毛球信息运动员姿态信息两个输入是本方案中需要深入讨论的问题。

中国知网 https://www.cnki.net

首先，为什么需要羽毛球信息？作为羽毛球运动的承担者，通过目标检测技术，可以从视频流中快速而准确地识别出羽毛球的位置和状态，以确保在众多帧中迅速找到羽毛球的存在，为后续的分析奠定基础。并且通过分析羽毛球飞行方向、速度等信息，可以在一些情况下获取击球时刻，如两条轨迹前后趋势为横向相反运动，如图 2.2（a）所示。但面对图 2.2（b）的情况，当两条轨迹前后趋势为横向同向运动，仅通过羽毛球信息无法准确的区分两条轨迹，准确的检测到击球时刻。



（a）轨迹相反运动　　（b）轨迹同向运动

图 2.2 羽毛球轨迹与击球时刻

Fig. Badminton track and shot time

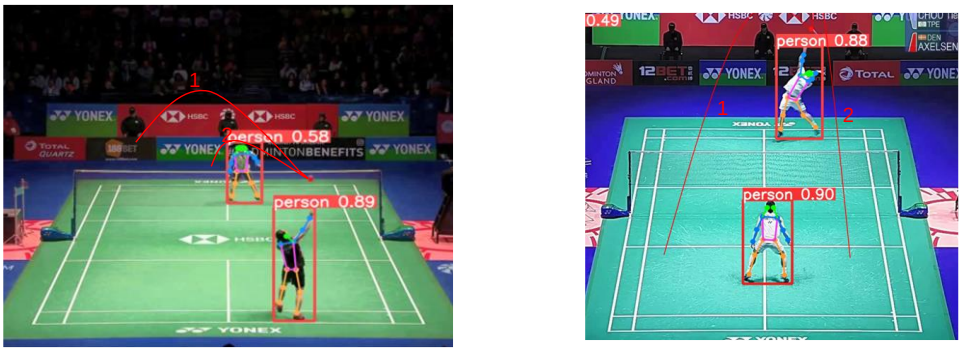
其次，为什么需要运动员姿态信息？作为羽毛球运动的发起者，利用姿态估计技术，可以获取到运动员在击球瞬间的身体姿态，包括运动员的手臂位置、挥拍角度、身体姿态等，它们对于判断击球帧的准确性至关重要。但是直接利用击球姿态检测击球帧是一种理论可行，但是实际很难实现的方案。如图 2.3 所示，运动员击球时的姿态多种多样，他们击球时的动作、击球位置等都不同，甚至有时需要跳起或者扑到击球。因此，直接使用运动员姿态检测击球帧在实际实现上很难，甚至无法实现。但是，通过结合运动员持拍手臂位置与羽毛球的准确位置和轨迹，可以更全面地分析击球过程，可以实现更精确的羽毛球击球帧检测，如图 2.4（a）所示。这样，可以同步解决上述仅通过羽毛球检测无法准确检测到击球帧的情况，即“两条轨迹前后趋势为横向同向运动”时无法检测的问题，如图 2.4（b）所示。



图 2.3 运动员击球姿态举例

Fig.2.3 Example of player hitting stance

中国知网 https://www.cnki.net



（a）轨迹相反运动　　（b）轨迹同向运动

图 2.4 结合羽毛球轨迹与运动员姿态的击球时刻

Fig.2.4 The moment of badminton shot that combines the badminton trajectory with the player's posture

综上所述，本文将结合羽毛球信息与运动员姿态信息以实现更精确地击球帧检测的方案作为研究的方向。具体来说，本文根据羽毛球的位置和运动员的挥拍动作，判断哪一帧是球员真正击中羽毛球的瞬间。

2.1.2 难点分析

为实现上述的研究目标，仍旧存在着许多的挑战，本文分为原始图像数据与算法两个方面。详细说明如下：

（1）从原始图像数据来看，羽毛球运动图像具有高速动态性、特征识别难度大与复杂背景等特点。羽毛球运动具有极高的速度，特别是专业比赛中，羽毛球的飞行速度与运动员击球时爆发动作极快，这些导致羽毛球运动图像具有高速动态性、运动模糊等特点。这要求设计的击球帧检测算法及其相关算法具备处理这种高速动态图像的能力。同时，由于运动模糊、视频拍摄距离等因素，导致羽毛球运动图像的特征少、微弱且模糊不清，特征尺度多等。这些要求设计的算法需具备极强的特征提取与选择的能力。并且，羽毛球运动环境因素干扰，场地中运动的机器人、走动的工作人员以及观众的噪音、环境的光照等都会影响图像拍摄的质量，从而对击球帧的检测产生干扰。综上所述，羽毛球击球帧检测的难点之一主要体现在羽毛球运动本身的特征识别难度大、运动模糊、高速动态性与环境因素干扰等方面。这些难点需要借助先进的图像处理和计算机视觉技术来解决。

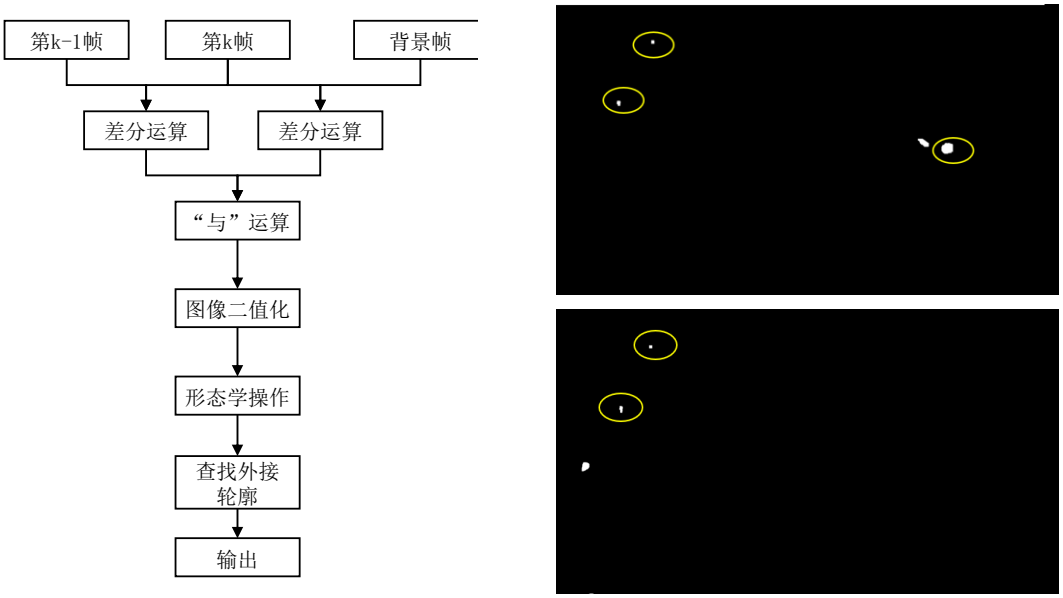
（2）从算法方面来看，主要难点在于羽毛球击球帧算法设计、精度与计算资源等算法性能等方面。击球帧检测算法设计存在诸多困难。从 2.1.1 节分析可得，传统得视频帧检测算法在击球帧检测上是失效的。同时利用传统图像处理方法，如帧差法等，进行击球帧检测算法设计，存在诸多应用限制，如高对比度和无遮挡等，

中国知网 https://www.cnki.net

并且算法的计算效率不高，实时性受限。这一点将在 2.2 节进行详细描述。基于深度学习技术，通过将羽毛球的目标检测结果与运动员的姿态估计信息相结合，实现击球帧检测是一个更可行的方案。这一方案需要解决相关算法在精度与计算资源等算法性能方面的难题，实现在预测精度、计算速度、计算复杂度等方面的性能综合平衡。由于上述羽毛球运动图像存在的难题，羽毛球检测与运动员姿态估计等算法的精度与性能都面临挑战。这需要设计或者优化现有算法，实现更优秀的检测算法，如通过在 CNN 中引入更高效、更有效的卷积操作或者模型结构，剔除原算法中的冗余部分，使得 CNN 检测算法的参数量更少、计算效率更高，从而实现在精度与速度上的平衡。

2.1.3 算法选择

羽毛球击球帧检主要包括羽毛球检测与运动员姿态估计两个前置算法。现有两个算法的解决方案主要有两种：基于传统图像处理方案与基于深度学习方案。



（a）传统羽毛球检测流程　　（b）传统羽毛球检测结果

图 2.5 传统羽毛球检测

Fig.2.5 Traditional badminton detection

羽毛球检测常用的基于传统图像处理方案有帧差法结合形态学操作的方案，具流程见图 2.5（a）。该算法利用帧间差分与背景差分获取运动的羽毛球前景信息，并利用“与”运算融合两前景信息，而后利用二值化、形态学操作（膨胀、腐蚀等）增强前景信息，最后利用外接矩形或连通域大小分理处羽毛球。但如图 2.5（b）所示，该方案在检测时存在缺陷，当拍摄的图像因某些因素扰动或者球拍运动会导致将其他物体被识别为羽毛球的情况，同时该传统算法要求场地内相机不可有任何晃动。因此，利用传统图像处理方法，如帧差法等，进行算法设计，存在诸多应用

中国知网 https://www.cnki.net

限制，如高对比度和无遮挡等，并且算法灵活性差、泛化能力弱。

基于深度学习的羽毛球检测算法，能够通过学习大量的羽毛球图像数据来准确识别羽毛球。该方法可以学习到羽毛球的形状、颜色、纹理等细微特征，从而在各种复杂的背景下实现精确的检测。羽毛球在比赛中存在快速移动、旋转和光照变化等挑战，基于深度学习的检测算法能够更好地处理这些动态变化。深度学习模型能够自动学习羽毛球的特征表示，而无需手动设计和提取特征，因此可以从大量数据中学习到这些变化模式，并在检测时自动适应。如图 2.6（a）所示，基于深度学习的 TrackNetV2[13]网络便可以实现羽毛球的检测，但该算法存在一定定位误差与误识别现象，如图 2.6（b）所示。综上所述，基于深度学习的羽毛球检测算法在精度、鲁棒性、适应性、自动特征学习等方面都具有显著优势，因此是羽毛球检测任务的首选方法。但是在性能方面，算法需要实现在预测精度、计算速度、计算复杂度等方面的性能综合平衡，因此，后续本文主要针对现有的高性能、高精度的卷积操作与特征提取方式进行研究。



（a）TrackNetV2 羽毛球检测结果　　（b）TrackNetV2 羽毛球检测缺陷

图 2.6 基于深度学习的羽毛球检测

Fig.2.6 Badminton detection based on deep learning

针对运动员姿态估计算法，基于传统方式的姿态估计慢慢退出历史舞台，基于深度学习的姿态估计算法取得了重大突破，显著提升了姿态估计的性能，已经成为主流的算法。因此，本文选择使用基于深度学习的运动员姿态估计算法作为研究方案。

2.2 相关理论基础

本文主要基于深度学习进行击球帧检测算法设计，涉及包括羽毛球检测算法、运动员姿态估计算法以及击球帧检测算法。本节主要描述了神经网络的基础知识，重点针对现有的高性能、高精度的卷积操作与特征提取方式进行研究，以便基于此实现算法在预测精度、计算速度、计算复杂度等方面的性能综合平衡。

中国知网 https://www.cnki.net

2.2.1 相关算法基础

（1）卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）通过模拟人脑中视觉皮层的神经元感受野，对输入的图像进行多层次的特征提取和分类。CNN 具有权值共享、局部感受野、完成时空上的下采样、多层次特征提取等特点，有效的实现特征提取、参数量降低，提高模型的泛化能力，被广泛用于图像、视频处理等应用，并在目标检测和分割等任务实现 SOTA（Sota of the arts）性能。CNN 的网络结构主要包括卷积层、池化层、激活层等，LeNet[44]模型是具有代表性的一个结构，如图 2.7 所示。

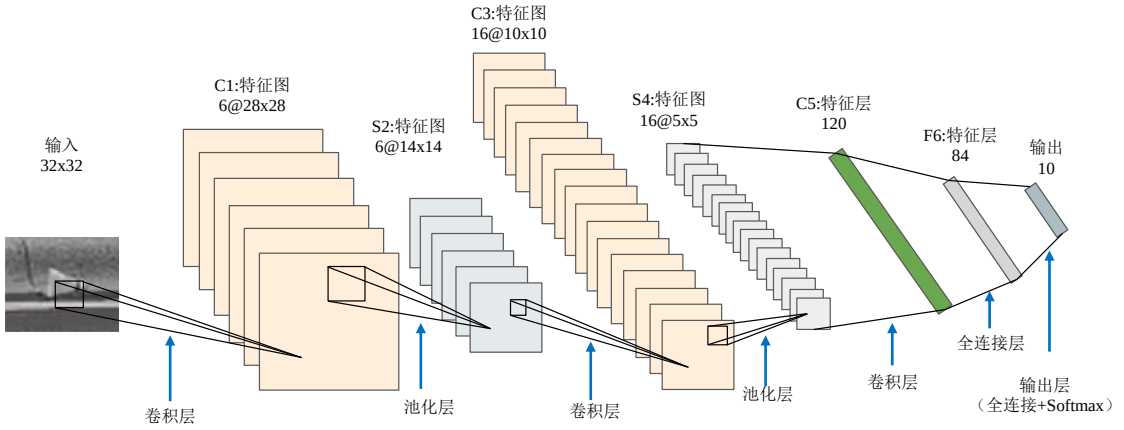


图 2.7 LeNet[44]网络结构

Fig.2.7 LeNet network structure

卷积层：通过卷积核与输入图像进行卷积运算，提取出图像中的局部特征。卷积操作指卷积核沿着图像的 X 方向和 Y 方向，按照设定好的步长与对应的像素点逐行滑动卷积核和图像对应区域像素点的点乘操作，如图 2.8 所示。通常卷积层的输入多通道的特征图，存在 N 个过滤器（每个过滤器由 3 个卷积核组成），每个过滤器可以提取不同的特征，例如过滤器 1 可能用来识别图像中彩色变化趋势，过滤器 2 可能用来识别图片中纹理变化等，如图 2.9 所示。

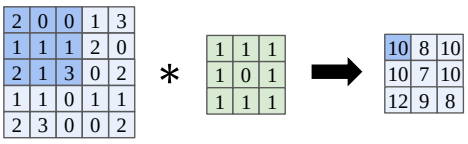


图 2.8 二维卷积操作

Fig.2.8 Two-dimensional convolution operation

中国知网 https://www.cnki.net

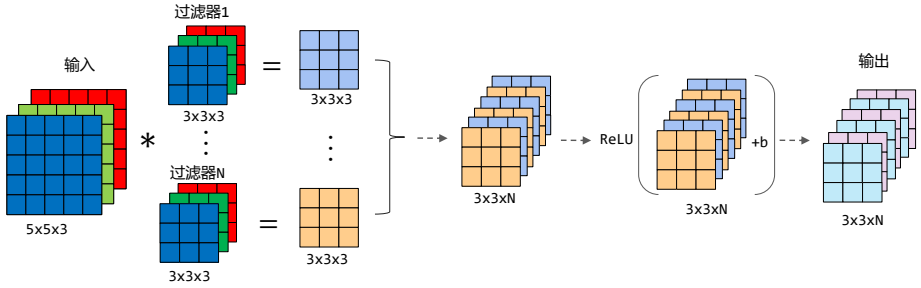


图 2.9 多维卷积操作

Fig.2.9 Multi-dimensional convolution operation

池化层：实际上是一个下采样过程，可以减小数据的维度并保留重要的特征信息。池化层可以减小模型规模，有效地减少计算量，提高模型的泛化能力。池化层通常放在卷积层之后，二者相互交替出现。池化操作类似卷积操作，也有一个类似卷积核的结构在特征图上移动，称作池化窗口。常用的池化函数有：平均池化（Average Pooling/Mean Pooling）、最大池化（Max Pooling）、最小池化（Min Pooling）和随机池化（Stochastic Pooling），如图 2.10 所示。

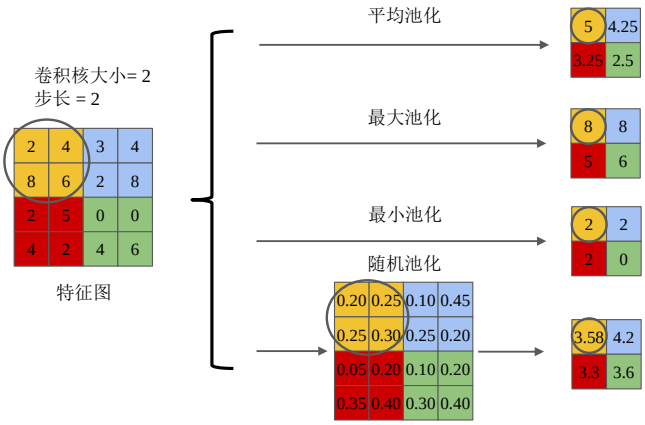


图 2.10 三种常见的池化操作

Fig.2.10 Three common pooling operations

激活层：本质是一种非线性映射。在卷积层中，CNN 采用卷积操作实现，实质上可以看作对每个像素点做加权运算，这个过程显然是线性过程。但实际样本来不一定是线性可分的，为了解决这个问题，就需要引入非线性因素，使得 CNN 具备分层的非线性映射学习能力。常用的激活函数有 Tanh 函数[45]、ReLU 函数[46]、LeakyReLU 函数[47]、Mish 函数[48]等，函数图像如图 2.11 所示。

中国知网 https://www.cnki.net

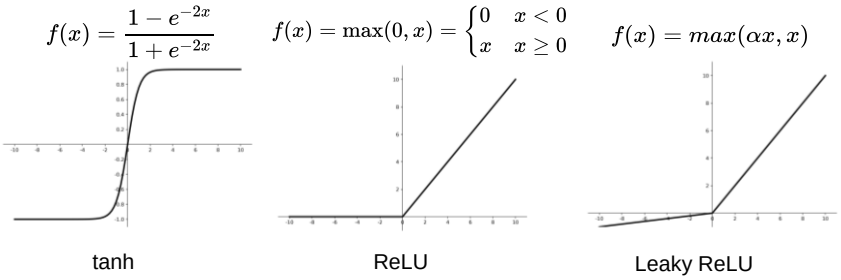


图 2.11 激活函数图像

Fig.2.11 Activation function image

（2）几种卷积变体结构

卷积层是 CNN 的核心，是 CNN 计算任务的主要承担者。卷积操作性能的优劣直接影响网络模型的性能。自卷积操作被提出以来，卷积操作一直在快速发展，卷积朝着参数更少、计算更高效的方向前进。为实现本文精度与速度综合平衡的检测算法设计的目的，本文重点关注卷积操作。鉴于此，本文对现有的一些卷积操作进行研究，并分析其优劣。

标准 2D 卷积核对应的卷积层参数量为$k \times k \times C_I \times C_O$（$k$ 为卷积核大小，C_I为输入特征图通道数，C_O为输出特征图通道数），以此中卷积进行设计会使模型变得臃肿，过大的参数量限制模型在计算机资源有限的移动端与自主领域应用，由此大量更高效的卷积变体结构快速发展，如深度可分离卷积[49][50]（Depthwise Separable Convolutions, DSConv）、可变形卷积[51][52]（Deformable Convolution, DConv）、幻影卷积[53]（Ghost Convolution，Ghost-Conv）、部分卷积[54]（Patial Convolution，PConv）。

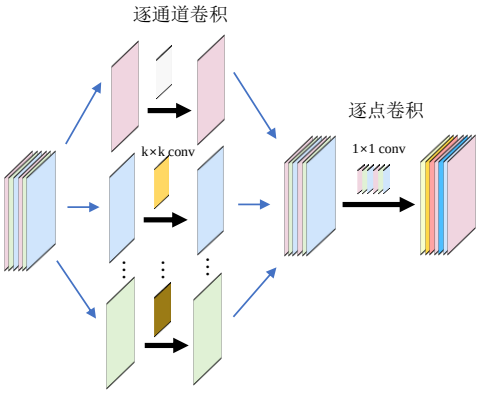


图 2.12 深度可分离卷积（DSConv）示意图

Fig.2.12 Illustration of Depthwise Separable Convolutions (DSCs)

深度可分离卷积 DSConv，将卷积计算过程分为逐通道卷积和逐点卷积两个步骤，降低卷积的参数量和运算成本较低，如图 2.12 所示。首先，使用C_I（特征图通

中国知网 https://www.cnki.net

道数）个$k \times k \times 1$的卷积核，即卷积核与通道一一对应单独进行卷积运算，共生成C_I个中间特征图；然后，利用C_O个 1×1×C_I的卷积核在深度上进行加权组合，生成$W_O \times H_O \times C_O$特征图。DSConv 卷积操作参数量为$k \times k \times C_I + C_O \times C_I$，参数量大大减少。

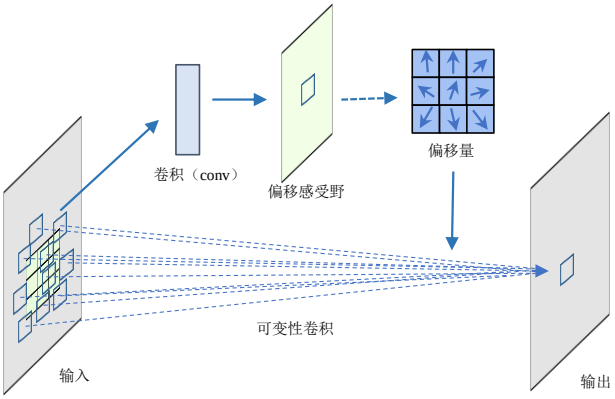


图 2.13 可变形卷积结构（DConv）

Fig.2.13 Illustration of Deformable Convolution (DConv)

可变形卷积 DConv，针对标准卷积核形状固定带来的提取形变严复杂体特征能力不足的问题，通过添加一个可学习的偏移量获取适应物体形状的偏移感受野，使卷积结构更贴合物体形变特性，获取更强的物体特征。DConv 通过给每个卷积位置点增加一个可学习的位置偏移量$\Delta \boldsymbol{p}_n$，实现位置不规则扩张，从而灵活的模拟目标物体复杂形变。可变形卷积 DConv 结构如图 2.13 所示。

标准卷积计算可用公式 2.1 表示，其中是输出特征图的每个点与卷积核中心点对应，$\boldsymbol{p}_n$是$\boldsymbol{p}_0$在卷积核范围内的每个偏移量。

$$\boldsymbol{y}(\boldsymbol{p}_0) = \sum_{\boldsymbol{p}_n \in \mathcal{R}} \mathbf{w}(\boldsymbol{p}_n) \cdot \boldsymbol{x}(\boldsymbol{p}_0 + \boldsymbol{p}_n) \tag{2.1}$$

DConv 则在上述公式 2.1 的基础上为每个点引入了一个偏移量$\Delta \boldsymbol{p}_n$，偏移量是由输入特征图与另一个卷积生成的，通常是小数，如公式 2.2 所示。

$$\boldsymbol{y}(\boldsymbol{p}_0) = \sum_{\boldsymbol{p}_n \in \mathcal{R}} \boldsymbol{w}(\boldsymbol{p}_n) \cdot \boldsymbol{x}(\boldsymbol{p}_0 + \boldsymbol{p}_n + \Delta \boldsymbol{p}_n) \tag{2.2}$$

其中，偏移量$\Delta \boldsymbol{p}_n$一般都是小数，并不对应特征图上实际存在的像素点，因此采用双线性插值完成不规则位置卷积计算。令$\boldsymbol{p}_0 + \boldsymbol{p}_n + \Delta \boldsymbol{p}_n = \boldsymbol{p}$，计算公式如式 2.3 所示。因此，可变形卷积通过增加极少参数量，可更好地适应物体应对诸如目标移动、尺寸缩放、旋转等。

中国知网 https://www.cnki.net

$$\begin{aligned} \boldsymbol{x}(\boldsymbol{p}) &= \sum_{\boldsymbol{q}} G(\boldsymbol{q},\boldsymbol{p}) \cdot \boldsymbol{x}(\boldsymbol{q}) \\ &= \sum_{\boldsymbol{q}} (\mathrm{g}(q_x,p_x) \cdot \mathrm{g}(q_y,p_y)) \cdot x(\boldsymbol{q}) \\ &= \sum_{\boldsymbol{q}} (max(0,1-|q_x-p_x|) \cdot max(0,1-|q_x-p_x|)) \cdot x(\boldsymbol{q}) \end{aligned} \tag{2.3}$$

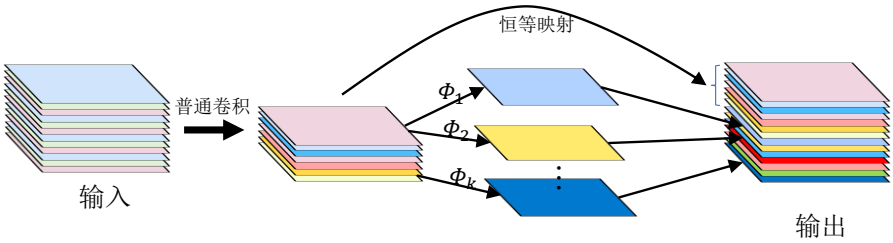


图 2.14 幻影卷积结构（Ghost-Conv）

Fig.2.14 Illustration of Ghost Convolution (Ghost-Conv)

幻影卷积 Ghost-Conv，神经网络堆叠的特征图中包含的大量相似、冗余的特征图，而这些特征可以利用廉价的线性变换从其他特征图中获取，即其中一个特征图是另一个特征图的“幻影”。Ghost-Conv 计算步骤如下：首先，使用普通卷积来生成固定数量的固有特征图，一般生成特征图会远少于最终输出特征图总数。然后，使用一系列简单的线性运算（即图 2.14 中的Φ_1，Φ_2，…，Φ_k，其中包括 3×3，5×5 卷积等线性运算方式）逐特征图的操作生成更多的“幻影”特征图。与普通卷积相比，Ghost-Conv 以更小的参数量核计算复杂度，获取相同大小的特征图。

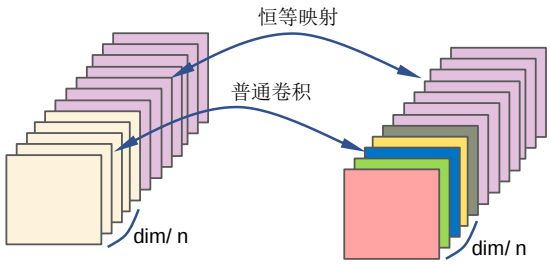


图 2.15 部分卷积结构（PConv）

Fig.2.15 Illustration of Patial Convolution (PConv)

部分卷积 PConv，针对神经网络中堆叠特征的冗余性现象，以及频繁的内存访问导致每秒低浮点运算（FLOPS）效率低下，通过对输入特征图的部分通道进行卷积操作，实现简单、快速、有效的卷积操作。如图 2.15 所示，PConv 仅对输入特征图的 1/n 通道进行卷积操作，对剩余通道不做卷积处理，避免产生过多的冗余特

中国知网 https://www.cnki.net

征，提高 FLOPS 效率，提升卷积性能。

（3）多尺度特征提取与融合

羽毛球运动图像的特征少、微弱且模糊不清，特征尺度多等因素，决定算法需具备极强的特征提取与选择的能力。多尺度特征提取与融合网络通过融合大小不同尺度可以增强网络的特征提取能力，并且综合不同尺度层特征信息，一提高网络的检测性能。

对 CNN 来说，网络层数的增加一方面提高了对图像特征提取的能力，另一方面不同尺度特征所提取的侧重图像信息也更加分明。对高层特征，其分辨率更低，感受野更大，主要包含图像的语义信息，更有利于占据像素更多的大目标检测；对低层特征，其分辨率更大，主要包含更多的纹理等细节信息和位置信息，感受野更小，更有利于占据像素更小的小目标检测。由于无法平衡高低特征之间的关系，常规特征提取方法在小目标检测任务中表现不佳。于是，便提出了多尺度特征融合的方法。该方法通过融合不同尺度的特征，聚合浅层位置信息和深层语义信息，利用浅层信息可以区分距离较小而密集的目标，利用深层信息可以区分大而复杂的目标。常见的多尺度特征融合网络有两种：是串行的跨层连接结构和并行多分支结构。下面对它们进行介绍。

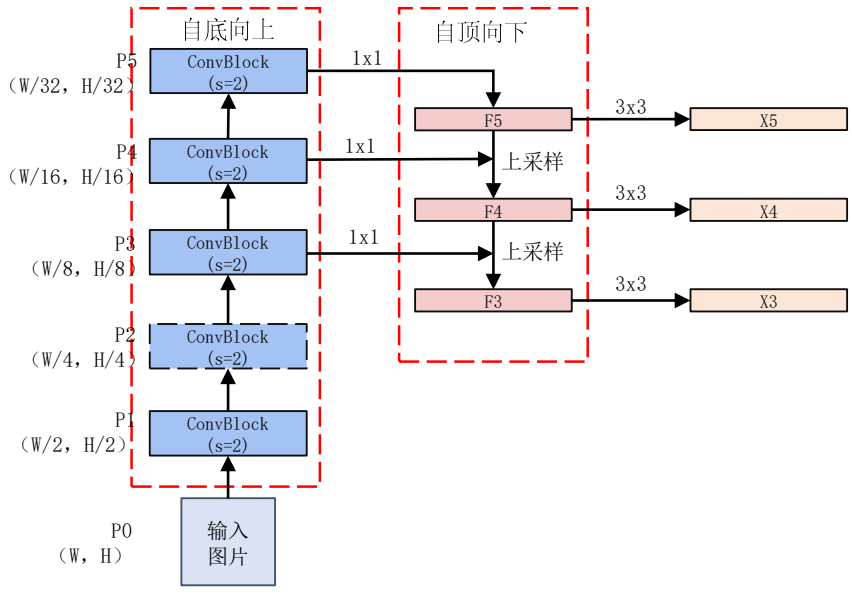


图 2.16 FPN 网络结构

Fig.2.16 FPN network structure

串行的跨层连接结构首先对多个尺度的特征进行上采样，然后通过跨层连接实现特征融合，代表网络有 FPN[16]、PANet[17]、U-Net[59]等。FPN 在网络中,添加了一条自上而下的路径，调整网络内部的连接方式获得检测性能的提升，网络结构如

中国知网 https://www.cnki.net

图 2.16 所示。自底向上的路径就是主干网络进行特征提取的过程，经过卷积操作会不断缩小特征图的尺寸，聚集特征信息，因此高层特征包含丰富的语义信息。自顶向下连接会对深层特征进行上采样，扩大特征图的尺寸，通过连接融合同一尺寸层面的特征，从而加强高分辨率信息和高语义信息。FPN 使用 1×1 的卷积调整特征图数量，利用 3×3 的卷积核对融合后的特征再次进行特征提取并去除混叠现象的影响。PANet 则在 FPN 的结构基础再次添加了一个自下向上的路径，如图 2.17 所示。FPN 自顶向下的特征传递路径，只是增强了语义信息，却没有传递位置信息。PANet 自下向上的路径则是将低层的高位置信息特征向高层传递，对整个网络的位置信息进行增强，同时可以缩短信息传播路径。至此，网络可以同时利用加强的高层特征的语义信息和低层特征的精准定位信息进行检测。

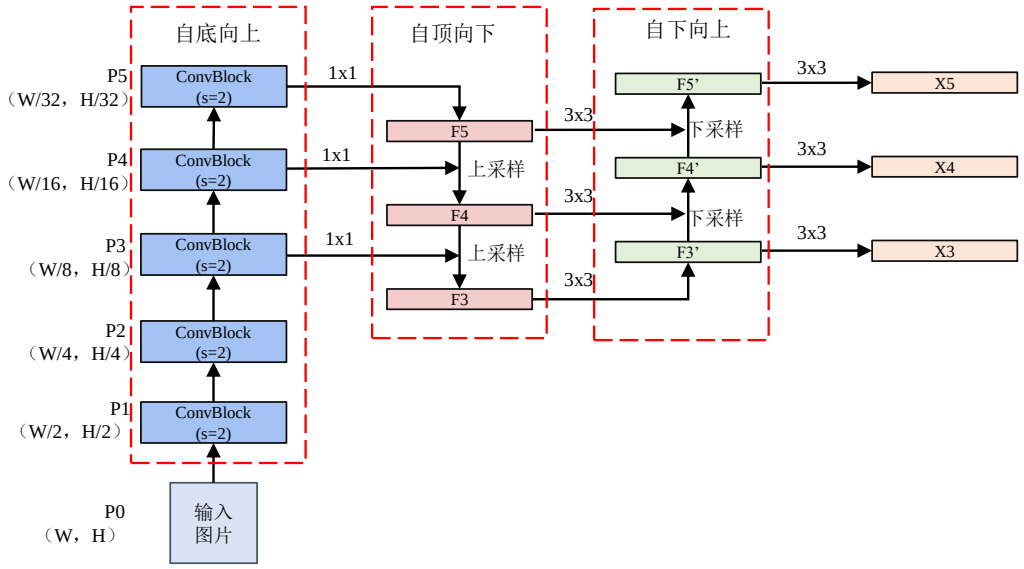


图 2.17 PANet 网络结构

Fig.2.17 PANet network structure

并行多分支结构代表网络有 SPP-Net[21]、Inception[60][61][62]系列等。SPP-Net 的核心模块为空间金字塔池化（SPP，Spatial Pyramid Pooling），模型允许任意大小的输入，获取相同尺寸的输出。SPP 将 256 通道特征图分别分为 4×4、2×2、1×1 三个尺度的模块，然后经过最大池化后输出 16，4，1 三个尺度的 256 维特征向量。最后再将三个尺度特征进行融合，从而得到固定维度的输出。具体流程如图 2.18 所示。

中国知网 https://www.cnki.net

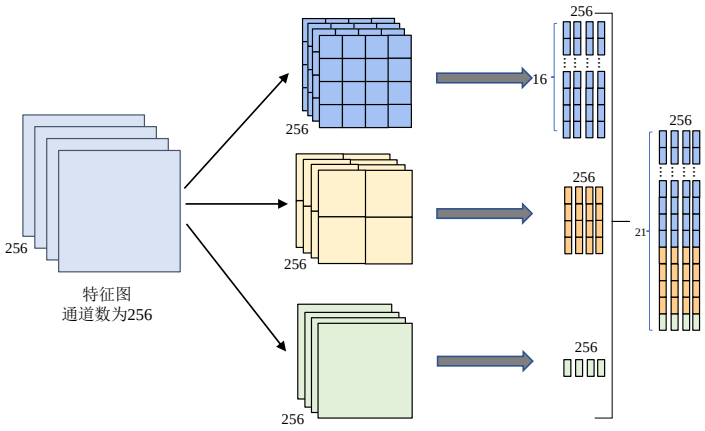


图 2.18 SPP 并行多分支融合过程

Fig.2.18 SPP parallel multi-branch fusion process

2.2.2 数据集与评价指标

（1）数据集

1）原始羽毛球数据分析

本文旨在研究一种低成本的羽毛球智能分析系统种的羽毛球击球帧获取算法，如何羽毛球原始视频数据便是首先需要考虑的事情。鹰眼系统使用多个高清高速相机采集比赛视频数据，并且可以获取一些羽毛球数据，但其所需设备价格高昂，普通人无法承担，并且数据向大众公开，因此无法普及。羽毛球比赛中保留的大量比赛视频获取难度低、成本低等，显然更符合本文研究的低成本研究目标。虽然这类视频的帧率与分辨率较低，使得羽毛球图像更加模糊等，从而增加了检测算法设计的难度，但是随着检测算法的快速发展，这些问题在现有的算法框架下是可以解决的。同时虽然羽毛球球速很高，但是绝大部分情况下，在运动员击球时刻球速并不会很高。

综上所述，本文选择比赛视频作为构建数据集的数据来源。

2）数据集构建与分析

本文采用的数据集主要来自比赛视频数据 TrackNetV2[13]与无人机采集的球场后方与顶部视频数据[55]。TrackNetV2 采集了 29 场比赛视频，其中包含 26 场专业比赛和 3 场业余比赛，视频分辨率为 1280×720，帧率为 30FPS。无人机视角视频在安徽大学羽毛球俱乐部比赛中采集，原始视频数据包括 39 场比赛，视频分辨率为 3480×2160，帧率为 30FPS。

将上述的视频数据按照近似 8：2 的比例将数据集划分为训练集与验证集，即训练集包含 23 场 TrackNetV2 视频数据与 32 场俱乐部比赛视频数据，验证机包含 6 场 TrackNetV2 视频数据与 7 场俱乐部比赛视频数据。最终的训练集与验证集以 2 帧/秒的规格从上述的视频数据种采集，并将采集的图片数据进行分辨率大小调

中国知网 https://www.cnki.net

整，统一调整为 1280×720 大小。

数据集使用”labelimg”进行标注，格式为“.txt”。标注格式为“class，x，y，w，h”，分别表示类别、归一化后的中心点 x 坐标，归一化后的中心点 y 坐标，归一化后的目标框宽度 w，归一化后的目标框高度 h，其中归一化指除以图片宽或高。标注后的图片如图 2.19 所示。



图 2.19 数据标注示例

Fig.2.19 Example of data annotation

本文对采集的数据集进行大小的统计结果如图 2.20。本文根据 COCO 数据集定义进行目标尺寸的定义：尺寸小于 32×32 像素为小目标；尺寸在 32×32 与 96×96 像素之间的为中目标；尺寸大于 96×96 像素之间的为大目标。从图中可以看到数据集中物体有 92.14%的目标尺寸小于 32×32 像素，满足小目标的定义。说明本数据集中的羽毛球基本都是小目标。

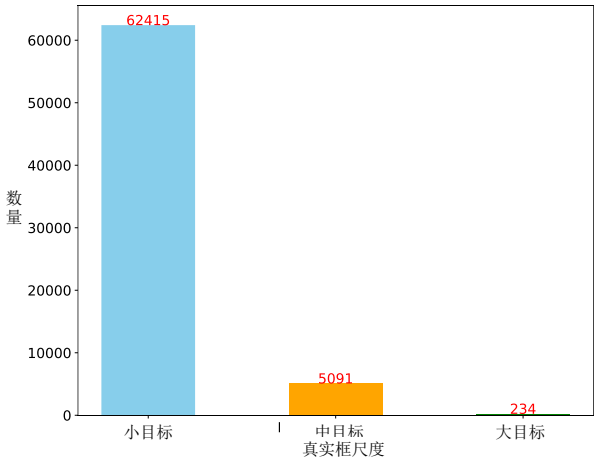


图 2.20 数据集分布情况

Fig. 2.20 Distribution of data sets

（2）评价指标

中国知网 https://www.cnki.net

目标检测领域的模型评价指标有很多，可以分为准确性和实时性两类。本文采用的准确性评估指标有精确率 Pre（Precision）、召回率 Rec（Recall）、mAP_{50}（mean Average Precision，mAP）和$mAP_{50:95}$，其中mAP_{50}代表 IoU（Intersection of Union）阈值为 0.5 时所有目标类别的平均精度，$mAP_{50:95}$代表以步长为 0.05，计算 IoU 阈值从 0.5 到 0.95 的 10 个 IoU 阈值下的所有目标类别的平均精度。本文采用的实时性评估指标有参数量 Params（Parameters）、帧率 FPS (Frames Per Second)和计算量 FLOPs（Floating-point Operations）。

其中，FPS 指在确定的硬件设备下，算法每秒处理图像的帧数，该参数衡量算法的检测速度。FLOPS 和参数量（Params），是衡量算法复杂度的指标，指标越小，则模型的性能越好。

在深度学习中，将分类任务的预测结果分为以下四种，如表 2.1 所示：

表 2.1 混淆矩阵

Table 2.1 Confusion matrix

真实值	预测值		
		Positive	Negative
	Positive	True Positive	False Negative
	Negative	False Positive	True Negative

表 2.2 混淆矩阵含义

Table 2.2 Meaning of confusion matrix

符号	含义
TP(True positive）	实际为正例，预测为正例
FP(False positive）	实际为负例，预测为正例
TN (True negative)	实际为负例，预测为负例
FN (False negative)	实际为正例，预测为负例

精确度又称为查准率，表示在模型识别为正类的样本中，检测正确的样本所占的比例。一般情况下，查准率越高，说明模型的效果越好。其公式如（2.9）所示。

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{2.9}$$

召回率又称查全率，模型正确识别出正样本的数量占总的正类样本数量的比值。一般情况下，Recall 越高，说明有更多的正类样本被模型预测正确，模型的效果越好。计算公式如（2.10）所示。

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{2.10}$$

模型对每一个预测框都可以生成对应的 Precision 和 Recall，P-R 曲线就是一这

中国知网 https://www.cnki.net

两个值为点（R，P）绘制成的曲线，曲线凸起程度越大，说明算法的误检、漏检的概率越低，效果越好。P-R 曲线如图 2.21 所示。

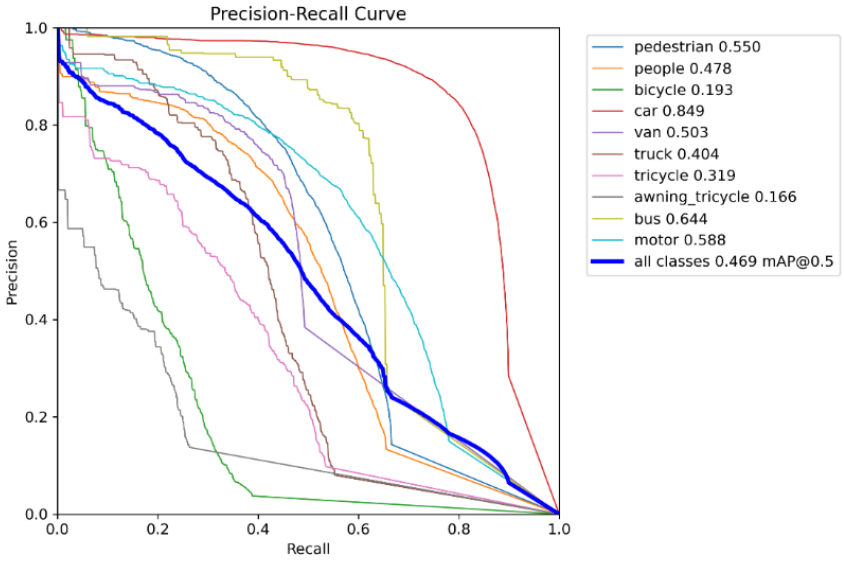


图 2.21 P-R 曲线

Fig.2.21 P-R curve

平均准确率(Average Precision, AP)，是类别检测的平均准确率，其定义是 P-R 曲线下包围的面积，AP 越大，检测的效果越好。其公式如下：

$$AP = \int_0^1 P\ （\mathrm{C}）\ \mathrm{d}R \qquad （2.11）$$

式中，C 表示不同的类别。

全类别平均精度(Mean Average Precision, mAP)，指所有类别的 AP 的平均值，常用来评价多分类器的性能。mAP 越大，检测的效果越好。其公式如下：

$$mAP = \frac{\sum AP(C)}{N(\mathrm{classes})} \qquad （2.12）$$

式中，C 表示不同的类别，$N(\mathrm{classes})$表示类别总数。

2.3 本章小结

本章主要进行击球帧算法研究分析以及相关神经网络知识介绍。本章分析通过分析羽毛球击球帧检测这一任务的特点进行方案设计，并分析任务存在的主要难点，通过对比传统方法与深度学习方法的优劣，选择基于深度学习的方法进行主要算法设计。然后，LeNet 网络结构为例，介绍了深度神经网络的基本知识，并对现有的高性能、高精度的卷积操作与特征提取方式进行研究，以实现算法在预测精度、计算速度、计算复杂度等方面的性能综合平衡。最后介绍了本文使用的数据集

中国知网 https://www.cnki.net

与评价指标。本章节为算法研究分析与基础性的知识介绍章节，为更好地理解下文中的算法设计与深度神经网络模型做铺垫。

中国知网 https://www.cnki.net

3 基于 RT-DETR 的羽毛球检测算法研究

羽毛球检测结果的好坏关系着击球帧检测的成败。RT-DETR[56]是一个基于 CNN 和 transformer 的实时检测算法，且在计算量与精度等性能指标上超越当前众多优秀算法，因此本文选择基于 RT-DETR 进行羽毛球检测算法设计。本章通过实验选择性能更好的卷积操作对 RT-DETR 主干网络进行优化，并且针对 RT-DETR 颈部网络中上/下采样方式单一，缺乏针对特征的针对性问题，设计注意力双分支上/下采样模块提升采样途径，结合串行的跨层连接结构与并行多分支结构设计并行多分支多特征提取与融合网络，进一步提高网络捕捉特征中的局部和上下文信息的能力。最后，结合 Inner-IoU 和 MPD-IoU 损失进行损失函数的优化。

3.1 RT-DETR 网络

本文 RT-DETR 模型结构如图 3.1 所示。RT-DETR 是 DETR 系列最新的研究成果之一，主要包括：主干网络、颈部网络和检测头。主干网络部分用于图像特征提取，颈部网络部分将主干网络中的 P3、P4、P5 层输出进行多尺度特征提取与融合，转换为一系列图像特征。然后，检测头中的 IoU 感知查询选择精炼这些特征，为解码器提供了一组优化的查询。解码器迭代优化这些查询以生成边界框和置信度分数。

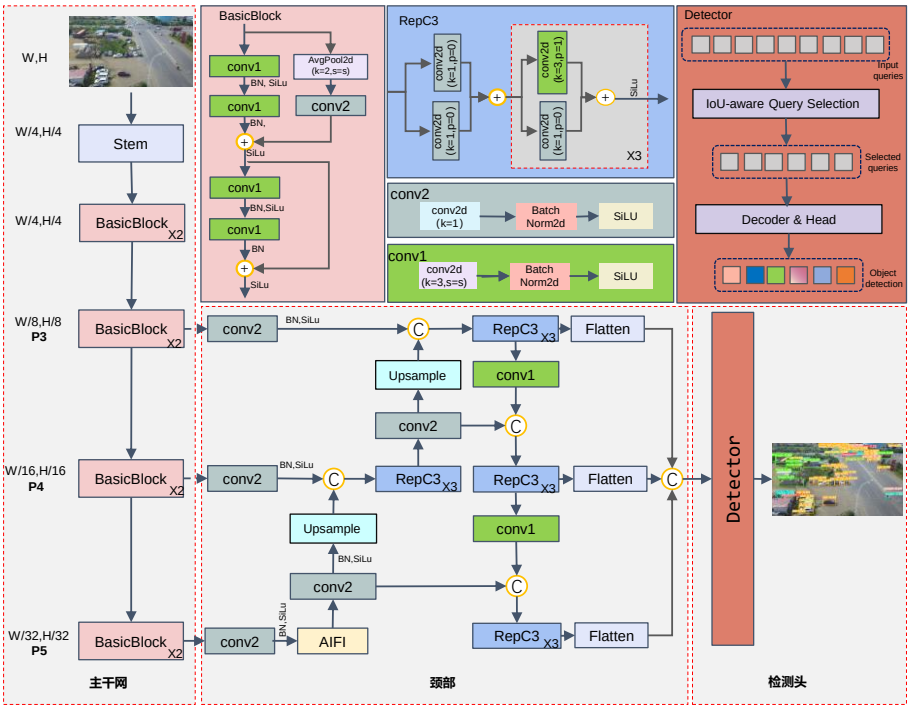


图 3.1 RT-DETR 结构图

Fig.3.1 Structure of RT-DETR

中国知网 https://www.cnki.net

（1）主干网络

RT-DETR 采用 CNN 网络，如流行的 ResNet18、ResNet50、HGNet。图 3.1 中以 ResNet18 为例展示了主干网路的结构，RT-DETR 从主干网络中选择 P3、P4、P5 三个尺度特征输出，其下采样倍数分别为 8、16 和 32。主干网络共包含 5 个 stage，Stem 为第一个 stage，由 3 个卷积模块“Conv+BN+ReLU”和 1 个最大池化层组成，共进行下采样两次；后续的 4 个 stage 由 2 干个 BasicBlock 模块组成并且仅在 stage3、stage4、stage4 三个阶段进行通道尺寸减半操作。

（2）颈部网络

RT-DETR 将多尺度特征交互解耦为尺度内特征交互和跨尺度融合，并通过设计的高效混合编码模块，对 P5 进行特征的提取和融合。高效混合编码模块由尺度内特征交互（Attention-based Intra-scale Feature Interaction，AIFI）和跨尺度特征融合（CNN-based Cross-scale Feature-fusion Module，CCFM）的组成，其中 AIFI 是只包含一层的 Transformer Encoder 结构，其公式如式 3.1 所示。具体处理过程如下：首先，网络将主干网输出的二维的特征拉成向量，然后由 AIFI 模块处理，其本质就是多头自注意力与 FFN，随后，我们再将输出调整回二维，进行后续的多尺度融合。对 P3、P4 层的特征则采用通用的特征提取与融合方式进行。该部分具体结构如图 3.1 中颈部部分所示。

$$\begin{aligned} Q = K = V &= \text{Flatten}(P_5) \\ F_5 &= \text{Reshape}\big(\text{Attn}\big(Q,\ K,\ V\big)\big) \end{aligned} \tag{3.1}$$

（3）检测头

如图 3.1 中红色”Detector”部分所示。该部分由 IoU 感知和 Query 选择、Transformer Decoder 组成。IoU 感知和 Query 选择可以解决分类分数和位置置信度的分布不一致问题，约束模型在训练期间为具有高 IoU 分数的特征产生高分类分数，并为具有低 IoU 得分的特征产生低分类分数，从而提供更高质量（高分类分数和高 IoU 分数）的 Decoder 的 Query。

3.2 特征提取网络优化

本小节针对 RT-DETR 主干网进行算法优化，即图 3.1“主干网部分”，通过使用性能更好的卷积操作、结构重参数化、轻量化注意力操作，设计速度和计算量平衡更好的特征提取主干网。

3.2.1 卷积操作分析与选择

卷积是深度学习网络的基础组件，近年来有很多的研究人员不满于使用最基础的卷积操作，而是采用不同的策略改进卷积的操作方式或者使用卷积组合，从而实现更快、参数更少、效果更好的检测效果。为提高模型的检测速度，降低网络的

中国知网 https://www.cnki.net

参数量和计算开销，实现更快更好模型的设计，本文设计了一个卷积小实验对 7 种卷积操作的速度，计算开销，参数量进行测试。

本文主要对比了普通卷积（Conv2d）、深度可分离卷积[49][50]（DSConv）、可变形卷积（DCNV2[51]、DCNV3[52]）、幻影卷积（Ghost-Conv[53]）、部分卷积（PConv[54]）等 7 种卷积操作，卷积的具体结构与分析见 2.2.1 节。每种卷积操作中卷积均采用“3×3Conv+BN+ReLU”的结构。

实验参数如下：（bs，h，w）=（8，256，256），（in_c，out_c，kernel_size）=128，128，3），所有参数指标取 3000 次卷积的平均值。实验结果如表 3.1 所示，其中 Ghost-Conv 的参数量与计算开销最低，而 PConv 的速度最高。PConv 与 Ghost-Conv 相比参数量与计算开销仅仅增加了 4.7%和 3.5%，而 FPS 增加了 26%。本文主要研究速度和计算量平衡更好的检测算法，因此选择 PConv 作为主干网络设计的核心卷积。

表 3.1 卷积家族对比

Table 3.1 Convolutional family comparison

	FPS	FLOPs	Params
Conv2d	131.61	77.58G	147.84K
DCNV2	28.65	16.58G	31.387K
DCNV3	49.85	20.13G	38.171K
GSConv	124.62	39.76G	75.712K
DSConv	127.34	9.73G	18.304K
Ghost-Conv	217.62	**4.87G**	**9.152K**
PConv	**274.18**	5.10G	9.472K

3.2.2 结构重参数化

结构重参数化将一个结构的参数等价转换为另外一组参数，且转换后的参数可以作为另一种结构的参数使用，那么这两种结构的效果同样是等价的。在实际应用中，深度学习模型训练时的计算资源一般是相对丰富的，但是在推理阶段的计算资源则相对受限，因此更在意应用中推理模型的计算开销和性能表现。因此，更希望模型在训练的时候有更大、更复杂的结构以具备更好的性能，同时，在推理的时候转换成更小、更简单的结构且能够保留这种性能。从而实现在高算力设备上进行模型训练，在低算力设备上进行模型部署，且保持模型性能不变。

RepVGG[57]网络结构如图 3.2 所示。与 ResNet 网络结构相比，RepVGG 在训练时可以在每一层卷积都添加 1x1 卷积分支和恒等映射分支，实现多分支结构训练。训练完成后，将网络等价转换为单分支结构，进行推理部署。结构重参数化的等价代换主要利用卷积的线性可加性，例如设三个卷积的卷积核分别为“w_1，w_2，

中国知网 https://www.cnki.net

w_3”，可以实现：$\mathrm{Conv}(x, w_1) + \mathrm{Conv}(x, w_2) + \mathrm{Conv}(x, w_3) = \mathrm{Conv}(x, w_1 + w_2 + w_3)$。网络中的 1×1 卷积可以看作一个卷积核中有很多 0 组成的特殊 3×3 卷积；恒等映射可以看作是以单位矩阵为卷积核的特殊 1×1 卷积，故也可以看作一个特殊的 3×3 卷积。实现等价转换只需要实现：（1）构建一个以单位矩阵为卷积核的 1×1 卷积来等价代换恒等映射；（2）构建一个特殊的 3×3 卷积来等价代换 1×1 卷积。

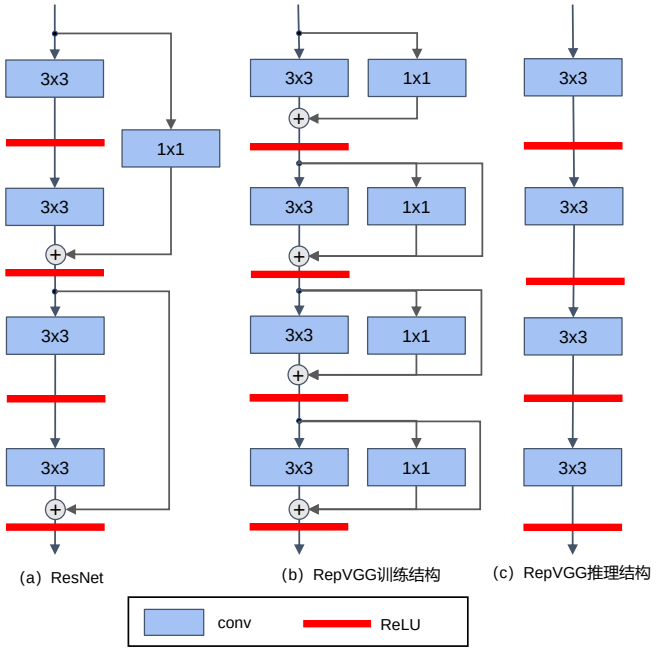


图 3.2 RepVGG 网络结构

Fig.3.2 RepVGG network structure

具体等价转换流程如图 3.3 所示，图中的输入输出通道数都是 2，故 3×3 卷积的参数是 4 个 3×3 矩阵，1×1 卷积的参数是一个 2×2 矩阵。等价代换具体操作步骤如下：

（1）将卷积层与批量归一化层（Batch Normalization，BN）进行融合。网络中的 3×3 卷积、1×1 卷积和恒等映射三个分支都有 BN 层，其参数包括累积得到的均值μ、标准差σ、学得的缩放因子γ和偏置$\boldsymbol{\beta}$。RepVGG 中通过式（3.2），进行 BN 层参数转换成卷积参数。

$$\begin{aligned} &\mathrm{BN}(M * W, \mu, \sigma, \gamma, \boldsymbol{\beta})_{:,i,:,:} = (M * W')_{:,i,:,:} + b'_i \\ &\mathrm{W}'_{i,:,:,:} = \frac{\gamma_i}{\sigma_i}\boldsymbol{W}_{i,:,:,:}, \qquad \mathbf{b}'_i = -\frac{\mu_i \gamma_i}{\sigma_i} + \beta_i \end{aligned} \tag{3.2}$$

式中，M 表示输入输出，$\boldsymbol{W}_i$表示转换前的卷积层参数，W'、$\mathbf{b}'_i$、W'_i表示转换后的卷积的权重，μ_i表示 BN 层的均值，σ_i表示 BN 层的标准差，γ_i和$\boldsymbol{\beta}_i$分别表示 BN 层的尺度因子和偏移因子，W'_i、$\mathbf{b}'_i$分别表示融合之后的卷积的权重和偏置。

中国知网　https://www.cnki.net

（2）将融合后的卷积层转换为 Conv3×3。主要将具有不同卷积核大小的卷积转换为卷积核大小为 3×3 的卷积。整个网络包含两个非 3×3 卷积：一个 Conv1×1 和一个恒等映射层。对于 Conv1×1，将 Conv1×1 的卷积核中的数值移动到 3×3 卷积核的中心点即可；对于恒等映射，使用一个权重值都设置为 1 的 Conv3×3 卷积代换，这样它与输入的特征映射相乘之后，保持了原来的数值。最后，三分支得到的卷积核和偏置分别相加即可。这样，每个 RepVGG 模块转换前后的输出完全相同，因而训练好的模型可以等价转换为只有 3×3 卷积的单路模型。

（3）合并所有分支中的 Conv3×3。将三分支得到的卷积核权重和偏置分别相加即可，从而获得一个融合之后的 Conv3×3 网络层。至此，完成从训练的多分支结构转换为单个的 Conv3×3。

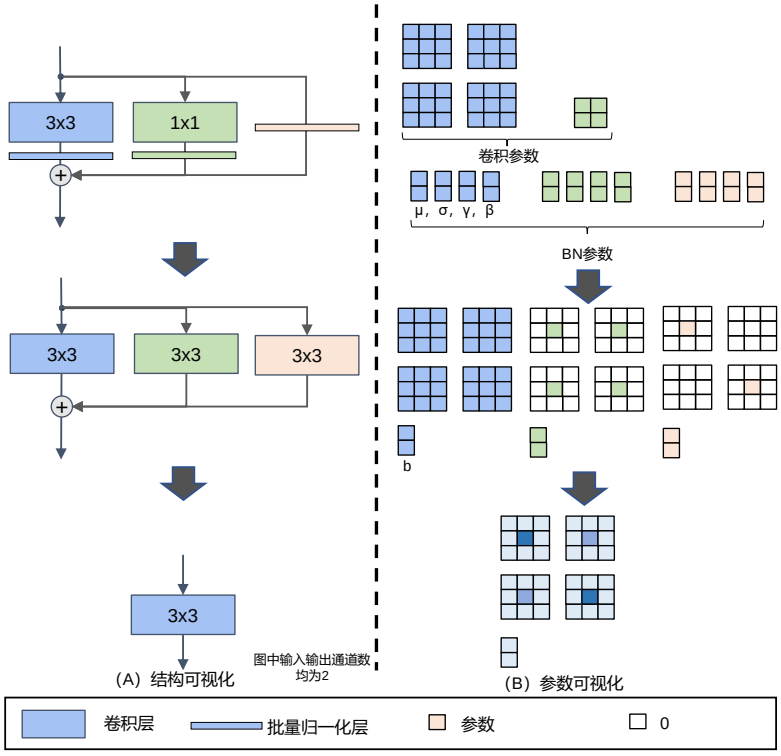


图 3.3 RepVGG 等价转换可视化

Fig.3.3 RepVGG equivalence transformation visualization

综上，结构重参数化让网络在训练时能采用多分支结构，可以带来更高的精度，同时推理时通过结构重参数化等价转化成单分支结构，在保持精度不变的同时又能带来更快的推理速度。

3.2.3 轻量化注意力机制

羽毛球因其尺度太小，同时特征有限而难以检测，因此充分利用图像中羽毛球有限的特征是提高羽毛球检测性能的有效途径之一。注意力机制不仅具有灵活的

中国知网 https://www.cnki.net

结构特性，同时能够加强更有判别力的特征，且能够和 CNN 主干网络做到很好的结合。

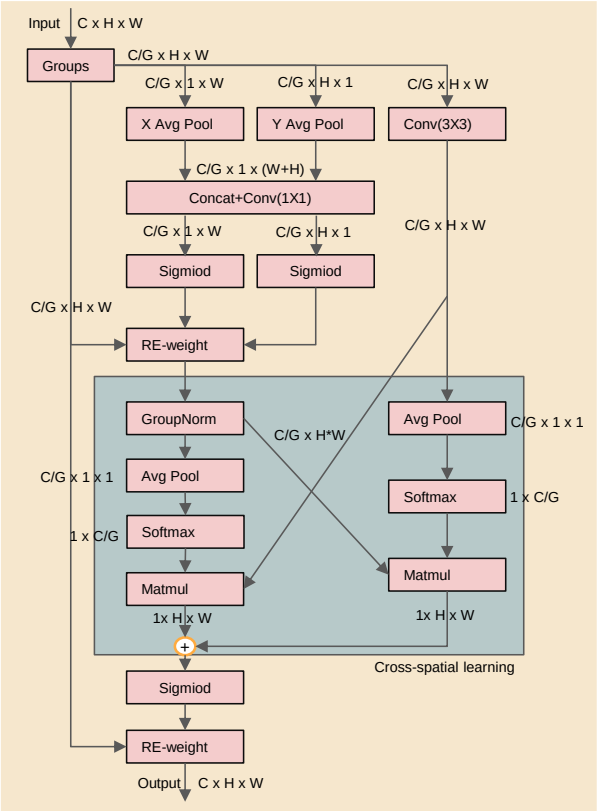


图 3.4 EMA 网络结构

Fig.3.4 EMA network structure

高效多尺度注意力[58]（Efficient Multi-Scale Attention， EMA）是一种轻量化的注意力机制，为本文引入的注意力机制。EMA 结构如图 3.4 所示。EMA 在 CA 注意力的基础上采用特征分组、并行子网和跨空间学习三种策略进行轻量化注意力设计。（1）特征分组。对于任何给定的输入特征图 X，EMA 会将 X 跨通道维度方向划分为 G 个子特征，学习不同的语义信息。（2）并行子网。EMA 采用行子结构进行跨维度交互并建立维度间依赖关系，同时解决模型大而深带来的复杂度和延时问题。EMA 通过三个并行子网来提取分组特征的注意力权重，包括两条 1×1 分支和一条 3×3 分支。在 1×1 分支中采用两个一维局平均池化操作沿 X，Y 两个空间方向对通道进行编码；在 3×3 分支中使用单个 3×3 卷积捕获多尺度特征。这样 EMA 不仅对通道间信息进行编码以调整不同通道的重要性，还将精确的空间结构信息保留到通道中。（3）跨空间学习。它对不同空间维度进行跨空间信息聚合方法，实现更丰富的特征聚合，如图 3.7 阴影部分所示。通过对 1×1 分支和 3×3 分支进行平均池化与 softmax 处理后捕获像素级的成对关系

中国知网 https://www.cnki.net

EMA 是一个轻量化高效的注意力机制。它通过对全局信息进行编码以重新校准每个并行分支中的通道权重，并按照通道维度分组为多个子特征，通过跨维度交互聚合两个并行分支的输出特征，进一步提取更加有用的特征信息，以捕获像素级成对关系与上下文信息。

3.2.4 轻量化 PREMA_Blocks 卷积模块

本文以 PResnet18 为基础，结合轻量化卷积操作 Pconv、结构重参数化和轻量化注意力模块 EMA 设计了一个轻量化卷积模块，命名为 PREMA_Block（Partial Convolution Re-parameterization with EMA Block）模块。模型的 Backbone 共有 4 个特征提取阶段，各包含 2 个 PREMA_Block 模块，每个 PREMA_Block 主要由两个残差模块组成，其中后三个 PREMA_Blocks 进行下采样。PREMA_Block 模块结构如图 3.5 所示。

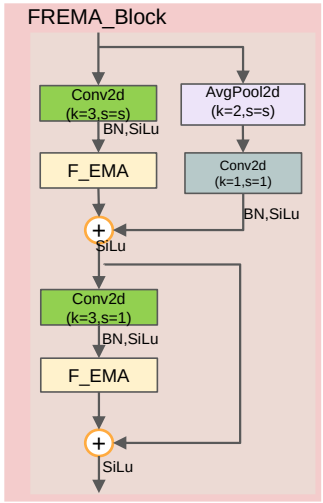


图 3.5 PREMA_Block 网络结构

Fig.3.5 PREMA Block network structure

在 PREMA_Block 模块中，本文设计了一个 F_EMA 模块，每个 F_EMA 模块有一个引入结构重参数化的 PConv 层，后跟 2 个 Conv1×1 层和一个 EMA 注意力模块。它们一起组成为倒置残差块，以丰富目标的特征信息。F_EMA 模块结构如图 3.6 所示。PConv 通过对输入进行部分通道卷积，以降低计算量和特征冗余，同时保持提取的特征信息足够丰富。如图 3.6 灰色部分所示，本文使用结构重参数化解耦训练和推理模型多分支结构优化 Pconv。在训练时采用多分支结构，通过大而深特征提取路径更有效地提取物体的特征，提高模型对特征的学习能力；在推理的时候则使用更快，占用内存更小，计算开销更小的单路结构，提高模型速度并保留多分支检测精度。后接的两个 1×1 卷积组成的逆瓶颈层（一种中间大两头小的结

中国知网 https://www.cnki.net

构），通过将输入特征图通道数扩张 a（图中 a=2）倍，获取更多的特征信息，进一步提高模型特征表达能力。在 F_EMA 模块中，本文引入了 EMA 注意力模块对逆瓶颈层的输出进行全局信息编码，并按照通道维度分组为多个子特征，通过跨维度交互聚合两个并行分支的输出特征，进一步提取更加有用的特征信息。最后输出与恒等映射路径通过相加操作整合到一起作为 F_EMA 模块的输出。

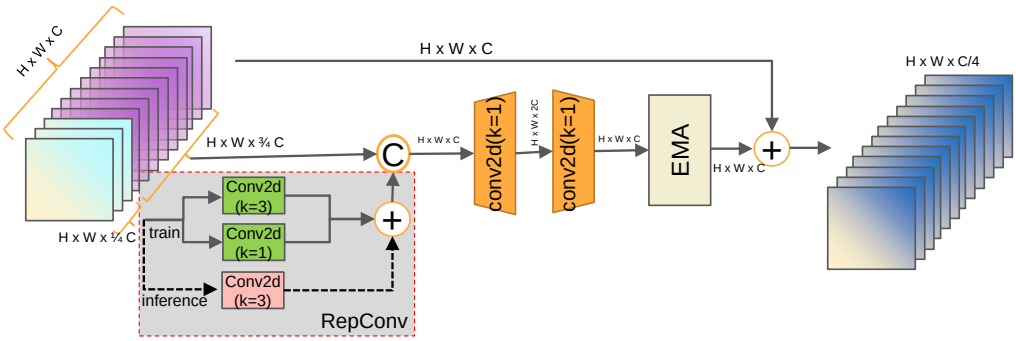


图 3.6 F_EMA 网络结构

Fig.3.6 F_EMA network structure

PREMA_Block 模块，通过 PConv、结构重参数化和轻量化的注意力机制 EMA 的有效结合，同时实现高效的特征提取和计算开销的降低。

3.3 基于注意力机制的并行多尺度特征提取与融合结构设计

RT-DETR 中使用的最近邻插值上采样算子进行上采样，但是它不能充分利用特征的语义信息，因此本节设计了一种注意力双分支上采样模块用来替换最邻近插值上采样算子。按照这个思路，同时设计了一个注意力双分支下采样模块。本节改进了基准模型中的特征融合结构中的特征提取模块，通过设计一个并行三分支空洞卷积模块，增加一个并行多分支多尺度特征融合途径。最后利用本节设计的上/下采样模块和特征提取模块提出了一种并行多分支多特征提取与融合结构，称作并行多分支特征金字塔（PMB-FPN，Parallel Multi-Branch Feature Pyramid Network）。

3.3.1 注意力双分支并行上采样模块

为了将深层的小尺度特征与浅层的大尺度特征融合，上采样是必不可少的环节。RT-DETR 采用最近邻插值算子进行上采样操作。如图 3.7 所示，最近邻插值算子使用手工设计的上采样核，利用像素点的位置关系来度量相互之间的相关性。这种依赖手工制作的上采样核插值，无法对所需要的特征信息进行针对性捕获的能力，并且可能会导致丢失大量特征信息。因此本文设计了一种注意力双分支并行上采样模块（ATP Sample，Attention Two-branch Parallel Upsample）。该模块拥有并行双路的上采样分支，同时采用了一个简单的注意力结构对融合的双分支上采

中国知网　https://www.cnki.net

样特征进行特征选择，增强更有效的特征，同时抑制冗余或无用的特征，提升特征表达的有效性。

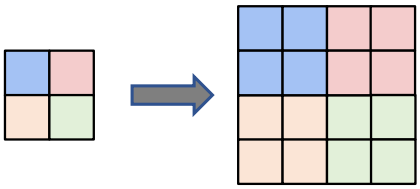


图 3.7 最邻近插值上采样算子

Fig.3.7 Upsampling operator of nearest interpolation

在神经网络中，除最邻近插值上采样之外，常用的上采样算子还有双线性插值、三线性插值、转置卷积等。本节在并行双分支上采样中采用的是最邻近插和转置卷积两种方式。转置卷积是卷积操作的一种“逆”运算，其过程如图 3.8 所示。图 3.8 中分别展示了“卷积核大小为 3×3，步长为 2，padding 为 1”的普通卷积和转置卷积的计算过程，同手工设计采样内核的最邻近插值等上采样算子相比，转置卷积的采样内核是一个可以学习的权重特征（图中大小为 3×3），它可以在网络训练时不断迭代更新。

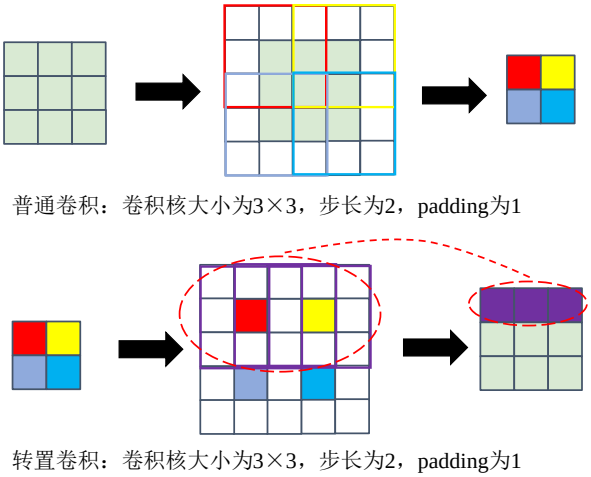


图 3.8 普通卷积与转置卷积计算示意图

Fig.3.8 Calculation diagram of ordinary convolution and transposed convolution

图 3.9 为所设计的 ATP Upsample 的结构。对输入为 H×W 通道数为 C 的特征图，网络通过右侧的并行双分支上采样将特征图宽高加倍（2H×2W），两个分支分别对输入特征的一半特征进行操作，通过多样的上采样方式可以为网络提供多条的特征提取方式，丰富网络的特征表达的多样性。两条分支通过通道合并融合为

中国知网 https://www.cnki.net

宽高为 H×W 通道数为 C 特征组。结构左侧为一个简单的注意力模块，通过对输入特征进行全局池化操作之后，经过一个 1×1 的卷积后使用 Sigmoid 函数对输出进行拟合，然后与双分支上采样融合的特征进行相乘操作，结合 gate 机制对采样后的特征进行特征选择，增强更有效的特征，同时抑制冗余或无用的特征，提特征表达的有效性。

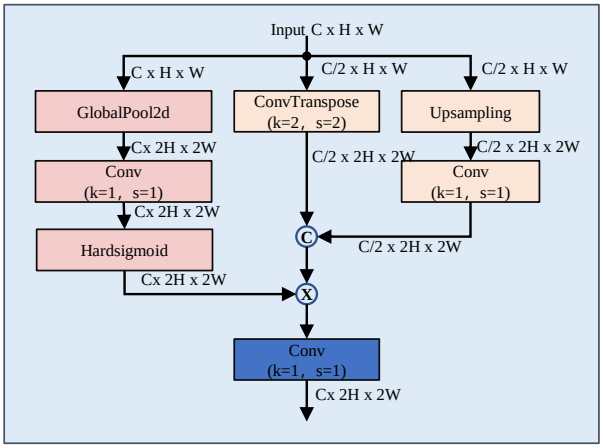


图 3.9 ATP Upsample 模块结构

Fig.3.9 ATP Upsample module structure

3.3.2 注意力双分支并行下采样模块

在将大尺度特征自下向上传递的过程中，下采样操作是必须的。RT-DETR 在进行下采样时，采用的是步长为 2 的卷积操作。深度学习中，常用下采样操作主要由池化操作和步长为 2 的卷积层。其中池化操作结构简单，计算量小，操作方式多样；卷积操作可以在下采样的同时提供一次特征提取，但计算量较池化操作大。本节结合这两种下采样操作，并通过注意力机制进行下采样后的特征选择，在平衡计算量和特征提取的同时，可以为网络提供更多的特征提取途径，丰富网络的特征表达能力，同时 gate 机制的特征选择，可以增强更有效的特征，同时抑制冗余或无用的特征，提特征表达的有效性。本文称之为注意力双分支并行下采样模块（ATP Downsample，Attention Two-branch Parallel Downsample）

图 3.10 为所设计的 ATP Downsample 的结构。对输入为 H×W 通道数为 C 的特征图，网络通过右侧的并行双分支下采样将特征图宽高减半（H/2×W/2），两个分支（步长为 2 的卷积和最大池化）分别对输入特征的一半特征进行操作，通过多样的下采样方式可以丰富特征的多样性。两条分支通过通道合并融合为宽高为 H/2×W/2 通道数为 C 特征组。同上采样模块一样与左侧的通道注意力进行相乘操作进行特征选择，增强更有效的特征，同时抑制冗余或无用的特征，提特征表达的

中国知网 https://www.cnki.net

有效性。

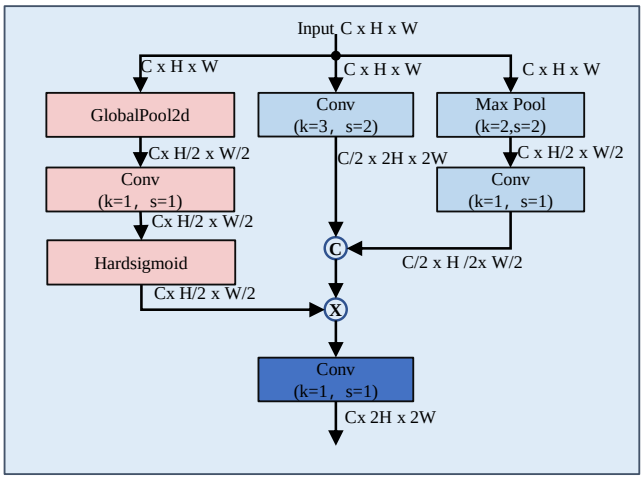
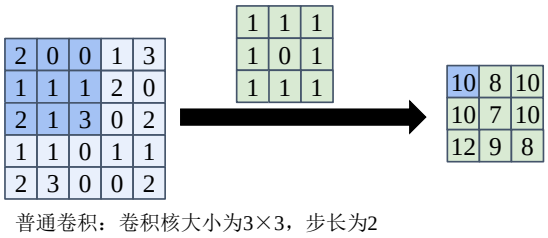


图 3.10 ATP Downsample 模块结构

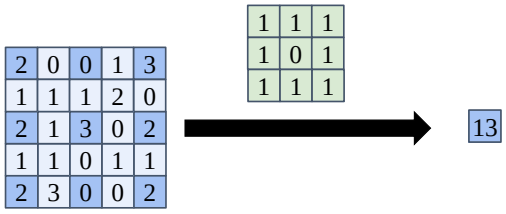
Fig.3.10 ATP Downsampling module structure

3.3.3 并行空洞卷积特征提取模块

普通卷积主要通过调节卷积核的大小和步长来控制输出特征图的感受野，而扩张卷积则可以灵活地设置采样间隔来增大感受野。图 3.11 为普通卷积与空洞卷积的对比图，可以看出来，空洞卷积通过调节空洞率可以轻易的增大感受野，实现多尺度特征的提取。本节采用空洞卷积进行多尺度特征提取模块的设计。模块采用不同空洞率的崆峒卷积设计并行多分特征提取模块，该模块可以有效的提取不同尺度的特征，以此提高网络对特征图中局部信息和上下文信息的捕捉能力，提高其表征复杂目标的能力。本文称此模块为多分支空洞卷积模块（MAC，Multi-branch Atrous Convolition）。



普通卷积：卷积核大小为3×3，步长为2



膨胀卷积：卷积核大小为3×3，步长为2，空洞率为2

图 3.11 普通卷积与空洞卷积操作流程

Fig.3.11 Operation flow of ordinary convolution and empty convolution

中国知网 https://www.cnki.net

图 3.12 为 MAC 模块结构，其中 PMBAC Module（Parallel Multi-Branch Atrous Convolition Module）为并行多分支空洞卷积模块。MAC 拥有两条分支，一条为残差连接，另外一条则通过为多尺度特征提取分支。对尺度特征提取分支，它首先利用两个并行的 1×1 卷积层丰富网络的非线性，而后通过并行三分支空洞卷积，卷积核大小为 3×3，空洞率分别为 1，3，5 进行不同尺度特征的提取，三分支融合后的输出经过一个 1×1 的卷积进行通道的调整。最后使用两个 1×1 的卷积组成的导致残差结构调整残差分支和多尺度特征提取分支融合后的特征通道数，同时进一步提取特征，保持输入输出通道数一致。

MAC 通过使用具有不同膨胀率的并行空洞卷积，能够有效地提取不同尺度的特征，使得网络能够捕捉特征中的局部和上下文信息，提高其表征复杂目标的能力。

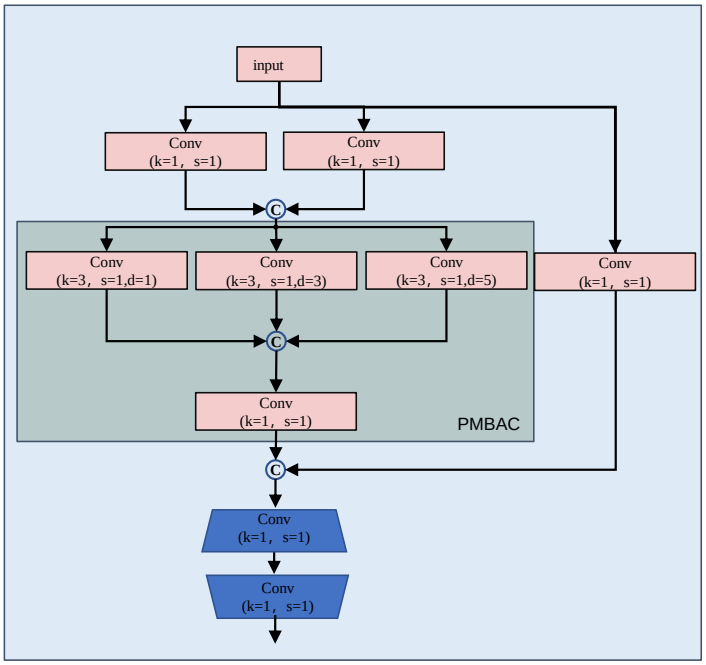


图 3.12 MAC 模块结构

Fig.3.12 MAC module structure

3.3.4 并行多分支多特征提取与融合网络

本节提出了一种并行多分支多特征提取与融合结构，称作并行多分支特征金字塔（PMB-FPN，Parallel Multi-Branch Feature Pyramid Network）。该结构基于利用前面小节中设计的上/下采样模块和多尺度特征提取模块，如图 3.13 所示。

中国知网 https://www.cnki.net

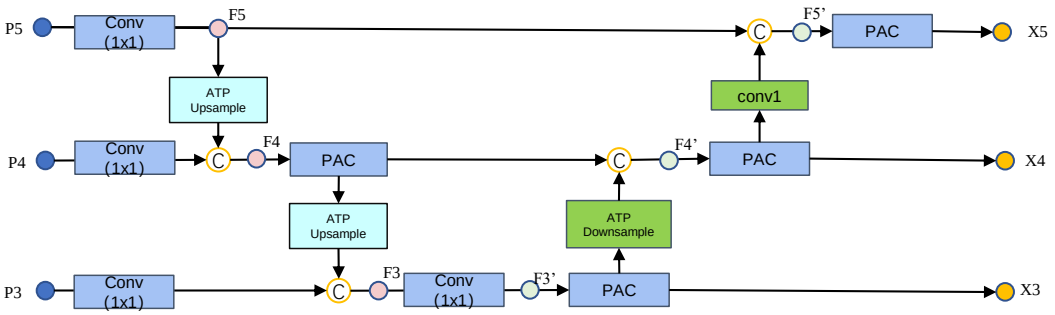


图 3.13 PMB-FPN 网络结构

Fig.3.13 Network structure of PMB-FPN

PMB-FPN 网络在内部采用串行的跨层连接结构，同时在细节模块引入了行多分支结构。串行的跨层连接结构让网络通过自上向下和自下向上两条路径传递和融合高层语义特征和低层位置特征信息；行多分支结构使用具有不同膨胀率的空洞卷积并行提取不同尺度的图像特征，增强网络捕捉特征中的局部和上下文信息的能力。

3.4 小目标检测层

在卷积神经网络中，网络深度的增加在增强网络语义信息提取能力，扩大深层特征感受野的同时，导致特征图中细节信息丢失，这对小目标的检测是十分不利的。因此学者使用多尺度信息进行目标检测，利用高层的特征检测大目标，利用低层特征去检测小目标。因此，本章在原有的基础上引入分辨率更大，携带细节信息更多的 P2 特征层来提高模型对羽毛球的检测效果，提高检测精度，减少漏检现象的发生。一般羽毛球在图像中所占的像素很少，故而更容易出现漏检、误检。通过增加分辨率更大 P2 层，网络能够更敏锐地检测和定位羽毛球，提高检测的准确性。

本节结合本文提出的轻量化主干模块 FREMA_block 模块与本章提出的 PMB-FPN 结构，并添加了 P2 特征层设计了一个轻量化羽毛球检测模型，本文称之为 Badminton-DETR，整体网络结构如图 3.14 所示。

Badminton-DETR 在主干网络部分使用轻量化主干网络进行特征提取，通过 PConv、结构重参数化和轻量化的注意力机制 EMA 的有效结合，同时实现高效的特征提取和计算开销的降低；在特征融合部分，PMB-FPN 与基准网络的特征融合结果相比，网络采用更少的卷积层，同时使用并行多分支结构的上/下采样模块和特征提取模块，为网络提供更多的特征提取途径，丰富网络的特征表达能力，使得网络能够捕捉特征中的局部和上下文信息，提高其表征复杂目标的能力。

中国知网 https://www.cnki.net

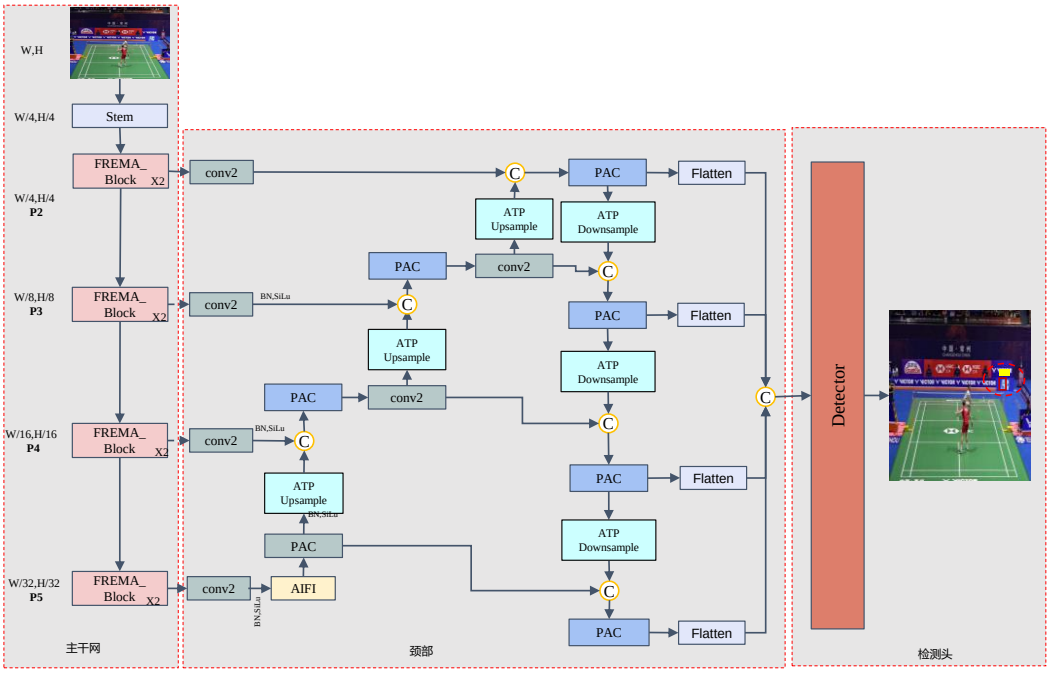


图 3.14 添加 P2 特征层的多尺度特征融合结构示意图

Fig.3.14 Schematic diagram of multi-scale feature fusion structure with P2 feature layer added

3.5 损失函数优化

本小节从羽毛球小目标特点出发，进行 IoU 损失函数计算方法优化。小目标边框的容忍度低，一个微小的扰动可能都会导致小目标超出边框，从而被判定为负样本。此外，小目标对网络损失的贡献小。因此通过提高小目标 IoU 损失，提升小目标对网络损失的贡献，让更多小目标样本被分为正样本，可以有效提高检测效果。

RT-DETR 整体损失函数计算公式如下：

$$\mathcal{L}oss = \mathcal{L}_{\text{cls}} + \mathcal{L}_{\text{bbox}} = \mathcal{L}_{cls} + \mathcal{L}_1 + \mathcal{L}_{IoU} \tag{3.3}$$

其中，$\mathcal{L}_{cls}$是物体分类损失，采用 Varifocal Loss；$\mathcal{L}_{bbox}$为边界框损失，为两部分之和$\mathcal{L}_1 + \mathcal{L}_{IoU}$，其中$\mathcal{L}_{IoU}$部分便是本小节研究的重点。

本文结合 Inner-IoU 和 MPD-IoU 损失进行 IoU 损失函数的优化，得到 Inner-MPDIoU 损失，优化 IoU 损失的计算方式。如图 3.15 所示，Inner-MPDIoU 计算公式如下：

$$\begin{aligned}\mathcal{L}_{IoU} &= 1 - Inner - MPDIoU \\ &= 1 - \left(\text{IoU}^{\text{inner}} - \frac{\text{d}_1^2}{\text{W}^2 + \text{H}^2} - \frac{\text{d}_2^2}{\text{W}^2 + \text{H}^2}\right)\end{aligned} \tag{3.4}$$

其中，$d_1^2 = \left(x_1^p - x_1^g\right)^2 + \left(y_1^p - y_1^g\right)^2$，$d_2^2 = \left(x_2^p - x_2^g\right)^2 + \left(y_2^p - y_2^g\right)^2$。$\text{IoU}^{\text{inner}}$计算方式如下所示：

中国知网 https://www.cnki.net

$$x_1^{g\prime} = x_c^g - \frac{W^g * \text{ratio}}{2}, x_2^{g\prime} = x_c^g + \frac{W^g * \text{ratio}}{2} \tag{3.5}$$

$$y_1^{g\prime} = y_c^g - \frac{H^g * \text{ratio}}{2}, y_2^{g\prime} = y_c^g + \frac{H^g * \text{ratio}}{2} \tag{3.6}$$

$$(x_1^{p\prime} = x_c - \frac{w * \text{ratio}}{2}, x_2^{p\prime} = x_c + \frac{w * \text{ratio}}{2} \tag{3.7}$$

$$y_1^{p\prime} = y_c - \frac{h * \text{ratio}}{2}, y_2^{p\prime} = y_c + \frac{h * \text{ratio}}{2} \tag{3.8}$$

$$\begin{aligned}\text{inter} = (min(x_2^{g\prime}, x_2^{p\prime}) - \max(x_1^{g\prime}, x_1^{p\prime})) * (\min(y_2^{g\prime}, y_2^{p\prime}) \\ - \max(y_1^{g\prime}, y_1^{p\prime}))\end{aligned} \tag{3.9}$$

$$\text{union} = (\mathrm{W^p} * \mathrm{H^p}) * (\text{ratio})^2 + (W^g * H^g) * (\text{ratio})^2 - \text{inter} \tag{3.10}$$

$$\mathrm{IoU^{inner}} = \frac{\text{inter}}{\text{union}} \tag{3.11}$$

其中，ratio放缩因子的取值范围为[0.5,1.5]，ratio 的选取与数据集分布有关。

Inner-MPDIoU 损失函数在计算预测框位置损失时，同时考虑到重叠与非重叠区域、中心点距离、宽高偏差并简化了计算过程。同时当 ratio 大于 1，增大的辅助边框扩大了回归的有效范围，可以有效提高低 IoU 的回归增益，即增大小目标预测边框的回归增益，让更多的小目标样本被分类为正样本，从而提高小目标对损失的贡献。

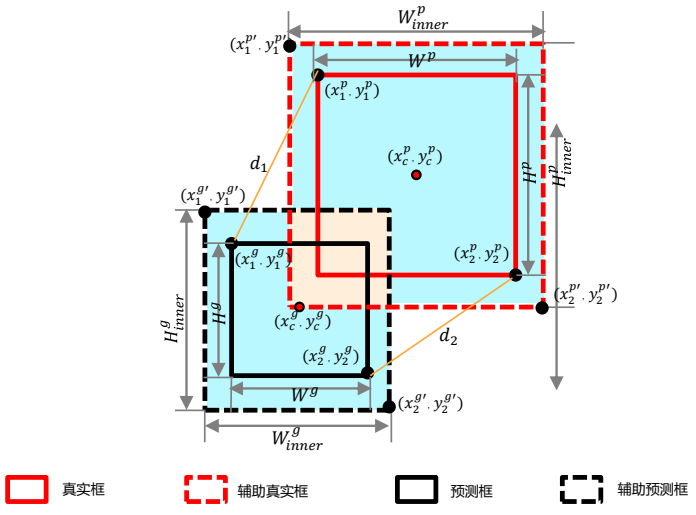


图 3.15 Inner-MPDIoU 示意图

Fig.3.15 Diagram of Inner-MPDIoU

3.6 实验与分析

3.6.1 实验环境与参数设置

（1）实验环境

中国知网 https://www.cnki.net

本文实验在 NVIDIA RTX3070 上进行，显存大小为 8G。实验基于深度学习框架 PyTorch1.13.0，计算机环境为 Ubuntu20.04 操作系统。

（2）参数设置

本文使用 AdamW 优化器训练模型。模型训练超参数设置如表 3.2 所示。

表 3.2 模型训练超参数

Table 3.2 Model training hyperparameters

参数名称	参数值
learning rate	0.0001
weight decay	0.0001
global gradient clip norm	0.1
linear warmup steps	2000
ema decay	0.9999
data augmentation	colour distort, expand, crop, flip, resize
Input image-size	640 x 640
epochs	150

3.6.2 损失函数超参数实验

本文改进的损失函数中，缩放因子 ratio 的大小将会影响模型效果，因此本文设计了实验以探索最优的 ratio 大小。本文使用的羽毛球数据集属于小目标数据集，因此选择从 ratio=1.0 开始进行实验。实验结果见表 3.5。由表可知，ratio 在 1.0~1.3 范围内，模型的精度呈现上升趋势，但当 ratio 大于 1.3 时，精度开始下降的趋势。因此对 1.2~1.3 范围内进行细化实验，当 ratio 设为 1.24，检测效果最好，如表 3.3 中加粗部分。因此本文选择 ratio 为 1.24，以获取最优的检测效果。

表 3.3 损失函数超参数 ratio 对模型性能的影响

Table 3.3 Influence of loss function hyperparameter ratio on model performance

ratio	mAP_{50}	$mAP_{50:95}$	Recall	Pre
1.0	82.8%	46.1%	76.9%	91·.7%
1.1	83.7%	47.6%	78.1%	92.9%
1.2	84.1%	48.6%	78.4%	93.5%
1.22	84.5%	48.9%	79.9%	94.7%
1.24	**85.2%**	**49.8%**	**80.6%**	**95.6%**

中国知网 https://www.cnki.net

表 3.3 损失函数超参数 ratio 对模型性能的影响（续）

Table 3.3 Influence of loss function hyperparameter ratio on model performance（continued）

ratio	mAP_{50}	$mAP_{50:95}$	Recall	Pre
1.26	84.7%	48.7%	79.7%	93.9%
1.3	84.3%	47.3%	78.9%	92.6%
1.4	82.6%	46.9%	77.6%	90.7%

注：表中加粗部分表示该指标下最优值。

3.6.3 对比实验

YOLO 系列算法是实时检测算法的代表，其中 YOLOv5 是使用范围最广的实时检测算法之一，YOLOv8 则是 YOLO 系列最新成果代表。此外 Tracknetv2 是羽毛球检测算法是羽毛球检测算法中最好的算法。因此，本文选择 YOLOv5（s、m、l）、YOLOv8（s、m、l）和 Tracknetv2 作为对比组，其中 RT-DETR(r18)为基准模型，Badminton-DETR 是本章提出的算法。所有实验均在章节 2.4.1 所提出的数据集上进行，YOLO 系列算法训练 epoch 为 100，其余参数见章节 3.6.1。本章对比实验结果如表 3.4 所示。

表 3.4 不同算法检测对比实验结果

Table 3.4Test results of different algorithms

模型	参数量	FLOPs	FPS	mAP_{50}	$mAP_{50:95}$	Recall	精确率
YOLOv5s	**7.2M**	**16.5G**	80.6	55.4%	24.0%	27.1%	85.4%
YOLOv5m	21.2M	49G	52.6	65.7%	33.5%	36.2%	86.9%
YOLOv5l	46.5M	109.1G	36.5	71.8%	34.3%	40.7%	87.3%
YOLOv8s	11.2M	28.6G	83	55.6%	23.0%	27.1%	82.7%
YOLOv8m	25.9M	78.9G	54.3	67.2%	33.4%	36.8%	84.7%
YOLOv8l	43.7M	165.2G	38.7	73.8%	34.1%	40.7%	85.4%
Tracknetv2	11.3M	112.5G	49.5	83.8%	48.7%	80.4%	95.2%
RT-DETR(r18)	20.0M	58.3G	56.6	82.8%	47.3%	78.6%	87.7%
RT-DETR(r34)	31.1M	88.8G	48.2	82.9%	50.1%	79.4%	95.3%
RT-DETR(r50)	42M	129.6G	39.6	83.6%	**50.6%**	81.4%	95.5%
Badminton-DETR	15.80M	80.8G	58.8	**87.3%**	**54.3%**	**83.3%**	**95.9%**

注：表中“(r18)”、“(r34)”、“(r50)”分别表示使用 Resnet18、Resnet34、Resnet50 作为主干网络，RT-DETR(r18)为基准网络。表中加粗部分表示该指标下最优值。

中国知网 https://www.cnki.net

如表 3.4 所示，本章提出的算法，mAP_{50}、$mAP_{50:95}$、精确率和召回率分别为87.3%、54.3%、95.9%、83.3%，均超过了对比实验中的其他方法，即在相同条件下本章提出的算法所检测出的羽毛球精度更高，漏检更少。同时在速度上达到了58.8FPS，满足实时性的要求，即本文所提出的方法在检测精度和检测速度上综合表现是最优的，为目前速度和精度平衡最好的羽毛球算法。本章所提出的方法与原有的 RT-DETR（Resnet18）相比，提高了羽毛球检测的精度和速度。本文算法虽然计算量增加了 22.5GFLOPs，但是其余参数都有较大的提升，其中参数量有较大的下降，FPS 提升了 2.2，mAP_{50}、$mAP_{50:95}$、精确率和召回率分别提高了 4.5%、7.0%、8.2%和 4.7%，提升较为明显。

本章算法训练曲线见图 3.16，可以看到算法已经完全收敛，同时没有出现过拟合现象。检测效果可视化见图 3.17，在不同的检测背景下，本章所提出的算法都可以实现羽毛球的检测。

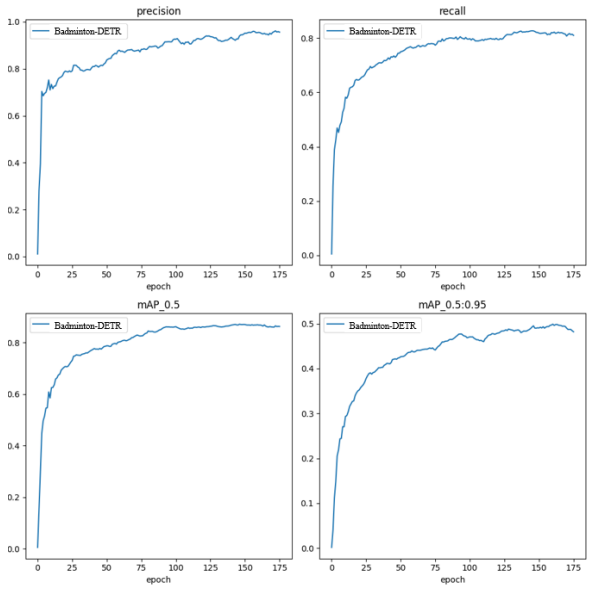


图 3.16 RTRP-DETR 训练曲线

Fig.3.16 RTRP-DETR training curve



图 3.17 RTRP-DETR 羽毛球检测效果

Fig.3.17 Detection effect of RTRP-DETR badminton

中国知网 https://www.cnki.net

3.6.4 消融实验

为了更好的说明本文改进模块对于模型检测效果提升的有效性，本文在羽毛球数据集上进行了消融实验。实验结果如表 3.5 所示

表 3.5 消融实验结果

Table 3.5 Results of ablation experiment

Inner-MPDIoU	PREMA_Block	PMB-FPN	参数量	FLOPs	FPS	mAP_{50}	$mAP_{50:95}$	召回率	精确率
			20.0M	58.3G	56.6	82.8%	47.3%	78.6%	87.7%
	√		16.9M	**51.4G**	**68.3**	83.9%	46.8%	78.2%	87.5%
√			20.0M	58.3G	56.6	85.0%	48.8%	80.2%	95.2%
√	√		16.9M	**51.4G**	**68.3**	85.2%	49.8%	80.6%	95.6%
		√	18.7M	86.3G	54.8	85.2%	50.9%	80.6%	93.1%
√	√	√	**15.8M**	80.8G	58.8	**87.3%**	**54.3%**	**83.3%**	**95.9%**

注：表中“√”表示添加该模块。表中加粗部分表示该指标下的最优值。

如表 3.5 所示，本文设计的组件对模型检测羽毛球的精度和速度都有所提升。当使用 PREMA_Block 代替原 Resnet18 中的主干网模块时，相比基准模型，模型参数量下降了 15.5%，计算量下降了 6.9GFLOPs，FPS 提高了 11.7，$mAP_{50:95}$上升了 1.1%，且mAP_{50}、召回率和精确率分别仅下降了 0.5%、0.4%和 0.2%。然后，使用 Inner-MPDIoU 替代基准网络中的 GIoU 损失函数模型时，相比基准模型在精度指标上均有提升，其中mAP_{50}、$mAP_{50:95}$、精确率和召回率四项指标分别提升了 2.2%、1.5%、7.5%和 1.6%。在使用本文提出 PMB-FPN 代替基准网络中的特征融合模块时，计算量有所增加，检测速度稍微降低，mAP_{50}、$mAP_{50:95}$和精确率分别提高了 2.4%、3.6%和 5.4%。当添加本文所有改进策略之后，本文所提出 Badminton-DETR 羽毛球检测算法与基准网络相比，检测的精度和速度都有明显的提高，具体提升有：参数量有明显下降，FPS 提升了 2.2，mAP_{50}、$mAP_{50:95}$、精确率和召回率分别提高了 4.5%、7.0%和 8.2%和 4.7%，提升较为明显。

3.7 本章小结

本章针对羽毛球检测任务，基于 RT-DETR 设计了一个高效且轻量级的羽毛球检测网络 Badminton-DETR。该模型优化了网络的主干网络与损失函数，提出了一个 PMB-FPN 多尺度特征融合网络，显著提升了羽毛球检测效果。本章通过引入高效卷积操作与注意力模块，结合结构重参数化技术进行轻量化设计，降低网络参数

中国知网 https://www.cnki.net

量的同时，保持网络精度。特别是针对羽毛球小目标的特点，网络通过添加 P2 特征层，引入注意力双分支并行上/下采样模块，以及设计轻量化的并行空洞卷积特征提取模块（MAC），提出了新的 FPN 变体，PMB-FPN。PMB-FPN 网络通过串行的跨层连接和并行多分支结构融合，不仅加强了网络对高层语义和低层位置特征信息的整合能力，还通过不同膨胀率的空洞卷积提取了多尺度特征，增强了网络捕捉局部和上下文信息的能力。针对损失函数，本章提出 Inner-MPDIoU 损失函数，进一步解决了小目标检测中边框容忍度低和网络损失贡献小的问题，使得模型能够更好地适应羽毛球检测任务的特殊需求。实验结果表明，Badminton-DETR 在保持较小模型体积的同时，实现了更高的检测速度和精度，显著优于基准模型。

中国知网 https://www.cnki.net

4 基于 YOLO-Pose 的运动员姿态估计算法

作为羽毛球运动的发起者，利用姿态估计技术，可以获取到运动员在击球瞬间的身体姿态，包括运动员的手臂位置、身体姿态等，它们对于准确的判断击球帧至关重要。本章基于 YOLO-Pose[66]进行运动员姿态估计算法设计。针对原 YOLO-Pose 在多尺度特征融合网络部分无法区分不同层特征对网络的贡献问题，本章引入了加权双向特征金字塔网络（BiFPN），通过特征加权的方式区分不同层特征对网络的贡献。并且对网络的特征融合方式做进一步研究，通过对比不同的融合方式，探究了一种最优的特征融合方法。

4.1 基准模型选择

人体姿态估计是计算机视觉领域的重要任务之一，用来识别和定位人体关节的位置。本文主要研究基于深度学习的多人姿态估计算法，根据其方案流程可分为自上而下和自下而上两种。自上而下的方法依赖于单独的人体检测器，并需要单独估计每个人的姿势，通常是计算密集型的，并且不是真正的端到端系统。而自下而上的方法能够更快地实现实时姿态估计。自下而上的方法在检测图像中所有人的身体部位（如关节、四肢等）后，再通过算法进行分组。这种方法在处理多人姿态估计时，其计算成本随着图像中人数的增加保持稳定，相比于自上而下的方法更加高效。

近些年，基于深度学习的方法在人体姿态估计领域取得了重大突破，涌现大量的姿态估计算法。本文使用官方模型在 COCO 测试数据集上详细比较几种姿态估计算法的性能，采用精度指标为mAP_{50}与 AR，速度指标为参数量与计算量（FLOPs），以进一步对比两种多人姿态估计算法优劣以及各个算法之间的区别，以便选择一种更合适的模型作为基准模型进行运动员姿态估计算法设计。在自上而下算法中，本文选择 HRNet[37]与 CPN[63]两个算法，其中 HRNet 选了 W32 与 W48 两个尺度；在自下而上算法中，本文选择 OpenPose[41]、HigherHRNet[64]与 YOLO-pose 四个算法。在输入尺寸方面，自上而下算法采用统一的尺寸 384×288，并且参数两与计算量仅计算姿态估计部分算法，不包括人体检测器算法；自下而上中 OpenPose 算法不限制输入尺寸为方便比较，均采用 512x512 输入尺寸。与 YOLO-pose 和 HigherHRNet 要求尺寸固定，采用 640×640 输入尺寸。

该实验在装有两块相同的 NVIDIA RTX2080Ti 显卡的计算机上完成，实验基于深度学习框架 PyTorch1.13.0，计算机环境为 Ubuntu20.04 操作系统。通过实验对各个模型的性能指标进行评估，结果如表 4.1 所示。

中国知网 https://www.cnki.net

表 4.1 姿态估计模型性能对比

Table 4.1 Performance comparison of attitude estimation models

	模型	输入尺寸	参数量	FLOPs	mAP_{50}	AR
自上而下	HRNet-W32	384×288	28.5M	**16.0G**	92.5%	80.1%
	HRNet-W48	384×288	63.6M	32.9G	**92.5%**	**80.5%**
	CPN	384×288	102M	13.9G	91.4%	78.5%
自下而上	OpenPose	512×512	52.3M	136G	84.9%	66.5%
	HigherHRNet	640×640	28.6M	47.9G	87.5%	
	YOLO-pose	640×640	**26.4M**	81.0G	89.4%	73.2%

注：表中加粗部分表示该指标下最优值。

表 4.2 添加人体检测器的自上而下算法性能

Table 4.2 Performance of top-down algorithm for adding human body detector

模型	HRNet-W32	HRNet-W48	CPN
参数量	54.4M （28.5M+25.9M）	89.5M （63.6M+25.9M）	127.9M （102M+25.9M）
FLOPs	94.9G （16.0G+78.9G）	111.8G （32.9G+78.9G）	92.8G （13.9G +78.9G）

注：所有参数为“模型+YOLOv8m”之和的性能指标，其中 YOLOv8m 为采用的人体检测器。

由表 4.1 可知，自上而下算法在精度与计算量上总体都小于自下而上的算法，但是由于该算法需要利用人体检测算法的检测结果作为输入，因此其综合计算量要远高于这个值。例如，若自上而下算法均采用 YOLOv8m 作为人体检测器，该算法计算量为 78.9GFLOPs，那么算法的的速度性能指标如表 4.2 所示。自下而上的检测算法在精度指标上与自上而下算法相比略低，但是就完成姿态检测整个任务所需的总计算资源，即参数量与计算量指标上，相比总体要远小于自上而下算法。就具体对比两种算法中最优算法：HRNet-W48 与 YOLO-pose。两种算法的mAP_{50}相差 3.1%，召回率相差 7.3%，但就两算法完成姿态估计整个任务所需的模型参数量相差 2 倍。同时 YOLO-Pose 继承 YOLO 快速检测的优势，在面对多人检测时能够保持快速且稳定的检测。

综上所述，在综合评估模型在完成姿态估计整个任务所表现出的性能后，本文选择以 YOLO-Pose 作为研究运动员姿态估计的基准模型。

4.2 YOLO-Pose 网络

YOLO-Pose 网络框架图如图 5.2 所示。YOLO-Pose 是一个端到端的的多人姿

中国知网 https://www.cnki.net

态估计算法，其性能超过了很多的自上而下和自下而上的算法达到 SOTA（State of the arts）。YOLO-Pose 同其他自下而上的方法类似，是一阶段方法，但是它不采用热力图（heatmap），而是采用将人体关节点与锚框匹配的策略，解决了自下而上姿态估计中靠近人体的关节点混淆的问题。相较于自上而下的方法在遮挡下表现很差，YOLO-Pose 采用的关节点与锚框匹配的策略可以允许关节点出现在预测边框外，因此当关键点由于遮挡而位于边界框之外，它们仍然可以被正确地预测出来。总的来说，YOLO-Pose 利用目标检测的思路解决多人姿态估计问题，只需要使用目标检测的后处理方式而不需要如像素级 NMS、细化等复杂的后处理，实现实时稳定的多人姿态估计。因此本文选择 YOLO-Pose 为基准。

如图 4.1 所示，YOLO-Pose 以 YOLOv5 作为基准网络进行设计，主干网络采用 CSPdarknet53 骨干网络，产生不同尺度的特征图（P3，P4，P5，P6）。然后采用 PANet 融合不同尺度的特征图。最后将每个分支融合后的特征图送入解耦检测头进行关节点检测和回归框检测。

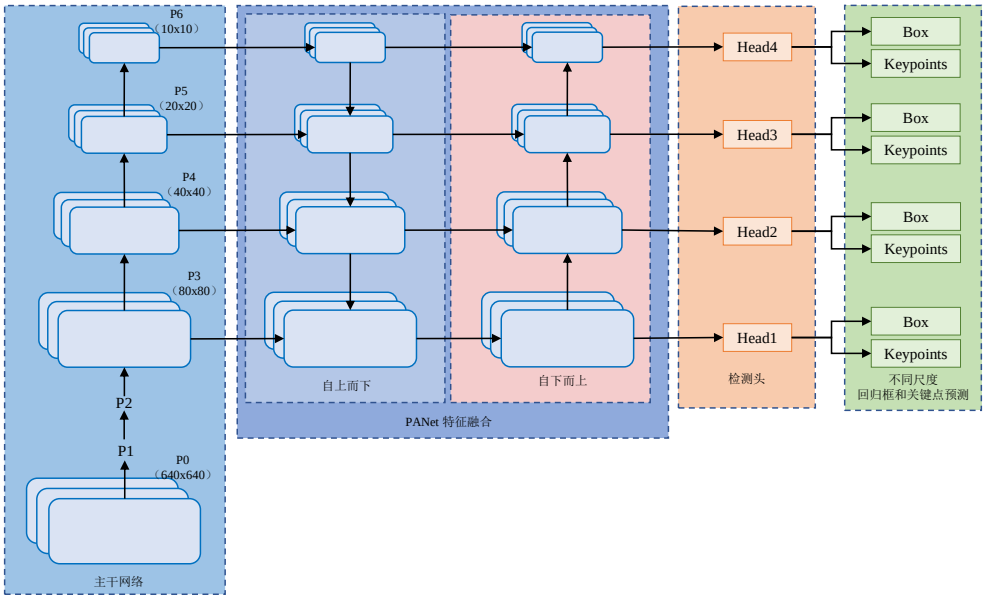


图 4.1YOLO-Pose 网络框架图

Fig.4.1 YOLO-Pose network framework

基于锚框的多人姿态表示。YOLO-Pose 认为人体姿态估计可以归结为一个单一人体检测问题，每个人有 17 个关键点，每个关键点使用位置和置信度进行标记：{x，y，conf}。因此，一个锚框共包含 17 个关键点，51 个值。那么对于每个锚框，关节点检测头预测 51 个值，回归框检测头预测 6 个值。对包含 n 个关节点的锚框，预测结果为：$P_v = \{C_x, C_y, W, H, \text{box}_{\text{conf}}, \text{class}_{\text{conf}}, K_x^1, K_y^1, K_{\text{conf}}^1, \cdots, K_x^n, K_y^n, K_{\text{conf}}^n\}$。对于给定的图像，图像中单个人体的锚框存储他的整个 2D 姿态和边框信息P_v。其中边

中国知网 https://www.cnki.net

框坐标用锚框的中心点坐标表示，边框尺寸为归一化尺寸（锚框宽高与图像宽高比值）。关键点位置同样使用锚框中心点坐标表示。

损失函数。YOLO-Pose 边框损失函数使用 CIoU Loss。YOLO-Pose 在 4 个尺度特征图上进行预测，在每个特征图上每个位置设置 2 个锚框进行匹配。对于一个给定的真实边界框，他与第 k 个匹配位置为（i,j），尺度为 s 的预测锚框的损失函数计算如式（4.1）所示。

$$L_{box}(s,i,j,k) = (1 - CIoU(Box_{gt}^{s,i,j,k}, Box_{pred}^{s,i,j,k})) \tag{4.1}$$

其中，$Box_{pred}^{s,i,j,k}$是第 k 个预测锚框，尺度为 s 的预测框。

对关节点损失，YOLO-Pose 没有采用 L1 损失，因为 L1 损失是一种简单的损失函数，无法获取最佳的 OKS（关键点相似性）指标。YOLO-Pose 将 IoU 损失从边框扩展到关节点，从而可以使用 OKS 作为损失函数。OKS 损失本质上是尺度不变的，并且某些关键点的比重会大一点以表示该关键点的重要性，例如，一个人头部上的关键点（眼睛、鼻子、耳朵）比他身体上的关键点（肩膀、膝盖、臀部等）受到的惩罚更多。预测的边界框存储一个人所有的关键点信息，当一个真实框与在特征图上某个位置生成的锚框相匹配，此时将预测相对于锚框中心点的所有关键点。对每个关键点分别计算 OKS，然后求和，得到最终的关键点 IOU 损失。如公式（4.2）所示。

$$\begin{aligned} \mathcal{L}_{kpts}(s,i,j,k) &= 1 - \sum_{n=1}^{N_{kpts}} \text{OKS} \\ &= 1 - \frac{\sum_{n=1}^{N_{kpts}} \exp(\frac{d_n^2}{2s^2k_n^2})\delta(v_n > 0)}{\sum_{n=1}^{N_{kpts}} \delta(v_n > 0)} \end{aligned} \tag{4.2}$$

其中d_n为预测框位置与真实框位置的欧氏距离，k_n表示关键点权重，s 为目标尺寸，$\delta(v_n)$为关键点是否遮挡。

并且对每个关键点设置一个可学习的置信度参数，来表示锚框中的人体是否包含次关键点，如公式（4.3）所示。

$$\mathcal{L}_{\text{kpts_conf}}(s,i,j,k) = \sum_{n=1}^{N_{kpts}} BCE(\delta(v_n > 0), p_{kpts}^n) \tag{4.3}$$

其中，p_{kpts}^n为第 n 个关键点预测的置信度。最终损失函数如公式（4.4）所示。

$$\begin{aligned} \mathcal{L}_{\text{total}} = \sum_{s,i,j,k} (&\lambda_{cls}\mathcal{L}_{\text{cls}} + \lambda_{\text{box}}\mathcal{L}_{\text{box}} + \lambda_{\text{kpts}}\mathcal{L}_{kpts} \\ &+ \lambda_{\text{kpts_conf}}\mathcal{L}_{\text{kpts_conf}}) \end{aligned} \tag{4.4}$$

中国知网 https://www.cnki.net

其中，超参数λ_{cls}=0.5，λ_{box}=0.05，λ_{kpts}=0.1，λ_{kpts_conf}=0.5，用于不同尺度上的损失。

4.3 多尺度特征融合方式优化

4.3.1 加权双向特征金字塔网络

在神经网络中，高层特征拥有大感受野和较强的语义信息表征能力，但特征图分辨率比较低，空间几何特征缺乏；低层特征的感受野虽小，语义信息表达能力也较弱，但它的特征图分辨率大，空间几何细节充分。因此，学者通过对融合各层次特征，提高目标检测的效果。YOLO-Pose 在特征融合阶段采用“FPN+PAN”结构，如图 4.2 左侧结构图所示，仅采用简单的通道拼接融合融合不同尺度的特征图。然而，不同尺度的输入特征图携带的信息侧重点也不一样，它们对最后融合输出特征图的贡献也是不同的，所以简单的通道拼接方式无法达到最优的结果。为了解决这一问题，本文引入加权双向特征金字塔网络[19]（BiFPN）结构，给不同尺度的特征添加一个可学习的权重参数。这样在训练过程就可以让网络自主探索每个输入特征的重要性，动态调整每个特征对输出特征图的贡献度，从而选择对网络最有效的权重组合实现特征有效融合。

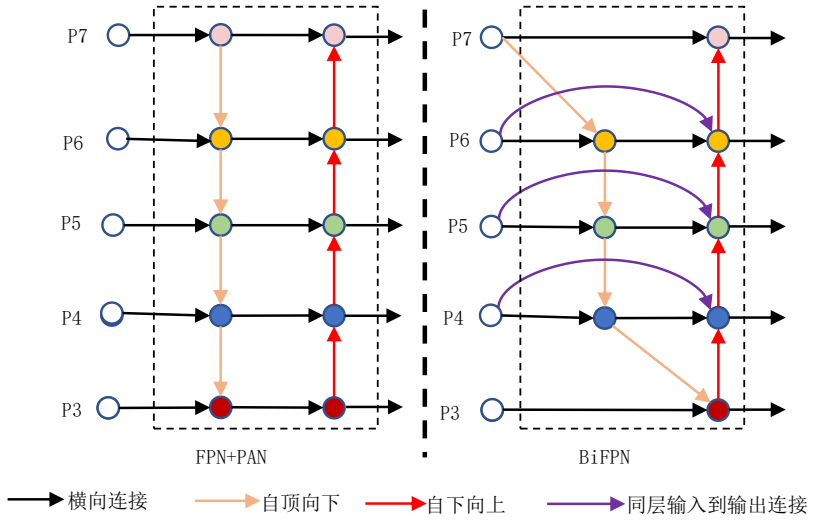


图 4.2 特征融合模块“FPN+PAN”与 BiFPN 结构

Fig.4.2 Structure Feature fusion module “FPN+PAN” and BiFPN

相较于 FPN+PAN 特征融合结构，BiFPN 主要创新如下：（1）删去了只有单条边输入的未及逆行特征融合的点，用来简化网络；（2）在同层的输入输出特征间添加了一条路径，以在不增加网络太大负担的情况下，丰富输出特征的来源；（3）特征的加权融合策略。给每个融合的调整添加可学习的权重，根据网络训练结果调

中国知网 https://www.cnki.net

整不同特征对融合特征的贡献。BiFPN 采用快速归一化特征融合的方式进行特征的加权，公式见式（4.5）。

$$O=\sum_{i}\frac{w_i}{\varepsilon+\sum_{j}w_j}I_i \tag{4.5}$$

其中$w_i>=0$，每个w_i在后使用 ReLU 函数可以实现，ε=0.00001确保计算的稳定性。

具体特征融合过程，以第六层特征融合为例，如公式（4.6）所示。

$$\begin{aligned}P_6^{td}&=\mathrm{Conv}\left(\frac{w_1\cdot P_6^{in}+w_2\cdot \mathrm{Resize}(P_7^{in})}{w_1+w_2+\epsilon}\right)\\ P_6^{\mathrm{out}}&=\mathrm{Conv}\left(\frac{w_1'\cdot P_6^{in}+w_2'\cdot P_6^{td}+w_3'\cdot \mathrm{Resize}(P_5^{\mathrm{out}})}{w_1'+w_2'+w_3'+\epsilon}\right)\end{aligned} \tag{4.6}$$

其中 Resize 操作通常是下采样或上采样操作；w 是我们学习到的参数，用于区分特征融合过程中不同特征的重要程度。

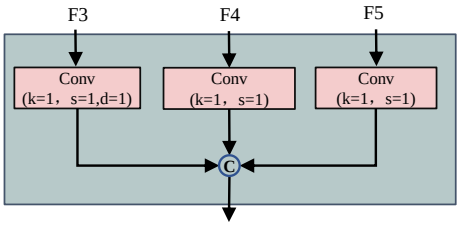
4.3.2 特征融合方式研究

BiFPN 采用的快速归一化特征融合方式进行特征的加权融合，但这种融合方式却不一定是最优的。为了研究不同融合方式对网络精度的影响，本文更换 BiFPN 融合方式，通过实验探索最优的特征融合方式。

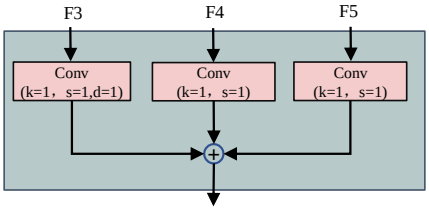
具体融合方式见图 4.3 所示。在所有融合方式中，加权拼接融合（concat fusion）与加权相加方式（add fusion）是最简单和常见的方式，除此之外还有自适应加权融合方式（adaptive fusion）[67]和结合语义与细节信息的融合方式（semantics and detail fusion，SDI）[65]。这四种特征融合方式均采用一个 conv1×1 卷积调整通道数，在最后融合阶段通过上/下采样统一特征尺度。加权拼接融合与加权相加方式分别采用拼接操作和直接相加的操作进行不同尺度特征融合，其结构如图 4.3（a）、（b）所示。自适应加权融合方式则引入空间自适应权重思想进行特征融合，其结构如图 4.3（c）所示。空间自适应权重通过卷积和 Softmax 操作实现，具体操作为：首先相加操作融合三个特征层 F3、F4、F5 的特征（bs，C，H，W），通过卷积融合所有维度的空间信息（bs，3，H，W），经过 Softmax 后拆分为 3 个空间自适应权重值，最后 3 个权重值再次对特征层 F3、F4、F5 进行特征筛选，并将上下文信息聚合到输出。结合语义与细节信息的融合方式则是分别对三个特征层 F3、F4、F5 通过空间注意力和通道注意力后，通过相乘的方式进行融合，其结构如图 4.3（d）所示。其中，卷积核大小为 5 的 GSConv[68]卷积用于平滑重采样特征图。GSConv 结构如图 4.4 所示，它是包含普通卷积、深度可分离卷积和通道混洗，可以实现不同通道上统一交换局部特征信息，将卷积生成的信息渗透到所有的特征图同都中。在

中国知网 https://www.cnki.net

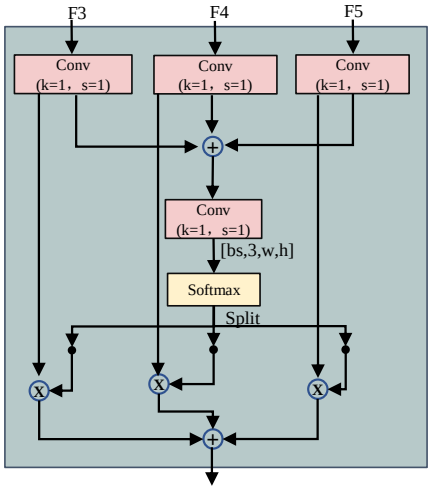
章节 5.4.1 中对不同融合方式的效果进行了实现。



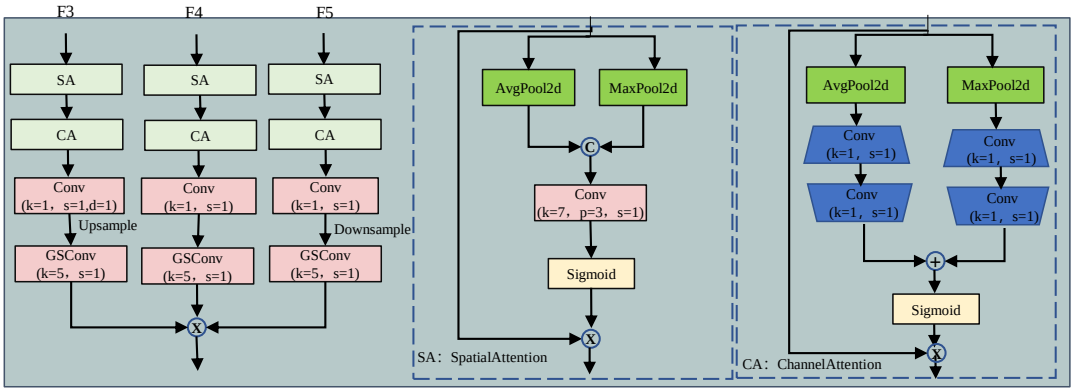
（a）加权拼接融合



（b）加权相加融合



（c）自适应加权融合



（d）语义与细节融合

图 4.3 特征融合方式

Fig.4.3 Feature fusion mode

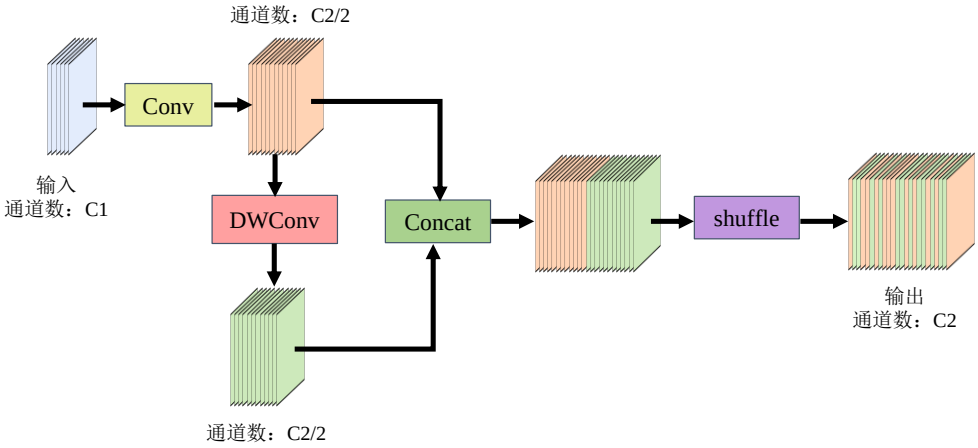


图 4.4 GSConv 结构图

Fig.4.4 GSConv structure diagram

中国知网 https://www.cnki.net

4.4 实验与分析

4.4.1 数据集与评价指标

数据集：本文在 COCO2017 数据集上评估我们的模型。COCO2017 关键点检测数据集是一个广泛应用于计算机视觉领域的数据集，特别适用于人体姿态估计和关键点检测任务。它由超过 200,000 张图像和 250,000 个人物实例以及 17 个关键点组成。训练集包含 57K 图像，验证集和测试集分别包含 5K 和 20K 图像。数据集中的图像包含了不同尺度、光照条件、遮挡程度和背景复杂度的情况，使得基于该数据集训练的模型更具鲁棒性和泛化能力。数据集为图像中出现的人体提供了详细的关键点标注，如头部、肩部、肘部、手腕、臀部、膝盖和脚踝等，如图 4.5 所示。本文在训练集上训练模型，并在验证集和测试集上的评估模型效果。

评价指标：本文主要对识别的精度进行对比，因此评价指标选择平均精度mAP、mAP_{50}和平均召回率 AR，具体介绍见 2.4.2 节。



图 4.5 COCO 姿态估计数据集

Fig.4.5 COCO pose estimation dataset

4.4.2 试验环境与参数设置

实验环境同 3.6.1 节。本章使用 Adam 优化器训练模型，模型其余训练超参数设置如表 4.3 所示。

表 4.3 模型训练超参数

Table 4.3 Model training hyperparameters

参数名称	参数值
learning rate	0.01
weight decay	0.0005
linear warmup epoches	3

中国知网 https://www.cnki.net

表 4.3 模型训练超参数（续）
Table 4.3 Model training hyperparameters

参数名称	参数值
data augmentation	colour distort, crop, flip，mosaic
Input image-size	960*960
epochs	200

4.4.3 对比试验

本实验主要对比了基准网络 YOLO-Pose（主干网为 YOLOv5m）与本章添加 SDI 特征融合方式的 SDBiFPN 的 YOLO-Pose 算法。

表 4.4 人体姿态估计对比试验实验结果
Table 4.4 Results of human posture estimation comparison test

模型	mAP	mAP_{50}	AR
YOLO-Pose	66.5%	89.4%	73.2%
YOLO-Pose-SDBiFPN	67.9%	90.3%	74.1%

实验结果如表 4.4 所示。本章提出的添加带有 SDI 特征融合模块的 BiFPN 模块明显提升 YOLO-Pose 姿态估计效果。与基准网络相比，本章提出的添加 SDI 特征融合方式的 SDBiFPN 的 YOLO-Pose 算法在mAP、mAP_{50}和 AR 上分别提升了 1.4%、0.9%和 0.9%。算法检测效果如图 4.6 所示。



图 4.6 运动员姿态估计效果
Fig.4.6 Effect of athlete posture estimation

4.4.4 消融实验

本实验为评估对不同特征融合方式添加到 BiFPN 后对 YOLO-Pose 检测精度

中国知网 https://www.cnki.net

的影响而设计，通过分别向 BiFPN 中添加加权拼接方式（concat fusion）与加权相加方式（add fusion）、自适应加权融合方式（adaptive fusion）和结合语义与细节信息的融合方式（SDI，semantics and detail fusion）四种不同的特征融合方式进行试验验证。实验结果见表 4.5。

表 4.5 BiFPN 特征融合方式实验结果

Table 4.5 Experimental results of BiFPN feature fusion mode

BiFPN	concat	add	adaptive	SDI	mAP	mAP_{50}	AR
					66.5%	89.4%	73.2%
√					67.3%	89.6%	73.4%
	√				66.2%	88.6%	72.8%
		√			66.4%	88.9%	73.1%
			√		67.5%	90.1%	73.5%
				√	67.9%	90.3%	74.1%

*表中“√”表示添加该模块

由表 4.5 可知，YOLO-Pose 在添加 BiFPN 后检测效果有些微提升，mAP、mAP_{50}和 AR 上分别提升了 0.8%、0.2%和 0.2%。但是使用加权拼接方式和加权相加方式替换原 BiFPN 融合方式后，检测效果却有微小的下降。自适应加权融合方式和结合语义与细节信息的融合方式两种方式替换原 BiFPN 特征融合方式后，检测效果再次有提升，相较基准网络mAP、mAP_{50}和 AR 上分别提升了 1.4%、0.9%和 0.9%。所以使用结合语义与细节信息的融合方式（SDI）可以增强 BiFPN 特征融合的效果，较为明显的提升 YOLO-Pose 的检测效果。

4.5 本章小结

本章针对运动员姿态估计任务，基于 YOLO-Pose 从多尺度特征融合模块角度进行优化。针对原 YOLO-Pose 在多尺度特征融合网络部分无法区分不同层特征对网络的贡献问题，本章引入了加权双向特征金字塔网络（BiFPN），通过特征加权的方式区分不同层特征对网络的贡献。此外，本章对特征融合的方式做进一步研究，通过对比不同的融合方式，探究了一种最优的特征融合方法，以提升多尺度特征融合的效果。最后，通过实验验证优化方案的有效性。

中国知网 https://www.cnki.net

5 基于羽毛球与运动员信息的击球帧检测算法

作为羽毛球运动中重要的一个环节，羽毛球击球帧对于分析球员的技术水平、战术意图以及比赛状态都至关重要。本章分析羽毛球击球帧检测这一任务的特点，设计一个基于羽毛球与运动员信息的击球帧检测算法。算法结合羽毛球的目标检测结果和运动员的姿态估计信息，分析羽毛球的运动轨迹和运动员的挥拍动作，判断击球瞬间，实现羽毛球击球帧检测任务。

5.1 任务分析与方案设计

如图 5.1 所示，羽毛球击球帧是运动员在挥拍击球过程中，拍与球接触的关键瞬间。在羽毛球运动的视频分析中，传统的帧检测方法无法精确捕捉这一关键瞬间。由于羽毛球运动图像的高速动态性、特征识别难度大与复杂背景等特点，以及传统帧检测方法失效，本文转向先进的图像处理和计算机视觉技术方面进行算法设计。



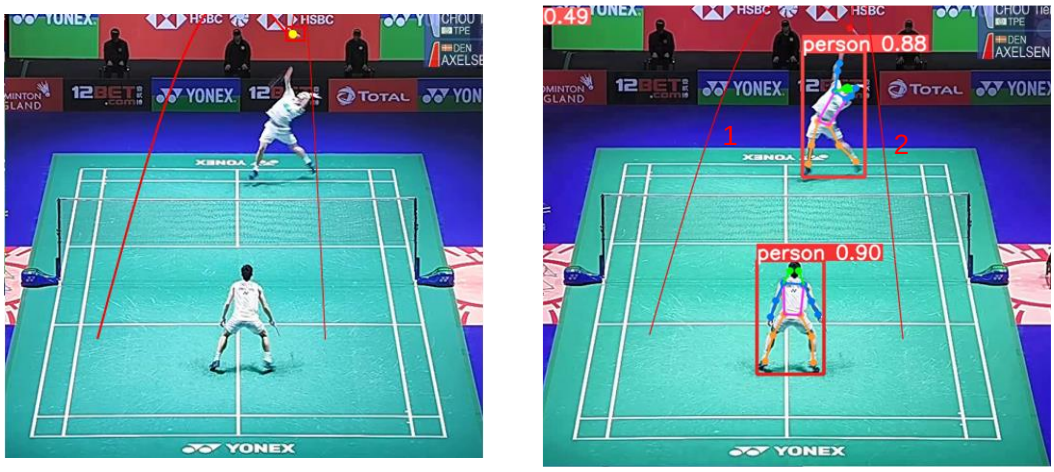
图 5.1 羽毛球击球帧

Fig.5.1 Badminton shot frame

羽毛球击球帧不仅是挥拍过程的结束点，也是球路变化的起始点。也就是说，击球帧共有三个参与者:运动员发起，球拍连接，羽毛球承担。理论上来说，作为发起者，我们只需要对运动员动作进行检测即可实现羽毛球击球帧检测，但是运动员击球时的姿态多种多样，他们击球时的动作、击球位置等都不同，甚至有时需要跳起或者扑到击球。因此，直接使用运动员姿态检测击球帧在实际实现上很难，甚至无法实现。而击球帧时球路变化的起始点，同时也是上一条球路的终点，因此通过检测羽毛球球路来进行击球帧检测是另一条备选方案，即通过羽毛球飞行趋势进行击球帧检测。然而该方案在面对无法准确区分连续球路的情况是会失效，如图

中国知网 https://www.cnki.net

5.2（a）。但运动员的挥拍动作信息可以作为补充实现球路的划分，此时便检测到击球帧，如图 5.2（b）。通过结合羽毛球信息与运动员击球姿态信息（如持拍手腕关键点等），便可以判断到球路更换的瞬间。



（a）仅羽毛球飞行趋势方案失效情况　　（b）结合羽毛球飞行趋势与运动员姿态方案

图 5.2 羽毛球击球帧检测方案示意图

Fig.5.2 Schematic diagram of the detection scheme of badminton shot frames

基于上述分析，本文提出的羽毛球击球帧识别算法，框架如图 5.3 所示。该算法利用第三章提出的 Badminton-DETR 羽毛球检测算法获取羽毛球信息，利用第四章优化后的 YOLO-Pose 获取运动员信息，通过将羽毛球的目标检测结果和运动员的姿态估计信息相结合，更全面地分析击球过程，提高检测精度。算法细节见 5.2 节。

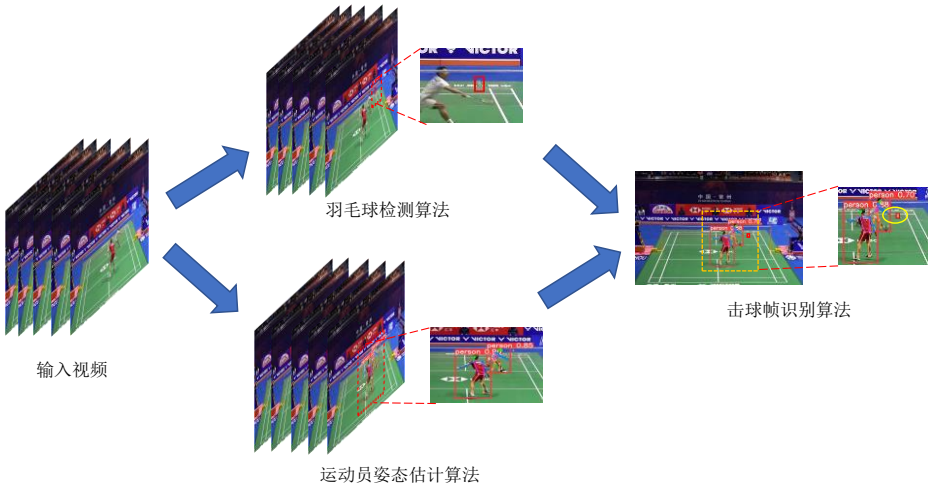


图 5.3 击球帧识别算法框架

Fig.5.3 Frame recognition algorithm framework

中国知网 https://www.cnki.net

5.2 羽毛球击球帧检测算法研究

击球帧一般指因运动员击打羽毛球并改变其飞行方向的帧，在智能化羽毛球分析系统中占据重要的地位。它包含着运动员的击球位置、击球动作、双方回球时的动作，羽毛球的落地点、击球点等，是下游的羽毛球分析应用的前提，如羽毛球轨迹重建、击球动作识别、运动分析等。为方便描述，本文将某时刻羽毛球所处的位置称为“点”，如羽毛球落地位置称为“落地点”。比赛中，羽毛球应处于地面状态、手持状态和飞行状态三种，特殊点一般为羽毛球状态之间切换时刻的位置。羽毛球所处特殊状态可分为落地点、发球点、击球点，本文将这三种状态所处的视频帧，称之为击球帧。

如图 5.4 所示，算法整体流程如下：对输入视频当前帧，首先进行羽毛球检测和运动员姿态检测，并通过筛选机制对羽毛球检测结果进行筛选，留下正确的羽毛球点。然后利用当前帧的羽毛球位姿和运动员位姿进行羽毛球状态更新。最后通过击球帧判断条件，判别当前帧是否为击球帧，满足条件则输出击球帧，不满足则进入下一帧检测，依次循环进行。

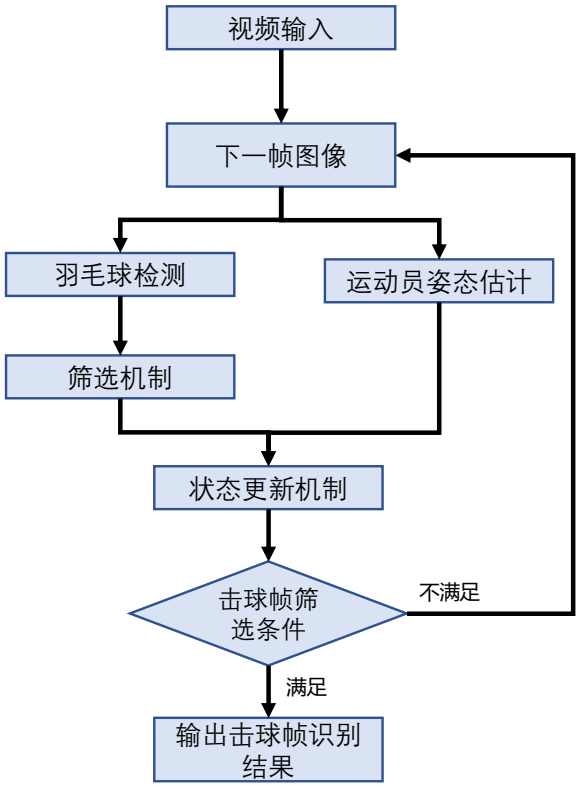


图 5.4 击球帧识别算法流程

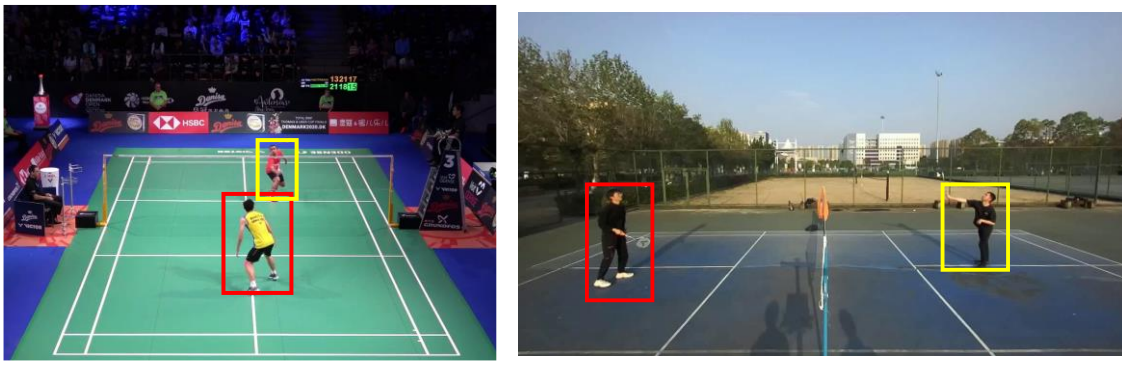
Fig.5.4 Process of shot frame recognition algorithm

其中筛选机制、状态更新机制与击球帧判断条件具体细节如下：

中国知网 https://www.cnki.net

筛选机制。筛选机制对羽毛球检测结果进行筛选，排除干扰检测点，主要筛除离群点（离群点一般为误识别目标）、落地点（羽毛球落地静止状态的羽毛球）、发球持球点（发球时手拿球阶段）等非羽毛球运动状态点。

状态更新机制。状态更新机制对羽毛球飞行状态进行更新。本文对羽毛球飞行状态定义如下：①稳定飞行状态，指羽毛球在空中正常飞行，不改变方向的情况，使用“S”（steady）表示。②向友方飞行，指羽毛球朝向友方飞型，本文以左侧或者底部运动员为友方，使用“F”（Friend side）表示。③向对方飞行，指羽毛球朝向对方飞行，本文以右侧或者顶部运动员为对方，使用“O”（Opposite side）表示。④落地状态，指羽毛球落地静止状态，表示此次击球回合结束，使用“E”（End）表示。如图 5.5 所示，红色框表示友方运动员，黄色框表示对方运动员。根据羽毛球位姿、前后帧之间的相对位置、羽毛球与运动员持拍手关键点的相对位置（根据像素坐标计算），判断羽毛球飞行状态，并进行状态更新。



（a）转播视角　　（b）侧面视角

图 5.5 运动员划分

Fig.5.5 Division of athletes

击球帧判断条件。羽毛球初始化状态为 S，当羽毛球当前状态与前一刻状态不同，则表示羽毛球的飞行状态以改变，代表当前帧为击球帧，否则该帧为普通帧。（1）如果之前羽毛球状态是 S，当前羽毛球状态是 F 或 O，表明比赛开始，视为击球帧；（2）如果之前羽毛球状态为 F，当前羽毛球状态为 O，则表明运动员击打羽毛球，导致羽毛球飞行方向更换，视为击球帧（反之亦然）。

5.3 实验与分析

（1）试验与分析

本实验选择两个数据来源下的羽毛球视频进行实验，其中 tracknetv2 为比赛转播视角共有 6 场比赛，俱乐部比赛包含侧面视角和头顶视角两个视角共有 7 场比赛。实验采用准确率作为评价指标，准确率采用朴素的计算方式计算，即检出击球

中国知网　https://www.cnki.net

帧与总击球帧的数量的百分比。实验结果如表 5.1 所示。本文提出的羽毛球击球帧检测算法可实现击球帧的有效识别，转播视角准确率达到 84.7%，其他视角准确率达到 89.3%，平均精度可达到 87.0%。

表 5.1 击球帧识别实验结果

Table 5.4 Experimental results of shot frame recognition

视频	场数	包含击球帧数量	检测击球帧数量	准确率
Tracknetv2	6	263	242	84.7%
俱乐部比赛	7	245	235	89.3%
总计	13	508	477	87.0%

（2）可视化效果

图 5.6 为羽毛球击球帧检测算法结果。由可视化结果可知，算法可以很好的实现羽毛球击球帧的检测。图中的红色轨迹为羽毛球信息生成的轨迹，轨迹的起始点均为击球帧，算法默认轨迹重点为击球帧。

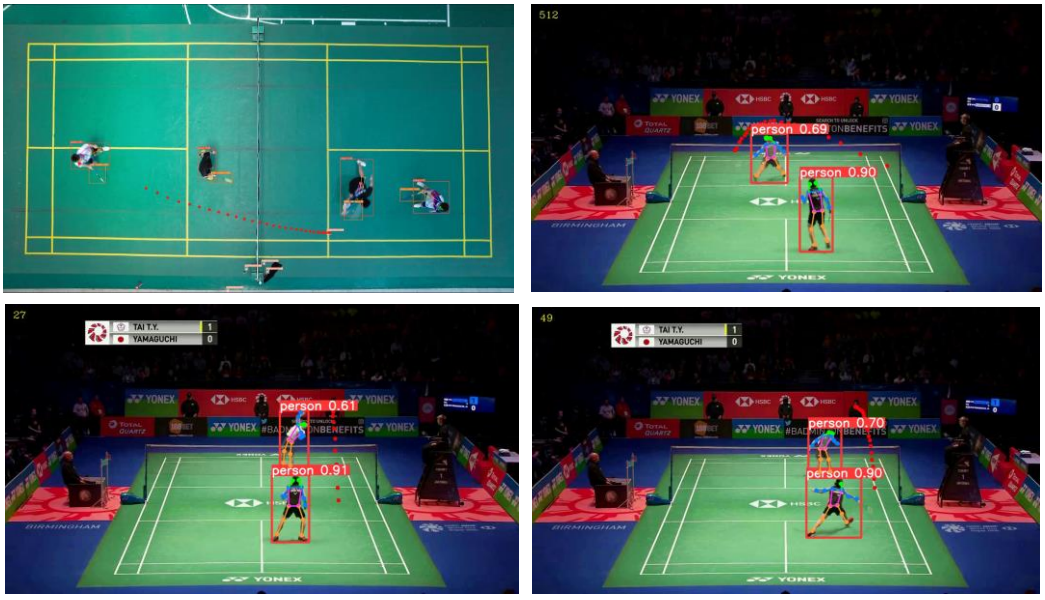


图 5.6 羽毛球击球帧检测结果

Fig.5.6 Badminton shot frame detection result

5.4 本章小结

本章分析羽毛球击球帧检测这一任务的特点，设计一个基于羽毛球与运动员信息的击球帧检测算法。算法结合羽毛球的目标检测结果和运动员的姿态估计信息，分析羽毛球的运动轨迹和运动员的挥拍动作，判断击球瞬间，实现羽毛球击球

中国知网 https://www.cnki.net

帧检测任务。最后，通过实验验证本文所设计算法的有效性。

中国知网 https://www.cnki.net

6 结论与展望

6.1 结论

智能化体育分析系统利用运动员的比赛数据进行运动分析，对运动员比赛风格、比赛习惯、胜败原因等进行总结，以提高运动员们的竞技水平，制定获胜策略。击球帧是指羽毛球运动中球员击打羽毛球并改变其飞行方向的视频帧，包含运动员的击球位置、羽毛球的着陆区域和双方回球时的动作等信息。这些信息正是智能化羽毛球分析系统所需要的基础信息，对识别击球方式和制定技战术策略等任务下游任务至关重要。然而，目前却缺乏一种羽毛球击球帧检测算法。羽毛球检测是羽毛球击球帧检测的基础，并以运动员姿态作为辅助。但是，当前羽毛球检测算法参数量大、复杂度高，需要高算力设备支持，并且因羽毛球自身特点和球场上的复杂环境，造成羽毛球图像微小、模糊、特征少和拖尾严重等，导致羽毛球检测精度偏低。

鉴于此，本文提出了一种利用羽毛球姿态和运动员姿态进行击球帧检测的算法，以满足智能化羽毛球分析系统对羽毛球数据获取的部分需求。并对所需的前置算法，羽毛球检测算法和关键点检测算法进行研究，实现在预测精度、计算速度、计算复杂度等方面的性能综合平衡。本文所作的主要工作如下：

（1）本文提出了一种轻量化羽毛球检测算法。该算法可以在较小的计算开销下，实现实时的羽毛球高精度检测。算法主要采用了以下的策略：①本文设计了一个轻量化特征提取模块，优化模型的特征提取骨干网络。首先，本文通过实验选用参数量和速度平衡性更好的 PConv 作为模块的核心卷积，并引入结构重参数化和高效的轻量化注意力模块 EMA 提升模型特征提取能力，设计了轻量化特征提取模块。②本文提出了一个轻量化的多尺度特征提取与融合模块。针对网络中上/下采样核存在提供特征呆板、单一的问题，本文提出了注意力双分支并行上/下采样模块，同时设计了一个轻量化的并行空洞卷积特征提取模块。在此基础上，本文实现串行的跨层连接和并行多分支结构结合，有效地提高模型的特征提取能力和表征能力。③针对羽毛球小目标特点，本文改进了边界框损失函数的计算方法，以提升小目标对损失函数的贡献，提高羽毛球检测的效果。实验结果表明，本文所提出的算法在羽毛球数据集上，相较其他算法，在模型预测精度、计算速度与模型计算复杂度等性能综合考虑下表现最优。本文所提出的方法与基准网络的 RT-DETR（Resnet18）相比，虽然计算量增加了 22.5G，但是参数量下降了 4.2M，FPS 提升了 2.2，mAP_{50}、$mAP_{50:95}$、精确率和召回率分别提高了 4.5%、7.0%、8.2%和 4.7%。

（2）本文提出了一种羽毛球击球帧检测算法。该算法利用检测到的羽毛球姿

中国知网 https://www.cnki.net

态信息和运动员姿态信息判别羽毛球飞行状态，而后根据羽毛球飞行状态进行击球帧的检测。①本文优化了 YOLO-Pose 关键点检测算法，提高算法检测的精度。针对 YOLO-Pose 采用的通道拼接多尺度特征融合方式无法区分不同尺度特征对检测的贡献问题，本文引入了 BiFPN 结构，并针对 BiFPN 特征融合的方式做进一步研究，通过对比不同的融合方式，探究了一种最优的特征融合方法，以提升多尺度特征融合的效果。②提出了一种羽毛球击球帧识别算法，结合羽毛球信息和运动员姿态信息进行击球帧的识别。通过设计的实验验证了本文提出算法的有效性，其中击球帧检测算法准确率达到 87.0%。

6.2 展望

本文旨在研究智能化羽毛球分析系统中的羽毛球数据获取方法，重点关注羽毛球击球帧检测这一具体问题，并同时对其前置任务羽毛球检测和关键点检测进行研究，以促进羽毛球运动的智能化发展。针对目前羽毛球检测和关键点检测在预测精度、计算速度、计算复杂度等方面的性能无法达到综合平衡的问题，以及智能化羽毛球运动分析领域仍旧缺乏一种方法能自动从原始视频中获取羽毛球击球帧的方法，进行了羽毛球击球帧检测算法研究。并且通过实验初步验证了算法的有效性。但是所设计的算法仍存在许多不足之处，未来可能的研究方向如下：

（1）融合 Badminton-DETR 羽毛球检测算法和 YOLO-Pose 多人姿态估计算法，实现多任务模型。两者的整体网络架构都是采用主干网络加上多尺度特征优化模型进行图像特征的提取，因此可以共享特征提取网络。那么利用多任务方式进行羽毛球检测和人体姿态估计检测整合便成为了一种可能。从而实现羽毛球检测和人体姿态估计算法结合。

（2）使用更多的羽毛球场信息进行智能化羽毛球分析系统数据获取算法设计。本文提出算法对一些羽毛球场信息如羽毛球拍和羽毛球场信息利用不足，这些信息同样对羽毛球运动中的球员评估与制胜策略的制定起着一定的作用，因此下一步可以利用分割网络获取羽毛球场的信息，从而进行例如击球是否得分等进行评估。

（3）解决某些特殊情形下，击球帧检测算法精度欠佳问题。本文所提出的算法在某些特定时刻的检测效果欠佳，如在双方球员近网搏杀的时刻，由于双方运动员距离太近，单个视角的图像存在遮挡、重合等问题，导致检测精度下降。因此，下一步可以通过设计多视角采集系统，设计配套算法解决此类问题。

中国知网 https://www.cnki.net

参考文献

[1] Wikipedia Contributors, “Hawk-Eye,”. Availabe: https://en.wikipedia.org/wiki/Hawk-Eye

[2] Rozumnyi D, Kotera J, Sroubek F, et al. The world of fast moving objects[C].Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 5203-5211.

[3] Watanabe H, Nihna Y, Masutani Y, Miyazaki F. Vision-based motion control for a hitting task-hanetsuki[C]. Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 1994, 2: 910-916.

[4] 胡景新, 满永奎, 赵亮, 等. 基于三菱 Q 系列伺服系统的毽球机器人[J]. 控制工程, 2009, 16(S4): 125-128.

[5] 赵军. 基于机器视觉的羽毛球路径跟踪算法的研究及实现[D]. 成都: 电子科技大学, 2017.

[6] 王恺睿. 羽毛球机器人设计与研究[D]. 徐州: 中国矿业大学, 2017.

[7] Kalsotra R, Arora S. Morphological based moving object detection with background subtraction method[C]. 2017 4th International Conference on Signal Processing, Computing and Control. IEEE, 2017: 305-310.

[8] Kamble P R, Keskar A G, Bhurchandi K M. A deep learning ball tracking system in soccer videos[J]. Opto-Electronics Review, 2019, 27(1): 58-69

[9] Komorowski J, Kurzejamski G, Sarwas G. BallTrack: Football ball tracking for real-time CCTV systems[C]. 2019 16th International Conference on Machine Vision Applications (MVA). IEEE, 2019: 1-5.

[10] Huang Y C, Liao I N, Chen C H, et al. Tracknet: A deep learning network for tracking high-speed and tiny objects in sports applications[C]. 2019 16th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). IEEE, 2019: 1-8.

[11] Simonyan K. Very deep convolutional networks for large-scale image recognition[J]. Proc ICLR, 2015.

[12] Noh H, Hong S, Han B. Learning deconvolution network for semantic segmentation[C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 1520-1528.

[13] Sun N E, Lin Y C, Chuang S P, et al. Tracknetv2: Efficient shuttlecock tracking network[C]. 2020 International Conference on Pervasive Artificial Intelligence (ICPAI). IEEE, 2020: 86-91.

[14] Liu P, Wang J H. MonoTrack: Shuttle trajectory reconstruction from monocular badminton video[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 3513-3522.

中国知网 https://www.cnki.net

[15] Jocher Glenn. Yolov8. https: // github. com /ultralytics/ultralytics/tree/main, 2023.

[16] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2117-2125.

[17] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition, 2018: 8759-8768.

[18] Ghiasi G, Lin T Y, Le Q V. Nas-fpn: Learning scalable feature pyramid architecture for object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 7036-7045.

[19] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 10781-10790.

[20] Qiao S, Chen L C, Yuille A. Detectors: Detecting objects with recursive feature pyramid and switchable atrous convolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 10213-10224.

[21] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.

[22] Li J, Liang X, Shen S M, et al. Scale-aware fast R-CNN for pedestrian detection[J]. IEEE Transactions on Multimedia, 2017, 20(4): 985-996.

[23] Li Y, Chen Y, Wang N, et al. Scale-aware trident networks for object detection[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 6054-6063.

[24] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2017: 7263-7271.

[25] Deng C, Wang M, Liu L, et al. Extended feature pyramid network for small object detection[J]. IEEE Transactions on Multimedia, 2021, 24: 1968-1979.

[26] Zhang H, Xu C, Zhang S. Inner-iou: more effective intersection over union loss with auxiliary bounding box[J]. arXiv preprint, 2023.

[27] Wang J, Xu C, Yang W, et al. A normalized Gaussian Wasserstein distance for tiny object detection[J]. arXiv preprint, 2021.

[28] Yang X, Yang J, Yan J, et al. Scrdet: Towards more robust detection for small, cluttered and rotated objects[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 8232-8241.

[29] Lu X, Ji J, Xing Z, et al. Attention and feature fusion SSD for remote sensing object

中国知网 https://www.cnki.net

detection[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-9.

[30] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 213-229.

[31] Zhu X, Su W, Lu L, et al. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C]. International Conference on Learning Representations. 2020.

[32] Dai X, Chen Y, Yang J, et al. Dynamic detr: End-to-end object detection with dynamic attention[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 2988-2997.

[33] Toshev A, Szegedy C. Deeppose: Human pose estimation via deep neural networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 1653-1660.

[34] Sun X, Shang J, Liang S, et al. [C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 2602-2611.

[35] Newell A, Yang K, Deng J. Stacked hourglass networks for human pose estimation[C]. Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14. Springer International Publishing, 2016: 483-499.

[36] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 5693-5703.

[37] Yu C, Xiao B, Gao C, et al. Lite-hrnet: A lightweight high-resolution network[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 10440-10450.

[38] Su K, Yu D, Xu Z, et al. Multi-person pose estimation with enhanced channel-wise and spatial information[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 5674-5682.

[39] Qiu L, Zhang X, Li Y, et al. Peeking into occluded joints: A novel framework for crowd pose estimation[C]. Computer Vision–ECCV, 2020: 488-504.

[40] Yang S, Quan Z, Nie M, et al. Transpose: Keypoint localization via transformer[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 11802-11812.

[41] Cao Z, Simon T, Wei S E, et al. Realtime multi-person 2d pose estimation using part affinity fields[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 7291-7299.

中国知网 https://www.cnki.net

[42] Wei S E, Ramakrishna V, Kanade T, et al. Convolutional pose machines[C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2016: 4724-4732.

[43] Pishchulin L, Insafutdinov E, Tang S, et al. Deepcut: Joint subset partition and labeling for multi person pose estimation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4929-4937.

[44] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[45] Kalman B. L, Kwasny S. C. Why tanh: choosing a sigmoidal function[C]. [Proceedings 1992]IJCNN International Joint Conference on Neural Networks, 1992, 578-581.

[46] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]. Proceedings of thefourteenth international conference on artificial intelligence and statistics, 2011, 315-323.

[47] Zhou G, Zhu X, Song C, et al. Deep interest network for click-through rate prediction[C]. Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018, 1059-1068.

[48] Misra D. Mish: A self regularized non-monotonic activation function[J]. arXiv preprint , 2019.

[49] Chollet F. Xception: Deep Learning with Depthwise Separable Convolutions[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017:1800-1807.

[50] Sifre L, Mallat S. Rigid-motion scattering for image classification[D]. Ecole Polytechnique, 2014.

[51] Zhu X, Hu H, Lin S, et al. Deformable convnets v2: More deformable, better results[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 9308-9316.

[52] Wang W, Dai J, Chen Z, et al. Internimage: Exploring large-scale vision foundation models with deformable convolutions[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 14408-14419.

[53] Han K, Wang Y, Tian Q, et al. Ghostnet: More features from cheap operations[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 1580-1589.

[54] Chen J, Kao S, He H, et al. Run, Don't walk: Chasing higher FLOPS for faster neural networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 12021-12031.

[55] Ding N, Takeda K, Jin W, et al. Estimation of control area in badminton doubles with pose information from top and back view drone videos[J]. arXiv preprint, 2023.

中国知网 https://www.cnki.net

[56] Lv W, Xu S, Zhao Y, et al. DETRs Beat YOLOs on Real-time Object Detection[J]. arXiv preprint, 2023

[57] Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great again[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 13733-13742.

[58] Ouyang D, He S, Zhang G, et al. Efficient multi-scale attention module with cross-spatial learning[C]. ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.

[59] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]. Medical Image Computing and Computer-Assisted Intervention(MICCAI), 2015: 234-241.

[60] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.

[61] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.

[62] Szegedy C, Ioffe S, Vanhoucke V, et al. Inception-v4, inception-resnet and the impact of residual connections on learning[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2017, 31(1).

[63] Chen Y, Wang Z, Peng Y, et al. Cascaded pyramid network for multi-person pose estimation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7103-7112.

[64] Cheng B, Xiao B, Wang J, et al. Higherhrnet: Scale-aware representation learning for bottom-up human pose estimation[C. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 5386-5395.

[65] Peng Y, Sonka M, Chen D Z. U-Net v2: Rethinking the Skip Connections of U-Net for Medical Image Segmentation[J]. arXiv preprint, 2023.

[66] Maji D, Nagori S, Mathew M, et al. Yolo-pose: Enhancing yolo for multi person pose estimation using object keypoint similarity loss[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 2637-2646.

[67] Xiao J, Zhao T, Yao Y, et al. Context augmentation and feature refinement network for tiny object detection[J], 2021.

[68] Li H, Li J, Wei H, et al. Slim-neck by GSConv: A better design paradigm of detector architectures for autonomous vehicles[J]. arXiv preprint, 2022.

中国知网 https://www.cnki.net

D 学位论文数据集

关键词	密级	中图分类号
羽毛球检测，多尺度特征融合，击球帧，轻量化	公开	TP

学位授予单位名称	学位授予单位代码	学位类别	学位级别
重庆大学	10611	学术学位	硕士

论文题名	并列题名	论文语种
羽毛球击球帧检测算法研究	无	中文

作者姓名	郜深阵	学号	202113021012
培养单位名称		培养单位代码	
重庆大学		10611	

学科专业	研究方向	学制	学位授予年
控制科学与工程	计算机视觉	3 年	2024
论文提交日期	2024.06	论文总页数	73
导师姓名	薛方正	职称	教授
答辩委员会主席		王智慧	

电子版论文提交格式
文本（） 图像（） 视频（） 音频（） 多媒体（） 其他（）

中国知网 https://www.cnki.net